

Lista 1

Variáveis, tabelas e estatísticas descritivas

Conteúdo Aulas 1 a 3
Turma 4A · 2026/2
Professor Julio Trecenti
Versão Com respostas comentadas. Não distribuir antes do prazo.

POR ONDE COMEÇAR

As questões marcadas com uma estrela vermelha são o caminho mínimo: são onze de vinte e oito, e juntas cobrem uma vez cada conceito das aulas 1 a 3. Se o tempo for curto, faça essas e volte às outras quando puder. As demais repetem os mesmos conceitos em outros contextos, e é a repetição em contextos diferentes que faz o conceito grudar.

PARTE 1

Variáveis e papéis

Questão 1 ★

FÁCIL

Um escritório trabalhista quer saber quanto costuma receber nos acordos que fecha. Uma estagiária montou a planilha abaixo com os seis acordos homologados no mês passado.

processo	valor_acordo	n_audiencias
0001234-12.2024.5.02.0001	R\$ 18.000,00	2
0002345-23.2024.5.02.0011	R\$ 7.500,00	1
0003456-34.2024.5.02.0004	R\$ 42.000,00	3
0004567-45.2024.5.02.0022	R\$ 12.000,00	2
0005678-56.2024.5.02.0009	R\$ 9.500,00	1
0006789-67.2024.5.02.0015	R\$ 25.000,00	4

Ela rodou uma linha e mostrou o resultado ao sócio:

```
df["valor_acordo"].mean()
```

19000.0

O sócio olhou a tela e comentou: "então o acordo é R\$ 19.000,00".

Explique, em um parágrafo, por que essa frase confunde três coisas diferentes. Use obrigatoriamente as palavras **variável**, **valor observado** e **estatística**, e diga a qual delas corresponde, na tela acima, o nome valor_acordo, uma célula da planilha e o número 19000.0.

RESPOSTA

A frase trata como se fossem a mesma coisa a coluna, uma célula da coluna e o resumo da coluna inteira.

A **variável** é `valor_acordo`, o nome que aparece dentro dos colchetes na linha de código: a característica que varia de acordo para acordo e que o escritório resolveu medir. Ela não é um número, é uma coluna com seis números.

O **valor observado** é o conteúdo de uma célula: os R\$ 42.000,00 do processo 0003456-34. É o valor de um caso, e existe de fato no mundo, tendo sido pago por alguém a alguém.

A **estatística** é o `19000.0` que apareceu na tela, ou seja, a soma dos seis acordos, R\$ 114.000,00, dividida por 6. Ela é o resultado de uma conta feita sobre a coluna toda e resume os seis casos em um número só. O ponto que a frase perde é que essa estatística não é o valor de nenhum acordo em particular: nenhum dos seis acordos foi de R\$ 19.000,00, e quatro dos seis ficaram abaixo disso. Dizer “o acordo é R\$ 19.000,00” sugere um valor de caso onde existe apenas um resumo de conjunto.

Vale notar que, com seis casos e um acordo de R\$ 42.000,00 no meio, a média é uma escolha ruim para descrever o acordo típico deste escritório. A mediana, que aqui é R\$ 15.000,00, descreveria melhor. A Parte 3 volta a esse ponto.

Questão 2 ★

FÁCIL

Uma procuradoria municipal quer entender por que tantas execuções fiscais prescrevem antes de recuperar o crédito. Montou uma base em que cada linha é uma certidão de dívida ativa executada, cujas primeiras linhas são estas. A coluna `n_citacoes` conta quantas vezes o oficial de justiça tentou citar o devedor.

<code>numero_cda</code>	<code>valor_inscrito</code>	<code>n_citacoes</code>	<code>tributo</code>	<code>houve_penhora</code>	<code>faixa_de_valor</code>
2019/004512	3.420,00	2	IPTU	não	até R\$ 5 mil
2018/011907	47.180,50	1	ISS	sim	R\$ 5 a 50 mil
2020/000883	612,00	3	taxa de lixo	não	até R\$ 5 mil
2017/023144	128.900,00	0	ISS	não	acima de R\$ 50 mil

Ao carregar o arquivo, o pandas informou como guardou cada coluna:

```
df.dtypes
```

```
numero_cda      object
valor_inscrito  float64
n_citacoes      int64
tributo          object
houve_penhora    bool
faixa_de_valor  object
```

Essa saída diz como o computador **guardou** cada coluna, e não que tipo de variável cada uma é. Para cada coluna, diga o tipo de variável (numérica discreta, numérica contínua, categórica nominal, categórica ordinal ou categórica binária) e justifique a escolha em uma frase. Atenção: uma das colunas não é nenhum desses cinco tipos.

RESPOSTA

`valor_inscrito`: **numérica contínua**. É o resultado de medir numa escala de reais. Entre R\$ 5.000,00 e R\$ 5.001,00 existe R\$ 5.000,50, e o limite é apenas o arredondamento adotado pelo fisco, não a natureza da variável.

`n_citacoes`: **numérica discreta**. É o resultado de contar tentativas, e não existe uma tentativa e meia de citação. Aqui a distinção importa de verdade, porque a coluna tem poucos valores possíveis: seria estranho reportar que “a média é 1,7 tentativa” sem explicar que ninguém tenta 1,7 vez.

tributo: **categórica nominal**. São rótulos sem ordem. Não faz sentido dizer que ISS é maior que IPTU, nem que a taxa de lixo fica entre os dois.

houve_penhora: **categórica binária**. Só assume dois valores, sim e não. É um caso particular de nominal, e a peculiaridade útil é que a média dela é a proporção de execuções com penhora.

numero_cda: **nenhum dos cinco, é um identificador**. Serve para achar a certidão de novo, conferir a extração e juntar esta base com a base de arrecadação. Não entra em conta nenhuma.

faixa_de_valor: **categórica ordinal**. As três faixas têm ordem clara, já que “acima de R\$ 50 mil” é inequivocamente mais do que “até R\$ 5 mil”. O que não existe é distância medível entre elas. Repare que essa coluna é **derivada** de valor_inscrito, ou seja, foi criada a partir de uma variável contínua, e essa criação destrói informação de propósito, para facilitar a comparação entre grupos.

O que a saída do dtypes não resolve. Ela distingue apenas texto (object), número com casas decimais (float64), número inteiro (int64) e lógico (bool). Três problemas aparecem na comparação com a lista acima. numero_cda e tributo estão no mesmo balde object, embora um seja identificador e o outro seja variável. faixa_de_valor também está em object, sem nenhum registro de que as três categorias têm ordem, e por isso qualquer ordenação automática vai sair em ordem alfabética, colocando “acima de R\$ 50 mil” primeiro. E n_citacoes aparece como int64, exatamente como apareceria um identificador numérico. O tipo de armazenamento é uma dica, e não a resposta.

Questão 3

FÁCIL

Um Juizado Especial Cível exporta as sentenças do ano num arquivo em que cada linha é uma sentença. A primeira coluna, id_sentenca, é um número sequencial que o sistema atribui a cada documento no momento em que ele é assinado.

id_sentenca	data_assinatura	resultado
4183291	03/02/2025	procedente em parte
4183508	03/02/2025	improcedente
4184017	04/02/2025	procedente
...	...	...

Um estagiário quis “resumir a base” e rodou a média de todas as colunas numéricas:

```
df["id_sentenca"].mean()
```

```
4183729.6
```

Explique o que esse resultado significa, e diga qual é a única informação sobre id_sentenca que vale a pena olhar.

RESPOSTA

Significa apenas que, somando os identificadores das sentenças e dividindo pelo número delas, chega-se a 4.183.729,6. É uma conta aritmética correta e uma estatística sem sentido nenhum, porque id_sentenca é um **identificador**, e não uma variável.

O identificador serve para achar a sentença de novo e para juntar esta base com outra base do mesmo juizado, e nada mais. Estar guardado como número é um acidente do sistema: o código poderia igualmente ser uma sequência de letras, e nada na análise mudaria.

A média só faz sentido quando a distância entre dois valores significa alguma coisa. Aqui não significa: duas sentenças com números vizinhos não são mais parecidas entre si do que duas sentenças com números distantes. Elas apenas foram assinadas em sequência, o que não diz nada sobre o valor, o

resultado ou a matéria. O computador calcula porque só olha o tipo de armazenamento, que é inteiro, e não o tipo da variável, que é identificador. Quem precisa saber a diferença é você.

A única informação útil sobre a coluna é operacional, e é de conferência de qualidade: **quantos identificadores distintos existem, e se esse número bate com o número de linhas**. Em pandas, comparar `df["id_sentenca"].nunique()` com `len(df)`. Se houver menos identificadores distintos do que linhas, existe sentença duplicada na base, e toda conta feita depois estará contando o mesmo caso duas vezes.

Um comentário extra para quem foi além. Como o número é sequencial e crescente no tempo, a diferença entre dois identificadores mede grosseiramente quantas sentenças foram assinadas entre uma e outra, o que ajuda a detectar lacunas na coleta. Isso não transforma a coluna em variável: o que se está medindo aí é a distância entre dois pontos de uma fila, e não uma característica da sentença.

Questão 4

DIFÍCIL

Os números desta questão são reais. Numa base de 460 acórdãos de dano moral do TJSP, a coluna `camara` guarda o número da câmara julgadora, de 1 a 38. Um aluno rodou uma linha de código e colou a saída abaixo no relatório, sem mais nenhum comentário.

```
df["camara"].describe()
```

```
count    393.000000
mean      17.898219
std       10.342592
min        1.000000
25%       11.000000
50%       16.000000
75%       27.000000
max       38.000000
```

- a) Aponte tudo o que está errado em colar essa saída num relatório.
- b) A primeira linha, `count 393`, é a única informação aproveitável aqui. Por quê?
- c) Escreva o que o aluno deveria ter feito, e o que deveria constar do relatório.

RESPOSTA

a) Três camadas de problema, da mais grave para a menos.

A conta está errada em espécie. `camara` é um **identificador**: o número não mede nada do acórdão, ele apenas nomeia o órgão que julgou. É um código, da mesma família do número do processo, e a diferença é só que este cabe em dois dígitos.

Média, desvio padrão e quartis exigem que a distância entre dois valores signifique alguma coisa, e aqui não significa: a 27ª câmara não é maior que a 11ª, e nada existe entre elas. Todos os números da saída, exceto o primeiro, são contas válidas sobre a variável errada. E repare no aviso mais barato de todos: não existe câmara 17,898219 no TJSP. Quando a média devolve algo que não corresponde a nenhuma entidade do mundo, a coluna não era do tipo que se resume.

A confusão com categórica nominal é comum e vale desfazer, porque as duas guardam texto ou código e nenhuma das duas aceita média. O critério que resolve é o mesmo da aula 3: **categórica nominal agrupa casos para comparar; identificador nomeia uma entidade**.

Compare com `comarca`, na mesma base. "São Paulo", "Campinas", "Santos" são nomes de lugar, e a `comarca` é uma característica do processo: dizer que um acórdão é de Santos descreve aquele acórdão. `Comarca` é **categórica nominal**.

Já camara não descreve o acórdão: ela nomeia o colegiado, e o número é o código desse colegiado. Mesma coisa com o código IBGE do município, que é identificador enquanto o nome do município é categórica nominal. A regra prática: **se o valor é um código atribuído a alguma entidade, é identificador; se é um nome que classifica o caso, é categórica nominal.**

Nada disso impede o uso do item (c): identificador não entra em conta, mas continua servindo perfeitamente de chave de agrupamento e de contagem.

A saída não é um resultado, é uma tela. Está em inglês, com seis casas decimais, com rótulos como std e 75% que o leitor de um parecer jurídico não tem obrigação de conhecer, e sem unidade, sem título e sem indicação da fonte. Resultado de análise se apresenta, não se cola.

Falta o contexto do denominador. A saída informa 393, e a base tem 460 linhas. Nada no relatório explica os 67 que faltam, e o leitor que somar errado vai concluir que a base é menor do que é.

b) Porque count é a única linha que não pressupõe que a variável seja quantitativa. Ela apenas conta quantas linhas têm valor preenchido, o que é verdadeiro e útil para qualquer tipo de variável. E aqui ela é especialmente informativa, porque revela que 67 acórdãos, 14,6% da amostra, não têm câmara identificada, o que é um achado sobre a qualidade da extração que merecia ser investigado antes de qualquer outra coisa.

c) O aluno deveria ter contado, e não resumido:

```
df["camara"].value_counts()
```

E, para a leitura em proporção, `value_counts(normalize=True)`.

No relatório deveria constar: quantos acórdãos têm câmara identificada, 393 de 460, com menção explícita aos 67 sem identificação; as câmaras mais frequentes, em número absoluto e em proporção do total, apresentadas numa tabela própria com título e fonte, ou num gráfico de barras; e uma frase de interpretação dizendo o que essa concentração significa, por exemplo se os casos de dano moral se concentram em poucas câmaras ou se distribuem por todo o tribunal.

O que **não** deveria constar em hipótese nenhuma é a média. Se ela aparecer, o leitor atento conclui que quem escreveu o relatório não sabe a diferença entre um número e um rótulo, e passa a desconfiar de tudo o mais que estiver ali.

Questão 5

MÉDIO

Um instituto de pesquisa vai estudar as multas ambientais aplicadas por órgãos federais. A base traz uma linha por auto de infração:

numero_do_auto	orgao_autuante	valor_multa	descricao_da_infracao
9147822-E	IBAMA	R\$ 50.000,00	Transportar 12,4 m³ de madeira serrada de espécie nativa sem licença válida para todo o tempo da viagem.
9148003-E	IBAMA	R\$ 8.500,00	Manter em cativeiro três aves da fauna silvestre nativa sem autorização do órgão competente.
2210447-D	ICMBio	R\$ 130.000,00	Destruir 3,1 hectares de vegetação em área de unidade de conservação de proteção integral.
9148219-E	IBAMA	R\$ 2.000,00	Deixar de apresentar relatório anual de atividades potencialmente poluidoras no prazo.

Depois de coletar tudo, o instituto decidiu restringir a análise apenas aos autos lavrados pelo IBAMA, que são a maioria, e descartou o resto. Conferindo o resultado do recorte:

```
df["orgao_autuante"].value_counts()
```

IBAMA 812

Para cada coluna, diga se ela é ou não uma variável para fins de análise, e por quê.

- a) numero_do_auto
- b) descricao_da_infracao
- c) orgao_autuante, depois do recorte

RESPOSTA

a) Não é variável: é identificador. Serve para localizar o auto, conferir a extração e juntar com a base de cobrança da multa. Não entra em conta nenhuma e não entra em comparação nenhuma. Formalmente ele até "varia", já que é diferente em cada linha, mas variar em todas as linhas é exatamente o que o torna inútil como variável: uma coluna que assume 812 valores distintos em 812 casos não separa grupo nenhum.

b) Não é variável: é a matéria-prima. O texto livre não é um tipo de variável, é o documento de onde as variáveis são extraídas. Basta olhar as quatro descrições da tabela para ver quantas colunas cabem ali dentro: o tipo de infração (transporte, cativo, desmatamento, obrigação acessória), se houve dano a área protegida, a quantidade envolvida com a sua unidade (12,4 m³, três aves, 3,1 hectares) e se a infração é material ou apenas formal. Uma vez extraídas essas colunas, o texto continua na base por dois motivos práticos, que são conferir a extração e permitir extrair variáveis novas mais tarde, mas ele mesmo não entra em conta.

Repare, aliás, que a quantidade envolvida não é uma coluna só: 12,4 m³, três aves e 3,1 hectares não são comparáveis entre si. Ou se criam colunas separadas por unidade, ou se cria uma coluna de quantidade e outra de unidade. Essa decisão é de pesquisa, e é bem mais difícil do que parece.

c) É uma coluna, mas deixou de ser uma variável útil naquela amostra. A saída do `value_counts()` mostra exatamente isso: uma única categoria, com as 812 linhas. Depois do recorte, `orgao_autuante` não varia mais, e uma variável que não varia não explica nada, porque não existe diferença entre casos para associar a diferença nenhuma no desfecho. Se alguém tentar responder "o valor da multa depende do órgão?" com esta base recortada, a resposta não será "não depende", será "não dá para saber".

O problema aqui não é a natureza da coluna: `orgao_autuante` era uma variável perfeitamente boa antes do recorte, e o ICMBio da terceira linha estava lá para provar. O que a matou foi uma decisão de pesquisa. A lição comum aos três casos é que ser variável não é propriedade só da coluna, depende do recorte da amostra e da pergunta que está sendo feita.

Questão 6 ★

MÉDIO

Um grupo de pesquisa vai investigar a seguinte pergunta:

Nas ações de despejo por falta de pagamento, o tamanho do débito está associado à concessão da liminar de desocupação?

A base tem uma linha por ação, e começa assim (o número do processo está abreviado para caber):

numero_processo	valor_do_debito	meses_de_atraso	tipo_imovel	liminar_concedida	houve_purgacao
1004512-88	R\$ 14.300,00	5	residencial	sim	não
1005033-21	R\$ 3.100,00	2	residencial	não	sim
1005190-74	R\$ 62.400,00	9	comercial	sim	não
1005247-09	R\$ 7.800,00	3	comercial	não	não

Percorra as **seis** colunas e, para cada uma, diga qual papel ela cumpre nessa pergunta: identifica o caso, o que eu quero explicar, o que pode explicar, ou define quais casos entram. Mais de uma coluna pode cumprir o mesmo papel, e você precisa justificar cada atribuição em uma frase.

RESPOSTA

numero_processo: identifica o caso. Permite voltar aos autos, conferir a extração e juntar com outras bases. Não entra na comparação.

valor_do_debito: o que pode explicar. É exatamente a característica que a pergunta suspeita estar associada ao desfecho, já que ela fala em "tamanho do débito". É a explicativa principal.

meses_de_atraso: o que pode explicar. A pergunta não a escolheu, mas ela é uma candidata legítima ao mesmo papel: o juiz pode reagir mais ao tempo de inadimplência do que ao valor. Aqui ela entra como característica a controlar, porque, se não for levada em conta, uma associação entre débito e liminar pode na verdade ser uma associação entre atraso e liminar.

tipo_imovel: o que pode explicar. Mesmo papel, pelo mesmo motivo. Imóvel comercial e residencial podem receber tratamento diferente, e essa diferença poderia ser confundida com efeito do valor, já que na tabela os débitos comerciais tendem a ser maiores.

liminar_concedida: o que eu quero explicar. É o desfecho da pergunta, aquilo cuja variação se quer entender. Em estatística, a variável resposta. É categórica binária, e a medida de posição dela é a proporção de liminares concedidas.

houve_purgacao: define quais casos entram. A purgação da mora encerra a discussão sobre o despejo, então o caso deixa de ser comparável aos demais. Restringir a análise às ações em que não houve purgação delimita o universo sem responder à pergunta. Na amostra acima, isso descartaria a segunda linha.

Duas observações que uma boa resposta acrescenta. A primeira é que três colunas caíram no mesmo papel, e isso é o normal: uma pergunta tem um desfecho só, mas costuma ter várias explicativas candidatas. O trabalho de pesquisa é escolher qual delas a pergunta persegue e o que fazer com as outras.

A segunda é que o papel não é propriedade da coluna. Se a pergunta virasse "o locatário purga a mora com mais frequência quando o débito é pequeno?", `houve_purgacao` deixaria de ser filtro e viraria o desfecho, e `liminar_concedida` provavelmente sairia da análise. A mesma tabela, outra pergunta, outros papéis.

Questão 7

MÉDIO

Os CEJUSCs, Centros Judiciários de Solução de Conflitos e Cidadania, foram criados pela [Resolução 125/2010 do CNJ](#) e são as unidades onde os tribunais fazem conciliação e mediação. Eles atuam em duas frentes: a **processual**, quando já existe ação em curso e o juiz remete as partes à tentativa de acordo, e a **pré-processual**, quando a pessoa procura o centro antes de ajuizar qualquer coisa. O acordo obtido é homologado por um magistrado e vale como decisão judicial. O CNJ mantém uma [página de perguntas frequentes sobre a política](#), e o TJSP descreve os seus centros na [página de Conciliação e Mediação](#). Só em São Paulo são 322 centros, que somaram mais de 1,4 milhão de acordos desde 2014, com índice de acordo particularmente alto na frente pré-processual.

Um desses centros mantém uma base com uma linha por audiência realizada:

assunto	valor_da_causa	duracao_minutos	conciliador_capacitado	houve_acordo
Cobrança indevida	R\$ 4.200,00	38	sim	sim
Contrato de locação	R\$ 22.000,00	65	não	não
Plano de saúde	R\$ 9.800,00	22	sim	não
Cobrança indevida	R\$ 1.500,00	15	sim	sim

Escreva **duas** perguntas de pesquisa que possam ser respondidas com essa base e nas quais `houve_acordo` cumpra papéis diferentes: em uma delas ela deve ser o que você quer explicar, e na outra ela deve ser o que pode explicar. Para cada pergunta, diga qual coluna ocupa o outro papel.

RESPOSTA

Como desfecho: "A chance de a audiência terminar em acordo é maior quando o conciliador passou pelo curso oficial do tribunal?" Aqui `houve_acordo` é o que se quer explicar, e `conciliador_capacitado` é o que pode explicar. Essa é uma pergunta de avaliação de política pública, é a mais natural das duas, e é exatamente o tipo de pergunta que a Resolução 125 torna relevante: se a capacitação exigida pela norma tem efeito mensurável.

Como explicativa: "As audiências que terminam em acordo duram mais ou menos tempo do que as que não terminam?" Aqui `houve_acordo` é o que pode explicar, e `duracao_minutos` é o desfecho. Uma variante igualmente boa usa `valor_da_causa` como desfecho: "as causas em que se fecha acordo são as de valor menor?"

O ponto da questão é que nada mudou na coluna. Ela continua sendo categórica binária e continua sendo registrada do mesmo jeito. O que mudou foi a pergunta, e o papel é a posição da coluna na pergunta, não uma etiqueta que a coluna carrega.

Uma resposta boa também percebe um problema na segunda pergunta, mesmo estando ela formalmente correta: acordo e duração acontecem ao mesmo tempo, e não existe ordem clara de causa e efeito entre os dois. Uma audiência pode durar mais porque as partes estão negociando e vão fechar acordo, ou pode terminar rápido justamente porque o acordo veio fácil. Nas quatro linhas da amostra as duas histórias aparecem: a de 15 minutos terminou em acordo e a de 65 minutos não. A associação vai aparecer nos dados, e explicá-la exige um argumento que os dados sozinhos não dão. Perceber isso é análise, e não estatística.

Questão 8**DIFÍCIL**

Um Procon estadual tem 380 reclamações registradas contra empresas de telefonia. O atendente que registra a reclamação ouve o consumidor, escreve um relato livre e escolhe um assunto numa lista fechada que hoje tem 40 opções. Quatro registros, feitos por atendentes diferentes:

id	relato do consumidor	assunto escolhido
1	Apareceu na conta um pacote de streaming que eu nunca pedi, e já paguei três meses.	Cobrança indevida
2	Estão me cobrando por um serviço adicional que eu não contratei, desde março.	Serviço não fornecido
3	Veio na fatura uma assinatura que eu não reconheço e a operadora não soube explicar.	Problema na fatura
4	Cobram de mim um plano que nunca foi ativado na minha linha.	Cobrança abusiva

Um requisito das variáveis categóricas é que as categorias sejam **mutuamente exclusivas e exaustivas**. Discuta se a coluna de assunto cumpre o requisito, explique o que dá errado na análise quando ele não é cumprido, e proponha um tratamento concreto.

RESPOSTA

Exclusividade. Não é cumprida, e a tabela mostra isso da forma mais direta possível: os quatro relatos descrevem **o mesmo fato**, que é cobrança por serviço não contratado, e caíram em quatro categorias diferentes. A categoria registrada não é uma classificação feita segundo um critério de pesquisa: é o que cada atendente escolheu na tela, num dia de trabalho, entre quarenta opções parecidas. Casos substancialmente iguais caem em categorias diferentes, e casos diferentes caem na mesma.

Exaustividade. Formalmente é cumprida, porque toda reclamação recebe algum assunto. Mas de um jeito que não ajuda: com 40 categorias para 380 reclamações, a média é de menos de dez casos por categoria, e a cauda é povoada por categorias com uma ou duas reclamações.

O que dá errado. Primeiro, e mais grave, a comparação entre categorias não mede diferença de assunto, mede diferença de registro. Um relatório que diga "cobrança indevida é a principal queixa contra a

telefonia" pode estar apenas descrevendo o hábito de digitação de alguns atendentes, e nesta amostra o mesmo problema aparece com peso 1 em quatro categorias, em vez de peso 4 em uma. A frequência de cada categoria está sistematicamente subestimada, e não por acaso: está diluída.

Segundo, a comparação entre grupos fica sem base, porque um grupo com três reclamações não sustenta uma proporção que se possa comparar com nada. Terceiro, a moda fica instável: basta um punhado de casos novos para trocar a categoria mais frequente.

Tratamento concreto. Agrupar as categorias segundo um critério explícito, definido e escrito **antes** de olhar os resultados. Por exemplo, reduzir as 40 a cinco grupos substantivos: cobrança, qualidade do serviço, contratação e cancelamento, atendimento, e outros. Os quatro registros da tabela cairiam todos em "cobrança", que é o resultado correto, já que descrevem o mesmo problema.

Duas regras acompanham a decisão: o critério de agrupamento vai escrito no relatório, com a tabela que mostra qual categoria original virou qual grupo, e nenhum grupo pequeno demais é reportado isoladamente.

Uma resposta muito boa nota ainda que o relato livre é a única coisa confiável nesta base. Se a classificação do atendente não é reprodutível, o caminho mais sólido é reclassificar os 380 relatos com um critério próprio, usando a coluna de assunto apenas como ponto de partida. É trabalho, e é o que separa uma pesquisa de uma tabulação.

Questão 9

DIFÍCIL

Uma advogada procura o núcleo de pesquisa empírica do escritório com esta pergunta: "O dano moral por inscrição indevida em cadastro de inadimplentes deve ser indenizado em valor mais alto do que hoje se pratica?"

O núcleo tem à disposição uma base de 800 acórdãos de tribunais estaduais sobre esse tema, com as colunas `numero_processo`, `tribunal`, `comarca`, `orgao_julgador`, `data_julgamento`, `dias_de_inscricao_indevida`, `houve_dano_moral`, `valor_arbitrado` e `ementa`.

- a) Explique por que a pergunta, como está, não pode ser respondida com essa base.
- b) Reescreva-a como uma pergunta empírica que a base possa ajudar a responder.
- c) **Monte a tabela** que descreve a sua versão da pergunta, no mesmo formato que o Projeto 1 pede: uma linha por coluna que você vai usar, com as colunas *variável*, *tipo*, *papel* e *de onde tirar*. Inclua apenas as colunas que a sua pergunta usa, e não a base inteira.

RESPOSTA

a) A pergunta é **normativa**: ela pergunta o que *deve* ser, e a resposta depende de um critério de justiça, não de uma contagem. Nenhuma tabela informa qual valor é o devido, porque isso não é um fato do mundo que se possa medir. Um banco de dados só registra decisões que já foram tomadas; se todas elas estiverem erradas, a base vai descrever fielmente um erro. O que os dados podem informar é o que é: quanto se arbitra hoje, para quais casos, e com que variação entre órgãos julgadores.

b) Uma versão empírica possível: "Nos acórdãos sobre inscrição indevida em cadastro de inadimplentes, o valor arbitrado varia conforme o tribunal que julgou, mantido o mesmo tempo de permanência da inscrição?"

c) A tabela correspondente:

variável	tipo	papel	de onde tirar
numero_processo	identificador	identifica o caso	cabeçalho do acórdão
valor_arbitrado	numérica contínua	o que quero explicar	valor em reais na ementa
tribunal	categórica nominal	o que pode explicar	metadado do acórdão
dias_de_inscricao_indevida	numérica discreta	o que pode explicar	relato de fato na ementa
houve_dano_moral	categórica binária	define quais casos entram	dispositivo do acórdão

Três decisões que a tabela registra, e que precisam estar explícitas.

`dias_de_inscricao_indevida` entra como **explicativa a controlar**, e não como a explicativa de interesse. A pergunta é sobre o tribunal; o tempo entra porque, sem ele, uma diferença entre tribunais poderia ser apenas o reflexo de os casos de um deles serem mais graves. É a expressão “mantido o mesmo tempo de permanência” do enunciado.

`houve_dano_moral` é **filtro**, e não desfecho. Só nos acórdãos que reconhecem o dano existe valor a explicar. Quem esquecer esse filtro vai calcular médias sobre casos em que nada foi arbitrado.

`comarca`, `orgao_julgador`, `data_julgamento` e `ementa` **ficaram de fora** da tabela, e isso é uma escolha, não um esquecimento. `ementa` é a matéria-prima de onde saem duas das colunas listadas, e não uma variável. As outras três são variáveis boas que esta pergunta não usa. Uma tabela de projeto lista o que a pergunta usa; listar a base inteira é sinal de que a pergunta ainda não foi escolhida.

O que a reescrita muda. A pergunta original pedia uma decisão e a nova pede uma descrição. A descrição pode alimentar a decisão, e alimenta de forma poderosa, porque mostrar que casos equivalentes, com o mesmo tempo de inscrição indevida, recebem valores muito diferentes conforme o tribunal é um argumento forte num debate sobre isonomia e sobre o valor devido. Mas o argumento é jurídico, e os dados são a premissa, não a conclusão.

PARTE 2

Tabelas

Questão 10 ★

FÁCIL

Uma defensoria pública vai analisar 1.200 audiências de custódia realizadas no ano. A base começa assim:

id_audiencia	horas_ate_audiencia	alegou_violencia	decisao	defensor_ou_advogado
A-2025-0417	19	sim	liberdade provisória	defensor
A-2025-0418	23	não	prisão preventiva	defensor
A-2025-0419	14	não	prisão preventiva	advogado
A-2025-0420	31	sim	relaxamento	defensor

Uma base de dados está **arrumada** (o termo em inglês é *tidy*) quando cumpre três regras. Enuncie as três regras e ilustre cada uma com essa tabela, apontando o que faz o papel de linha, o que faz o papel de coluna e o que faz o papel de célula.

RESPOSTA

Regra 1: cada linha é uma unidade de observação. Aqui cada linha é uma audiência de custódia, e A-2025-0417 é uma delas. Escolher a unidade é uma decisão de pesquisa, e ela precisa ser a mesma em

todas as linhas. Não pode haver, no meio das 1.200 audiências, uma linha que seja uma pessoa presa ou um total mensal.

Regra 2: cada coluna é uma variável. `decisao` guarda uma característica, e uma só. Não existe coluna que misture a decisão com a data, nem duas colunas guardando a mesma característica em pedaços, como aconteceria se houvesse `decisao_liberdade` e `decisao_preventiva`, cada uma com sim ou não.

Regra 3: cada célula é um valor. O cruzamento de `alegou_violencia` com a audiência A-2025-0420 contém "sim", e não "sim, agressão física e ameaça". Se o tipo de violência alegada interessar à pesquisa, ele é outra coluna.

O motivo de as três regras importarem é bem prático: toda função de análise supõe que elas valem. `df["horas_ate_audiencia"].mean()` supõe que a coluna inteira mede a mesma coisa, pela regra 2, e que cada célula tem um número só, pela regra 3. Uma contagem por decisão supõe que cada audiência conta uma vez, pela regra 1. Quando uma regra é quebrada, a função continua rodando e devolve um número errado sem avisar, que é a pior forma de erro que existe.

Questão 11

MÉDIO

Um pesquisador está estudando recuperações judiciais e montou esta tabela a partir do sistema do tribunal. Cada número é a quantidade de pedidos de recuperação distribuídos naquela comarca naquele ano.

comarca	2023	2024	2025
São Paulo	48	51	43
Campinas	5	7	5
Ribeirão Preto	6	4	6

- Qual regra da tabela arrumada foi quebrada, e por quê?
- Redesenhe a tabela na forma arrumada, escrevendo as primeiras linhas.
- Cite duas contas que ficam difíceis na tabela original e fáceis na arrumada.

RESPOSTA

a) A regra 2: cada coluna deve ser uma variável. Aqui, "2023", "2024" e "2025" não são variáveis, são **valores** de uma variável que a tabela não nomeou, o ano. O nome da coluna virou dado. Há uma segunda variável escondida também sem nome, que é a quantidade de recuperações, hoje espalhada por três colunas.

b) A forma arrumada tem três colunas, uma para cada variável, e uma linha por combinação de comarca e ano:

comarca	ano	n_recuperacoes
São Paulo	2023	48
São Paulo	2024	51
São Paulo	2025	43
Campinas	2023	5
Campinas	2024	7
...	...	...

Repare que a unidade de observação também ficou explícita: cada linha é uma comarca em um ano, e não uma comarca.

c) Duas entre várias.

Filtrar por período. Na tabela original isso significa escolher colunas à mão, e o código muda toda vez que o recorte muda. Na arrumada é uma condição sobre a coluna ano, e é a mesma condição sempre.

Acrescentar 2026 quando o ano acabar. Na original isso muda a estrutura da tabela e quebra todo código escrito antes. Na arrumada é só acrescentar linhas, e nada do que já existia precisa ser tocado.

Valem também: calcular a média de recuperações por ano, que na original não é uma média de coluna porque os três anos estão em colunas diferentes; e comparar a evolução das comarcas ao longo do tempo, que na arrumada é um agrupamento por comarca.

Questão 12

MÉDIO

Um pesquisador quer saber se os bancos são condenados com mais frequência do que as companhias aéreas em ações de consumo. Ele extraiu a tabela abaixo da capa dos processos.

processo	partes	resultado
1001234-55.2024.8.26.0100	Maria Silva x Banco Alfa S/A	procedente em parte
1002345-66.2024.8.26.0100	João Souza x Cia Aérea Beta	improcedente
1003456-77.2024.8.26.0100	Ana Lima x Banco Alfa S/A; Loja Gama Ltda	procedente

- Aponte os problemas de arrumação desta tabela.
- Explique por que, do jeito que a tabela está, a pergunta do pesquisador não pode ser respondida com uma conta.
- Proponha uma estrutura de tabela que permita respondê-la.

RESPOSTA

a) Dois problemas, e o segundo é mais grave do que parece.

O primeiro é que a coluna partes guarda **duas variáveis numa célula só**, autor e réu, separadas por um "x". Isso quebra a regra 3. Enquanto estiver assim, nenhuma conta sobre o réu é possível sem antes partir o texto.

O segundo é que na terceira linha o campo do réu guarda **dois réus**, "Banco Alfa S/A" e "Loja Gama Ltda". Isso não se resolve criando uma coluna reu, porque o número de réus varia de processo para processo, e criar reu_1, reu_2 e reu_3 só empurraria o problema para a frente, além de espalhar a mesma variável por várias colunas, o que quebra a regra 2.

b) Porque a pergunta pede uma comparação entre dois grupos, banco e companhia aérea, e essa classificação não existe como coluna. Ela está dentro de um texto livre, misturada com o nome do autor. Para contar condenações por tipo de réu seria preciso, antes, ler cada célula, separar o réu do autor, decidir a que ramo de atividade cada réu pertence e resolver o caso em que há dois réus de ramos diferentes. Nada disso é uma conta: é extração, e é trabalho de pesquisa, exatamente o que o Projeto 1 exige que seja feito e documentado antes das estatísticas.

c) Depende de qual é a unidade de observação, e essa é a decisão que a questão esconde.

Se a unidade for o **processo**, a tabela precisa de uma coluna categórica tipo_de_reu com categorias exclusivas e exaustivas, definidas por um critério declarado, mais uma regra explícita para processos com vários réus. Por exemplo, classificar pelo réu principal, ou criar a categoria "mais de um ramo". A vantagem é que cada processo continua contando uma vez.

Se a unidade for o **par processo e réu**, a tabela ganha uma linha por réu, e o processo com dois réus vira duas linhas. Isso resolve a multiplicidade de forma limpa, e cobra um preço: contar linhas deixa de ser contar processos, e quem esquecer disso vai contar o processo da Ana Lima duas vezes na hora de calcular a proporção de condenações.

Uma boa resposta escolhe uma das duas e diz por quê. Para a pergunta enunciada, que é sobre réus, a segunda estrutura é mais natural.

Questão 13 ★

DIFÍCIL

Um monitor entregou esta planilha de ações de cobrança de cotas condominiais, dizendo que já está pronta para análise.

caso	comarca	valor_cobrado	pedidos	distribuicao
1	São Paulo	R\$ 5.000,00	cobrança	12/03/2024
2	Campinas	8000	cobrança e dano moral	5 de abril de 2024
3	São Paulo/SP	R\$ 12.000	dano moral	2024-04-19
4	são paulo	não consta	cobrança	22/04/2024
TOTAL		25.000		

Identifique pelo menos **quatro** problemas distintos, explique o efeito prático de cada um sobre as contas que virão depois, e diga como corrigir.

RESPOSTA

1. A linha "TOTAL" não é uma observação. Ela quebra a regra 1, porque a unidade de observação da tabela é o caso e essa linha é um resumo. O efeito é direto e silencioso: a média de `valor_cobrado` passa a incluir o total no próprio cálculo, e a contagem de casos dá 5 em vez de 4. Correção: apagar a linha. Total é resultado de análise, e resultado de análise não mora na base de dados.

2. A coluna `valor_cobrado` mistura formatos e tipos. "R\$ 5.000,00", "8000", "R\$ 12.000" e "não consta" convivem na mesma coluna, então ela é lida como texto. O efeito é que a média não roda, e, pior, se alguém "resolver" isso com uma conversão automática, o "não consta" pode virar zero sem ninguém perceber. Correção: uma coluna numérica limpa, em reais, com a célula do caso 4 **vazia**, e não zero. Se for importante registrar o motivo da ausência, isso vai numa segunda coluna, nunca misturado com o número.

3. A coluna `comarca` tem a mesma categoria escrita de três jeitos. "São Paulo", "São Paulo/SP" e "são paulo" são o mesmo lugar, mas o computador conta como três categorias diferentes. O efeito aparece em toda contagem e em todo agrupamento: a contagem reporta três comarcas com um caso cada onde existe uma comarca com três casos, e um agrupamento reparte o mesmo grupo em três pedaços pequenos demais. Correção: padronizar os rótulos, com uma lista fechada de valores permitidos.

4. A coluna `pedidos` guarda mais de um valor na mesma célula. "cobrança e dano moral" quebra a regra 3. O efeito é que não dá para contar casos com pedido de dano moral sem antes procurar o texto dentro da célula, e qualquer contagem por categoria vai criar uma categoria "cobrança e dano moral" que não é comparável às outras duas. Correção: duas colunas binárias, `pediu_cobranca` e `pediu_dano_moral`, cada uma verdadeira ou falsa. Assim o caso 2 é verdadeiro nas duas, e as contagens somam corretamente.

5. A coluna `distribuicao` está em três formatos. Dia/mês/ano, data por extenso e ano-mês-dia na mesma coluna. O efeito é que a coluna é lida como texto, ordenar por data ordena alfabeticamente, e filtrar por período não funciona. Correção: um único formato de data.

Um comentário que vale a resposta inteira: nenhum desses cinco problemas gera mensagem de erro na hora de calcular a média, com exceção do segundo. Eles geram números. É por isso que olhar a base antes de resumi-la não é formalidade.

Questão 14

DIFÍCIL

Um tribunal divulgou uma nota informando que "em 62% dos casos houve acordo na conciliação". O número saiu desta base, em que cada linha é uma **audiência**:

processo	data_audiencia	houve_acordo
1002345-66.2025	04/03/2025	False
1002891-13.2025	04/03/2025	True
1002345-66.2025	22/05/2025	False
1003120-77.2025	23/05/2025	True
1002345-66.2025	11/08/2025	True

São 1.500 audiências no total, referentes a 900 processos distintos, e o número da nota veio daqui:

```
df["houve_acordo"].mean()
```

0.62

- a) Que problema isso cria para a afirmação da nota?
- b) A base está arrumada, ou não está? Justifique.
- c) Que providência você tomaria antes de reportar a proporção, e o que precisa ser escrito no relatório de qualquer forma?

RESPOSTA

a) A palavra “casos” é ambígua, e a nota troca uma coisa pela outra. O 0,62 é a proporção de **audiências** que terminaram em acordo, porque o denominador da média são as 1.500 linhas. A nota apresenta esse número como se fosse a proporção de **processos** resolvidos por acordo, e as duas coisas são diferentes.

A amostra mostra o mecanismo com todas as letras: o processo 1002345-66 aparece três vezes, falhou duas e fechou acordo na terceira. Ele contribui com dois False e um True para a conta, quando o fato sobre ele é simplesmente que terminou em acordo.

E o viés tem direção conhecida. Um processo só é reputado quando a audiência anterior falhou, então as audiências que se repetem são justamente as dos casos mais difíceis. Contar audiências dá peso maior a esses casos, e portanto a proporção por audiência é **menor** do que a proporção por processo. A nota está subestimando o desempenho da conciliação, com uma conta que parecia inofensiva.

b) **A base está arrumada.** Esse é o ponto sutil da questão. A unidade de observação é a audiência, cada linha é uma audiência, cada coluna é uma variável e cada célula tem um valor. As três linhas do processo 1002345-66 não são duplicatas: são três audiências diferentes, em datas diferentes, e todas aconteceram. A tabela cumpre as três regras.

O problema não é de arrumação, é de **correspondência entre a unidade da tabela e a unidade da pergunta**. Uma base perfeitamente arrumada na unidade errada produz números perfeitamente calculados que respondem a outra pergunta. É por isso que “está arrumada” não é o mesmo que “está pronta”.

c) Antes de reportar, reduzir a base à unidade da pergunta: uma linha por processo, marcada como acordo se **qualquer** uma das audiências daquele processo terminou em acordo. O processo 1002345-66 passaria a contar uma vez, e como acordo. Sobre essas 900 linhas, calcular a proporção. Esse número responde à pergunta que a nota queria responder, e será maior que 62%.

Em qualquer um dos caminhos, o relatório precisa dizer **sobre o quê** a proporção foi calculada: “930 das 1.500 audiências”, ou “tantos dos 900 processos”. As duas frases são verificáveis; “62% dos casos” não é. Trocar “casos” por “audiências” ou por “processos” custa nada e é a diferença entre um número auditável e um número vago.

PARTE 3

Estatísticas

Questão 15 ★

FÁCIL

Um juizado especial cível julgou, numa mesma semana, nove ações de indenização por negativação indevida. Os valores arbitrados, já ordenados, foram:

R\$ 2.000 R\$ 3.000 R\$ 5.000 R\$ 6.000 R\$ 8.000 R\$ 10.000 R\$ 12.000
R\$ 15.000 R\$ 29.000

Calcule à mão a média, a mediana, a moda, o mínimo, o máximo e a amplitude, mostrando as contas. Em seguida, responda: a média é maior, menor ou igual à mediana, e o que isso diz sobre o formato da distribuição?

RESPOSTA

Os valores já vêm ordenados, o que é sempre o primeiro passo.

Média. A soma é $2.000 + 3.000 + 5.000 + 6.000 + 8.000 + 10.000 + 12.000 + 15.000 + 29.000 = 90.000$. Dividindo por $n = 9$: **R\$ 10.000,00.**

Mediana. Com $n = 9$, ímpar, a mediana é o valor da posição $(9 + 1)/2 = 5$ na lista ordenada, que é **R\$ 8.000,00**. Quatro valores ficam abaixo e quatro acima.

Moda. Não há. Os nove valores são todos distintos, então nenhum se repete. Isso é o normal em variável numérica contínua, e é a razão de a moda ser pouco útil aqui: ela serve principalmente para variável categórica.

Mínimo: R\$ 2.000,00. **Máximo:** R\$ 29.000,00.

Amplitude: $29.000 - 2.000 = 27.000$, ou **R\$ 27.000,00.**

Média contra mediana. A média (R\$ 10.000,00) é **maior** que a mediana (R\$ 8.000,00). Isso indica uma distribuição **assimétrica à direita**: a maior parte dos casos se concentra em valores baixos, e uns poucos valores altos, aqui o R\$ 29.000,00, puxam a média para cima. A mediana não se move por causa deles, porque ela só olha a posição do valor do meio, e não o tamanho dos valores das pontas.

Esse formato é a regra, e não a exceção, em valores de indenização. Numa base real de 460 acórdãos de dano moral do TJSP, a mesma comparação dá média de R\$ 7.935,26 contra mediana de R\$ 5.000,00, com o mesmo diagnóstico.

Questão 16 ★

FÁCIL

Uma defensoria pública quer dimensionar a carga de trabalho da instrução criminal e contou quantas testemunhas foram ouvidas em cinco processos, na ordem em que eles foram encerrados:

4 9 2 6 4

Calcule à mão a média, a variância e o desvio padrão, mostrando a tabela de desvios. Depois, escreva uma frase que interprete o desvio padrão obtido, em linguagem de relatório.

Use o denominador $n - 1$ na variância, que é a convenção do pandas e a que vale na disciplina inteira.

RESPOSTA

Média. $(4 + 9 + 2 + 6 + 4)/5 = 25/5 = 5$ testemunhas.

Tabela de desvios. Para cada valor, a distância até a média, e o quadrado dessa distância:

valor	desvio (valor - 5)	desvio ao quadrado
4	-1	1
9	+4	16
2	-3	9
6	+1	1
4	-1	1
soma	0	28

Repare que a soma dos desvios dá exatamente zero, e isso não é coincidência: é sempre assim, por definição de média. É justamente por isso que os desvios precisam ser elevados ao quadrado antes de somados, porque senão não sobraria nada para medir.

Variância. A soma dos quadrados dividida por $n - 1$: $28 / (5 - 1) = 28 / 4 = 7$ testemunhas ao quadrado.

Desvio padrão. $\sqrt{7} \approx 2,65$ testemunhas.

Interpretação em linguagem de relatório. "Foram ouvidas em média 5 testemunhas por processo, com desvio padrão de 2,6 testemunhas, o que indica variação considerável entre os casos: a distância típica entre um processo e a média é de cerca de duas testemunhas e meia, num conjunto em que a média é 5."

O que faz a frase ser boa: ela dá a média e a dispersão juntas, e traduz o desvio padrão como distância típica até a média, em vez de apenas repetir o número. Reportar a média sozinha esconderia que os processos vão de 2 a 9 testemunhas, e é essa variação que decide quantos defensores são necessários.

Questão 17 ★

MÉDIO

Uma corregedoria acompanha o tempo que os processos levam até a sentença e separou nove processos encerrados numa vara. Os tempos, em dias, já ordenados:

210 280 340 390 450 520 610 740 1.180

Calcule à mão o primeiro quartil, o terceiro quartil e o intervalo interquartil, mostrando como você localizou cada posição. Depois, escreva o que o intervalo interquartil obtido significa em português, sem usar a palavra "quartil".

Localize os quartis como o pandas faz: na lista ordenada, contando as posições a partir de zero, a posição do quartil é $p \times (n - 1)$, com p igual a 0,25 para o primeiro e 0,75 para o terceiro; se a posição cair entre dois valores, interpole proporcionalmente entre eles.

RESPOSTA

A lista ordenada tem $n = 9$ valores. Contando as posições a partir de zero, elas vão de 0 a 8.

Primeiro quartil. A posição é $0,25 \times (9 - 1) = 0,25 \times 8 = 2$. É um número inteiro, então não há interpolação: o primeiro quartil é o valor da posição 2, ou seja, o terceiro da lista, que é **340 dias**.

Mediana, que é o segundo quartil. A posição é $0,5 \times 8 = 4$, o quinto valor da lista, que é **450 dias**.

Terceiro quartil. A posição é $0,75 \times 8 = 6$, o sétimo valor da lista, que é **610 dias**.

Intervalo interquartil. $610 - 340 = 270$ dias.

Em português, sem a palavra quartil. Se a gente descartar o quarto de processos mais rápidos e o quarto de processos mais lentos, a metade do meio leva de 340 a 610 dias até a sentença, uma faixa de 270 dias de largura. Ou seja: metade dos processos está contida numa janela de menos de nove meses, e a outra metade se espalha pelas duas pontas, de 210 dias no caso mais rápido a 1.180 dias no mais lento.

Duas observações que valem registrar. A primeira é que, num relatório de corregedoria, essa é uma informação melhor do que a média. Dizer que o tempo mediano é de 450 dias e que a metade central vai de 340 a 610 descreve a realidade da vara; a média, de 524 dias, está inflada pelo processo de 1.180 dias e não corresponde à experiência típica de quem espera.

A segunda é técnica. Este conjunto foi construído para que as posições caíssem em números inteiros. Se ele tivesse oito valores, a posição do primeiro quartil seria $0,25 \times 7 = 1,75$, que cai entre a segunda e a terceira posição, e aí seria preciso interpolar: pegar o valor da posição 1 e somar 75% da distância até o valor da posição 2. É exatamente isso que o pandas faz quando se escreve `df["dias"].quantile(0.25)`, e é a razão de ele às vezes devolver um quartil que não é nenhum dos valores observados.

Questão 18

MÉDIO

Voltando às nove indenizações por negativação indevida da Questão 15:

R\$ 2.000 R\$ 3.000 R\$ 5.000 R\$ 6.000 R\$ 8.000 R\$ 10.000 R\$ 12.000
R\$ 15.000 R\$ 29.000

Nesse conjunto, a média é de R\$ 10.000,00, a mediana é de R\$ 8.000,00, o desvio padrão é de R\$ 8.276,47 e o intervalo interquartil é de R\$ 7.000,00.

Ao conferir os autos, descobriu-se que a sentença de R\$ 29.000,00 foi lançada na base por engano: ela é de outra vara. Retire esse valor, ficando com oito. Para sua conferência, os valores recalculados são: média de R\$ 7.625,00, mediana de R\$ 7.000,00, desvio padrão de R\$ 4.501,98 e intervalo interquartil de R\$ 6.000,00.

Monte uma tabela com o antes, o depois e a variação percentual de cada medida. Depois responda: quais medidas são mais sensíveis a um único caso extremo, e o que essa constatação implica na escolha do que reportar num parecer?

RESPOSTA

medida	com os 9 valores	sem o R\$ 29.000	variação
média	R\$ 10.000,00	R\$ 7.625,00	-23,8%
mediana	R\$ 8.000,00	R\$ 7.000,00	-12,5%
desvio padrão	R\$ 8.276,47	R\$ 4.501,98	-45,6%
intervalo interquartil	R\$ 7.000,00	R\$ 6.000,00	-14,3%

Quem é mais sensível. O desvio padrão, disparado: um único caso entre nove respondia por quase metade da dispersão medida. Depois vem a média, que caiu quase um quarto. A mediana e o intervalo interquartil se moveram pouco, e o que mexeu neles não foi o tamanho do valor retirado, e sim o fato de a lista ter encolhido de nove para oito elementos, o que desloca as posições.

A razão. Média e desvio padrão usam o **tamanho** de cada valor: o R\$ 29.000,00 entra na soma inteiro, e no desvio padrão entra elevado ao quadrado, o que amplifica ainda mais o caso extremo. Mediana e intervalo interquartil usam só a **posição** dos valores na fila ordenada. Trocar o R\$ 29.000,00 por R\$ 290.000,00 não mexeria um centavo na mediana, e mudaria a média para R\$ 39.000,00.

Implicação para o parecer. Em valores de indenização, que quase sempre têm cauda longa à direita, reportar apenas a média é enganoso, porque ela é puxada por um punhado de casos atípicos e sugere um patamar que a maioria dos casos não alcança. A prática defensável é reportar **mediana acompanhada do intervalo interquartil**, que descrevem o caso típico e a faixa em que a metade central está, e mencionar a média e o máximo separadamente, para não esconder que existem casos muito altos.

O que não é defensável é escolher a medida depois de ver qual delas favorece a tese do cliente. A medida se escolhe pelo formato da distribuição e pela pergunta, e a escolha vai declarada no texto.

Um último ponto, sobre o enunciado. Aqui o valor foi retirado porque estava errado, e esse é o único motivo legítimo para retirar um caso: erro de coleta, comprovado. Retirar um valor apenas por ser alto é fraudar o resultado, e a diferença entre as duas coisas é justamente a justificativa escrita.

Questão 19 ★

MÉDIO

Um CEJUSC registrou o resultado das dez audiências de conciliação de uma manhã, na ordem em que aconteceram:

não sim não não sim não sim não não não

- Calcule a proporção de audiências com acordo, apresentando a razão entre as duas quantidades.
- Reescreva a mesma coluna trocando "sim" por 1 e "não" por 0, e calcule a média dessa nova coluna.
- Explique por que os dois números coincidem, e diga por que isso não vale para uma variável categórica com três categorias.

RESPOSTA

a) São 3 "sim" em 10 audiências. A proporção é $3/10 = 0,30$, ou **30%**. Apresentar a razão, e não só o percentual, importa: "3 em 10" deixa claro que o denominador é pequeno, e "30%" sozinho sugere uma precisão que dez casos não sustentam.

b) A coluna vira 0,1,0,0,1,0,1,0,0,0. A média é $(0 + 1 + 0 + 0 + 1 + 0 + 1 + 0 + 0 + 0)/10 = 3/10 = 0,30$.

c) Os números coincidem porque, numa coluna de zeros e uns, **somar é contar os uns**. A soma dá exatamente o número de casos "sim", e dividir pelo total é justamente a definição de proporção. Então, para variável binária, média e proporção são literalmente a mesma conta, e não duas contas que por acaso dão igual. É por isso que `df["houve_acordo"].mean()` devolve a proporção de acordos, e por isso a mesma expressão funciona dentro de um agrupamento por conciliador ou por assunto.

Isso não se estende a uma categórica com três categorias porque não existe codificação numérica neutra. Se alguém rotular "acordo total" como 1, "acordo parcial" como 2 e "sem acordo" como 3, a média dessa coluna dará algo como 1,8, um número que não corresponde a resultado nenhum e que muda se a ordem dos rótulos mudar. Com três categorias não há uma proporção, há três, uma para cada categoria, e a ferramenta certa é a tabela de frequências, não a média.

O caso binário é especial exatamente porque, com duas categorias, saber a proporção de uma delas já determina a outra.

Questão 20

FÁCIL

O mesmo tribunal da Questão 14 guarda `houve_acordo` como coluna lógica, com verdadeiro em 612 das 1.500 audiências:

processo	data_audiencia	houve_acordo
1002345-66.2025	04/03/2025	False
1002891-13.2025	04/03/2025	True
1002345-66.2025	22/05/2025	False
...	...	...

Um analista roda:

```
df["houve_acordo"].mean()
```

- Que número essa linha devolve? Apresente a conta, e explique por que uma coluna de verdadeiro e falso aceita uma média.
- Escreva, em uma frase de relatório, o que esse número significa.

c) A linha `df["houve_acordo"].sum()` devolve o quê, e para que serve?

RESPOSTA

a) Devolve $612/1.500 = 0,408$.

A média funciona porque, numa coluna lógica, o pandas trata `True` como 1 e `False` como 0. Somar passa a ser contar os verdadeiros, e dividir pelo total de linhas é exatamente a definição de proporção, que é o que a Questão 19 mostrou à mão. Não é um truque do pandas: é a propriedade da variável binária, e é a razão de a proporção ser a medida de posição desse tipo de variável.

b) "Em 40,8% das 1.500 audiências de conciliação realizadas houve acordo."

Duas exigências dessa frase: converter o 0,408 para percentual, porque proporção em relatório se lê em percentual, e dizer o denominador, que aqui são as 1.500 audiências. E note que a frase diz "audiências", e não "casos": pela Questão 14, essas duas palavras não são intercambiáveis nesta base.

c) Devolve **612**, a contagem de audiências com acordo. Serve para reportar o valor absoluto ao lado da proporção, que é a prática correta: "612 das 1.500 audiências, ou 40,8%". A proporção sozinha esconde o tamanho da amostra, e 40,8% de 1.500 é uma afirmação muito mais forte do que 40,8% de 12.

Questão 21

MÉDIO

Uma base de 3.000 recursos julgados por um tribunal tem a coluna `recurso_provido` preenchida com os textos "sim" e "não", e não com valores lógicos. Um estagiário executa a mesma linha da questão anterior:

```
df["recurso_provido"].mean()
```

```
TypeError: Could not convert string 'simnãoãosimnão...' to numeric
```

- a) Explique o erro, e diga por que ele é uma boa notícia.
- b) Descreva, em português, duas formas diferentes de chegar à proporção de recursos providos com a coluna nesse formato, e diga qual você prefere e por quê.
- c) Um colega sugere trocar "sim" por 1, "não" por 0 e as células vazias por 0,5, para "não perder informação". Avalie a sugestão.

RESPOSTA

a) A coluna é de texto, e não existe soma de "sim" com "não". A mensagem mostra o que o pandas tentou fazer: concatenou os textos, como faria com qualquer soma de strings, e depois não conseguiu transformar o resultado em número.

É uma boa notícia porque o computador se recusou a fazer uma conta que não faz sentido, e avisou. O caso perigoso é o contrário: quando a conta sem sentido roda, devolve um número plausível e ninguém é avisado. A Questão 3 é um exemplo disso, com a média de um identificador.

b) Duas formas, descritas antes de virarem código.

Comparar cada célula com "sim" e tirar a média do resultado. A comparação produz uma coluna lógica de verdadeiro e falso, e a média de uma coluna lógica, pela Questão 20, é a proporção. No pandas:

```
(df["recurso_provido"] == "sim").mean()
```

Contar quantas vezes cada categoria aparece e dividir pelo total. O resultado é uma linha para "sim" e outra para "não", cada uma com a sua fração. No pandas:

```
df["recurso_provido"].value_counts(normalize=True)
```

Preferência. A segunda, como primeiro passo, e por um motivo de conferência: ela mostra **todas** as categorias que existem na coluna. Se alguém tiver digitado "Sim" com maiúscula, ou "s", ou "parcialmente provido", isso aparece na tabela, enquanto a primeira forma jogaria tudo isso silenciosamente no grupo dos "não" e devolveria uma proporção baixa demais. Em 3.000 linhas digitadas por várias pessoas, a chance de existir uma variação de grafia é alta. Depois de conferir que só existem "sim" e "não", a primeira forma é mais direta para o número final.

c) A sugestão é ruim, e por três motivos.

Inventa um dado que não existe. Meio provimento não é um resultado do julgamento: ou o recurso foi provido, ou não foi, ou não se sabe. Atribuir 0,5 é afirmar que o caso está metade de cada lado, o que é falso em qualquer leitura. E note que provimento parcial, se existir na base, é uma **terceira categoria** de verdade, que merece um rótulo próprio, e não um número no meio do caminho.

Contamina todas as contas seguintes sem avisar. A média da coluna deixa de ser a proporção de provimentos e passa a ser uma mistura sem nome, que muda conforme o número de faltantes. Nada no resultado indica que isso aconteceu.

Resolve um problema que não é problema. "Não perder informação" é um objetivo bom, e o jeito de alcançá-lo é o oposto do proposto: manter o faltante como faltante, que é a informação verdadeira de que não se sabe, e reportar quantos são. Assim as contas se fazem sobre os casos conhecidos, e o leitor sabe de quantos casos se está falando.

A regra da disciplina vale aqui inteira: em branco quando a informação não está no documento, "não se aplica" quando a pergunta não se coloca naquele caso, e nunca um número inventado.

Questão 22

DIFÍCIL

No conjunto das nove indenizações da Questão 15, a variância vale 68.500.000 e o desvio padrão vale R\$ 8.276,47, em torno de uma média de R\$ 10.000,00.

- a) Qual é a unidade de medida da variância nesse caso? Escreva-a por extenso.
- b) Explique por que a variância existe, se o desvio padrão é mais fácil de interpretar.
- c) Um relatório afirma: "a variância das indenizações é de R\$ 68.500.000,00, o que mostra dispersão altíssima". Corrija a frase.

RESPOSTA

a) Reais ao quadrado. A variância é construída a partir dos desvios elevados ao quadrado, e elevar reais ao quadrado produz reais ao quadrado, que é uma unidade sem qualquer significado no mundo. Ninguém paga, arbitra ou recebe reais ao quadrado. Por isso o número 68.500.000 não é comparável ao valor de nenhuma indenização, e a impressão de "número enorme" que ele passa é um artefato da unidade, não da dispersão dos dados.

b) A variância existe porque é ela que tem as propriedades matemáticas úteis. A soma dos desvios simples é sempre zero, então é preciso eliminar o sinal antes de somar, e o quadrado é a forma de fazer isso que a matemática sabe manipular: a variância de uma soma de variáveis independentes é a soma das variâncias, e é sobre a variância que se constroem quase todos os métodos que vocês verão depois, de intervalos de confiança a regressão. O desvio padrão é a raiz quadrada da variância, feita justamente para trazer o resultado de volta à unidade original e permitir a leitura em reais. Em resumo: a variância é a medida que a matemática usa, e o desvio padrão é a medida que o leitor lê.

c) A frase tem um erro de unidade e uma conclusão sem base. Uma versão correta:

"As indenizações têm desvio padrão de R\$ 8.276,47 em torno de uma média de R\$ 10.000,00, ou seja, a distância típica entre um caso e a média é de cerca de oito mil reais, quase o tamanho da própria média. A dispersão é alta."

Repare no que a correção faz. Ela troca a variância pelo desvio padrão, tira o símbolo de real de um número que não está em reais, e, sobretudo, só chama a dispersão de alta **depois** de compará-la com a média. Um desvio padrão de oito mil reais seria altíssimo num conjunto de média mil reais e modesto num conjunto de média um milhão. Dispersão alta ou baixa é sempre em relação a alguma coisa.

Questão 23

DIFÍCIL

Os números desta questão são reais. Numa base de 460 acórdãos de dano moral do TJSP, 303 têm valor de indenização extraído da ementa. O resumo dessa coluna é este:

```
df["valor_indenizacao"].describe()
```

count	303.000000
mean	7935.255182
std	8388.184932
min	40.250000
25%	5000.000000
50%	5000.000000
75%	10000.000000
max	90000.000000

Olhando a coluna de perto: 99 acórdãos arbitram exatamente R\$ 5.000,00, 56 arbitram menos que isso, e 155 arbitram esse valor ou menos. A moda também é R\$ 5.000,00.

- As linhas 25% e 50% mostram o mesmo número. Como três medidas diferentes podem coincidir? Mostre, com os números acima, por que isso acontece.
- Colher mais acórdãos resolveria a coincidência? Justifique.
- O que você escreveria no relatório para que o leitor não ache que houve erro de conta?

RESPOSTA

a) Porque um número enorme de acórdãos arbitra **exatamente** R\$ 5.000,00: são 99 dos 303, quase um terço da amostra. Quando um único valor concentra uma fatia grande dos casos, ele ocupa uma faixa larga da fila ordenada.

Os números fecham a conta. Abaixo de R\$ 5.000,00 estão 56 acórdãos, ou 18,5% do total; em R\$ 5.000,00 ou abaixo estão 155, ou 51,2%. O corte do primeiro quartil está em 25% e o corte da mediana está em 50%, e os dois caem dentro do intervalo que vai de 18,5% a 51,2%. Ou seja: os dois cortes acontecem dentro do mesmo bloco de casos iguais, e por isso as linhas 25% e 50% mostram o mesmo valor. A moda é R\$ 5.000,00 pelo motivo mais direto de todos, que é ser o valor mais repetido.

O que isso revela é uma **ancoragem em números redondos**. Juízes não arbitram R\$ 4.873,00: arbitram cinco mil, dez mil, vinte mil. A distribuição não é uma nuvem contínua, é um conjunto de degraus altos em valores redondos. Isso é um achado sobre a prática do tribunal, e não um defeito da base. O 75% de R\$ 10.000,00 exatos e o max de R\$ 90.000,00 exatos contam a mesma história.

b) Não. Essa é a parte importante. A coincidência não vem de a amostra ser pequena, vem de a distribuição ter um degrau nesse ponto. Colher mil ou dez mil acórdãos do mesmo tribunal reproduziria o mesmo padrão de ancoragem, e o bloco de casos iguais a R\$ 5.000,00 continuaria atravessando os dois cortes. É um fato estrutural sobre como se arbitra dano moral, e mais dados o confirmam em vez de dissolvê-lo.

O que mudaria a coincidência seria mudar o recorte, e não o tamanho: separar por assunto, ou por faixa de gravidade, ou olhar outro tribunal, porque aí os degraus estariam em lugares diferentes em cada grupo.

c) Escreveria a explicação junto do número, mais ou menos assim:

"O primeiro quartil, a mediana e a moda coincidem em R\$ 5.000,00. A coincidência não é erro de cálculo: 99 dos 303 acórdãos com valor arbitram exatamente essa quantia, o que reflete a forte ancoragem dos arbitramentos em números redondos. Como consequência, o primeiro quartil não é informativo neste caso, e a descrição da metade inferior da distribuição fica melhor servida pela proporção de acórdãos abaixo de R\$ 5.000,00, que é de 18,5%."

O princípio geral é que um resultado que parece estranho deve vir com a explicação anexa. Quem não explica deixa o leitor concluir que houve erro, e depois de essa desconfiança se instalar ela contamina o relatório inteiro.

Uma observação final sobre o min de R\$ 40,25, que a saída também mostra: esse valor é implausível como indenização por dano moral, e quase certamente é erro de extração, com a regra tendo capturado o primeiro valor em reais da ementa, que era outra coisa. Olhar o mínimo e o máximo antes de qualquer outra conta é o jeito mais barato de descobrir que a coluna mediu outra coisa.

PARTE 4

Interpretação

Questão 24 ★

FÁCIL

Os números desta questão são reais. Numa base de 460 acórdãos de dano moral do TJSP, foi possível extrair o valor arbitrado em 303 deles. Nesses 303, a média é de R\$ 7.935,26 e a mediana é de R\$ 5.000,00.

Escreva um parágrafo de relatório interpretando as duas medidas em conjunto. O parágrafo precisa dizer o que cada número significa, o que a diferença entre eles indica, e sobre quantos casos as contas foram feitas.

RESPOSTA

Um parágrafo aceitável, com os elementos exigidos:

"Entre os 303 acórdãos em que foi possível extrair o valor arbitrado, a indenização mediana é de R\$ 5.000,00, ou seja, metade dos acórdãos arbitrou até esse valor e metade arbitrou a partir dele. A média é de R\$ 7.935,26, consideravelmente mais alta, o que indica distribuição assimétrica à direita: existem poucos acórdãos com valores muito superiores ao restante, e eles puxam a média para cima sem deslocar a mediana. Para descrever o valor típico de uma condenação por dano moral neste conjunto, a mediana é a medida mais adequada; a média é útil para dimensionar o montante total envolvido, e não o caso comum."

Os quatro elementos que a correção procura: a interpretação correta da mediana como corte de 50%, a leitura da diferença entre média e mediana como assimetria à direita, a explicitação de que a conta foi feita sobre 303 acórdãos e não sobre os 460, e uma recomendação de qual medida usar, com o motivo.

Um erro comum a evitar é escrever que "a média é R\$ 7.935,26, ou seja, o valor médio pago". Não existe "o valor pago": existem 303 valores, e a média é um resumo deles.

Questão 25

MÉDIO

Sobre a mesma base real de 460 acórdãos do TJSP, em que 303 têm valor extraído, com média de R\$ 7.935,26, mediana de R\$ 5.000,00, moda de R\$ 5.000,00 e máximo de R\$ 90.000,00, um parecer afirma o seguinte:

"A indenização média por dano moral no TJSP é de R\$ 7.935,26. Portanto, metade dos casos recebe mais do que isso, e nosso cliente, que recebeu R\$ 5.000,00, foi tratado abaixo da média do tribunal."

Identifique **três** problemas distintos nessa passagem e reescreva-a de forma defensável.

RESPOSTA

Problema 1: confunde média com mediana. "Metade dos casos recebe mais do que isso" é a definição de mediana, não de média. Nesta base elas são bem diferentes, R\$ 5.000,00 contra R\$ 7.935,26, e a proporção de acórdãos acima da média é bem menor que a metade, justamente porque a distribuição é assimétrica. A frase transfere para a média uma propriedade que só a mediana tem.

Problema 2: "abaixo da média" sugere um tratamento anômalo que não houve. Receber R\$ 5.000,00 é receber exatamente a mediana e exatamente a moda do tribunal, ou seja, o valor mais comum e o valor central. Chamar o caso mais típico de todos de "abaixo da média" é verdadeiro no sentido literal e enganoso no sentido que a frase quer produzir. O leitor entende "tratado pior do que os outros", e o dado diz o oposto, que é "tratado como a maioria".

Problema 3: a média foi calculada sobre uma base que a frase não descreve. Os R\$ 7.935,26 saem de 303 acórdãos, e não dos 460 da amostra, porque em 157 não foi possível extrair valor. E a amostra é de acórdãos de segundo grau colhidos por um recorte de busca específico, e não do TJSP inteiro. Dizer "a indenização média por dano moral no TJSP" atribui ao tribunal como um todo um número que descreve uma amostra particular.

Versão defensável:

"Na amostra de 460 acórdãos de dano moral do TJSP examinada, foi possível extrair o valor arbitrado em 303 deles. Nesse conjunto, a indenização mediana é de R\$ 5.000,00, valor que também é o mais frequente. A média, de R\$ 7.935,26, é mais alta que a mediana porque um pequeno número de acórdãos arbitra valores muito superiores, chegando a R\$ 90.000,00. O valor de R\$ 5.000,00 recebido pelo cliente corresponde, portanto, ao patamar típico praticado nesta amostra, e não a um tratamento desfavorável."

Repare que a versão defensável é mais longa, e não tem como não ser: ela declara o universo, distingue média de mediana, e substitui uma insinuação por uma comparação verificável. Se a tese do cliente for que ele merecia mais, ela terá de ser sustentada por argumento jurídico sobre a gravidade do caso, e não por uma leitura torta da média.

Questão 26 ★

MÉDIO

Os números desta questão são reais. Na base de 460 acórdãos de dano moral do TJSP, em 157 não foi possível extrair o valor da indenização. Em 192 dos 460 o acórdão não reconheceu dano moral algum.

- Liste pelo menos **três** razões substantivas diferentes pelas quais uma célula da coluna de valor pode estar vazia.
- Por que tratar todas essas ausências da mesma forma é um problema?
- Que informação sobre os faltantes precisa constar do relatório, mesmo que a análise apenas os ignore?

RESPOSTA

a) Três razões substantivas, com naturezas bem diferentes:

A pergunta não se coloca naquele caso. O acórdão negou o dano moral, então não há valor a arbitrar. A ausência aqui é uma informação verdadeira sobre o caso, e não uma falha. Os 192 acórdãos sem reconhecimento de dano moral explicam boa parte dos 157 vazios.

A informação existe mas não está na ementa. O acórdão manteve a condenação de primeiro grau sem repetir o valor, ou remeteu a quantificação para a liquidação. O valor existe no processo e não no documento que foi lido. A ausência é uma limitação da fonte.

A extração falhou. A ementa traz o valor, mas em formato que a regra de extração não reconheceu, por exemplo por extenso, ou em salários mínimos, ou misturado com outros valores como custas e honorários. A ausência é um defeito do método.

b) Porque as três significam coisas diferentes e pedem tratamentos diferentes. As do primeiro tipo não deveriam nem entrar no universo de análise, já que a pergunta é sobre quanto se arbitra quando se arbitra. As do segundo tipo são uma limitação a declarar, e, se forem muitas, uma ameaça à validade das conclusões, porque nada garante que os acórdãos que omitem o valor sejam parecidos com os que informam. As do terceiro tipo são um problema a corrigir, refinando a extração.

Se todas forem jogadas no mesmo balaio, um defeito corrigível fica indistinguível de um fato sobre os casos, e o pesquisador perde a chance de melhorar a base e de avaliar o próprio viés.

c) No mínimo, quatro coisas. **Quantos são**, em número absoluto e em proporção, ou seja, 157 de 460, que são 34% da amostra. **Por que faltam**, ao menos na medida em que se conseguiu apurar, separando quem não teve dano moral reconhecido dos demais. **O que a análise fez com eles**, que aqui é excluí-los, deixando explícito que as estatísticas de valor se referem a 303 acórdãos. E **se há motivo para suspeitar de viés**, ou seja, se os acórdãos sem valor extraído parecem sistematicamente diferentes dos outros em assunto, comarca ou resultado.

A regra prática que resume tudo isso: faltante é deixado **em branco**, e nunca zero. Zero é um valor, e afirma que o juiz arbitrou nada. Em branco é a ausência de valor, e é o único registro honesto de que não se sabe.

Questão 27

MÉDIO

Continuando na base real de 460 acórdãos do TJSP: um colega, incomodado com as 157 células vazias da coluna de valor, resolveu preenchê-las com zero.

```
df["valor_indenizacao"].mean()          # sobre os 303 com valor
df["valor_indenizacao"].fillna(0).mean() # sobre as 460 linhas
```

```
7935.255182
5226.917935
```

A mediana, nas duas contas, continuou em R\$ 5.000,00.

- a) Explique por que a média caiu tanto e a mediana não se moveu.
- b) Existe alguma pergunta de pesquisa para a qual preencher com zero seria **correto**? Se sim, qual, e o que mudaria no enunciado da pergunta.
- c) Qual é o problema de fazer isso sem declarar?

RESPOSTA

a) A média caiu porque ela usa o tamanho de todos os valores. O `fillna(0)` acrescentou 157 zeros à soma: o total não mudou, e o denominador saltou de 303 para 460. O resultado é uma diluição mecânica, que não corresponde a nenhum juiz ter arbitrado menos. Confere na conta: 7.935,26 vezes 303, dividido por 460, dá exatamente 5.226,92.

A mediana não se moveu porque ela usa apenas a posição do valor central. Os 157 zeros entraram todos no começo da fila ordenada, o que empurrou a posição do meio para a esquerda, mas o bloco de casos iguais a R\$ 5.000,00 é tão grande que a nova posição central continuou caindo dentro dele. Essa é a robustez da mediana em ação, e vale notar que ela não é mágica: se os faltantes fossem 400 em vez de 157, a mediana iria para zero.

b) Sim, existe, e a mudança de pergunta é justamente o ponto. A média sobre as 460 linhas com zeros responde a: **"quanto o TJSP arbitra em média por acórdão de dano moral julgado, contando os**

acórdãos em que nada foi arbitrado?" É uma pergunta legítima, e até útil para dimensionar exposição financeira de uma carteira de processos, porque quem estima passivo precisa contar os casos em que não se paga nada.

Mas essa pergunta só é bem respondida assim se **todos** os faltantes forem realmente casos de arbitramento zero. E não são: parte dos 157 são acórdãos em que houve dano moral reconhecido e o valor não pôde ser extraído. Para esses, o zero é falso. Ou seja, mesmo para essa pergunta, o preenchimento correto exigiria primeiro separar as três razões da Questão 26, preencher com zero apenas as ausências do primeiro tipo, e continuar tratando as demais como desconhecidas.

c) O problema é que o número muda em quase R\$ 2.700 e nada no relatório avisa. O `fillna(0)` some no meio do código; o que chega ao leitor é só a média. Quem comparar esse parecer com outro, feito sobre a mesma base sem o preenchimento, encontra duas médias diferentes e não tem como saber por quê. Toda decisão de tratamento de faltante é uma decisão de pesquisa: ela muda o resultado, e por isso vai escrita, com a justificativa e com o número que se obteria sem ela.

Questão 28

DIFÍCIL

Um escritório quer descobrir quanto costuma receber de honorários de sucumbência nas **causas de consumo** que patrocina, para calibrar propostas a clientes novos. O setor financeiro mandou o resumo abaixo, calculado sobre **todos** os processos encerrados nos últimos três anos, de qualquer matéria.

medida	valor	medida	valor
processos encerrados	240	mínimo	R\$ 180,00
com honorários fixados	180	primeiro quartil	R\$ 3.500,00
média	R\$ 12.400,00	terceiro quartil	R\$ 14.000,00
mediana	R\$ 6.000,00	máximo	R\$ 210.000,00
moda	R\$ 5.000,00	desvio padrão	R\$ 21.800,00

- Escolha quais medidas reportar e justifique cada escolha e cada omissão.
- O mínimo de R\$ 180,00 chama atenção. O que você faria antes de reportá-lo?
- Há um problema conceitual em usar esses números para responder à pergunta como ela foi feita. Qual é?

RESPOSTA

a) Uma escolha defensável reporta quatro coisas.

A mediana, R\$ 6.000,00, como valor típico, porque a distribuição é fortemente assimétrica, o que se vê na distância entre a média e a mediana, e a mediana é o que descreve o caso comum.

O intervalo entre o primeiro e o terceiro quartil, de R\$ 3.500,00 a R\$ 14.000,00, porque descrever o típico sem descrever a variação é meio relatório. Essa faixa contém a metade central dos casos, e é justamente ela que serve para calibrar uma proposta.

O máximo, R\$ 210.000,00, mencionado como extremo e identificado como tal, porque omitir a existência de honorários altos seria esconder informação relevante para quem decide se aceita a causa.

O número de casos, 180 de 240, porque toda estatística precisa dizer sobre quantos casos foi calculada. Vale investigar o que são os 60 sem honorários fixados: provavelmente acordos, desistências e improcedências, e cada um desses grupos significa uma coisa diferente para a decisão do escritório.

E as omissões, que também precisam de motivo. A **média** pode ser mencionada, mas nunca sozinha e nunca como "o que o escritório recebe": em R\$ 12.400,00 ela é o dobro da mediana, puxada por um punhado de causas grandes, e usá-la para calibrar proposta levaria o escritório a prometer o que não costuma acontecer. O **desvio padrão** de R\$ 21.800,00 é dispensável aqui: num conjunto assimétrico ele descreve mal a dispersão, chega a ser quase o dobro da média, e o intervalo interquartil faz o mesmo

trabalho de forma mais legível. A **moda** de R\$ 5.000,00 acrescenta pouco além do que a mediana já disse, salvo se o objetivo for justamente destacar que existe um valor padrão sendo repetido.

b) Abriria o processo e olharia a sentença. R\$ 180,00 é implausível como honorário de sucumbência de uma causa que o escritório levou até o fim, e a explicação mais provável é erro de registro: pode ser uma parcela de um valor maior, uma custa lançada no campo errado, ou honorários fixados por equidade num processo de valor mínimo. Antes de reportar o mínimo, é preciso saber se ele mede o que a coluna diz medir.

Essa é, aliás, a utilidade principal do mínimo e do máximo numa análise: eles são o jeito mais barato de descobrir que a coluna mediu outra coisa. Olhar os extremos antes de qualquer outra conta é rotina de conferência, não curiosidade.

c) A pergunta é sobre **causas de consumo**, e todos os números apresentados são de todos os processos encerrados, de qualquer matéria. Uma causa previdenciária, uma trabalhista e uma societária têm patamares de honorários completamente diferentes, e a mistura das três não descreve nenhuma delas. Responder a uma pergunta sobre um subgrupo com a estatística do conjunto todo é errado, e o erro é do tipo que não aparece: os números estão corretos, só não são os números pedidos.

O que a pergunta exige é filtrar os processos de consumo e recalculá-los tudo sobre eles, reportando quantos são. Se, depois de filtrado, o grupo tiver poucos casos com honorário fixado, isso também precisa ser dito, porque uma mediana calculada sobre uma dúzia de processos não sustenta uma política de precificação.

COMO ESTA LISTA FOI ELABORADA

Parte das questões desta lista foi redigida com apoio do modelo de linguagem Claude Opus 5. Todas passaram por revisão do professor, enunciado por enunciado: o caso, os números, o gabarito e o recorte de conteúdo são de responsabilidade dele, e as questões que não sobreviveram à revisão ficaram de fora.