

Lista 1

Variáveis, tabelas e estatísticas descritivas

Conteúdo Aulas 1 a 3
Turma 4A · 2026/2
Professor Julio Trecenti
Versão Sem respostas.

POR ONDE COMEÇAR

As questões marcadas com uma estrela vermelha são o caminho mínimo: são onze de vinte e oito, e juntas cobrem uma vez cada conceito das aulas 1 a 3. Se o tempo for curto, faça essas e volte às outras quando puder. As demais repetem os mesmos conceitos em outros contextos, e é a repetição em contextos diferentes que faz o conceito grudar.

PARTE 1

Variáveis e papéis

Questão 1 ★

Um escritório trabalhista quer saber quanto costuma receber nos acordos que fecha. Uma estagiária montou a planilha abaixo com os seis acordos homologados no mês passado.

processo	valor_acordo	n_audiencias
0001234-12.2024.5.02.0001	R\$ 18.000,00	2
0002345-23.2024.5.02.0011	R\$ 7.500,00	1
0003456-34.2024.5.02.0004	R\$ 42.000,00	3
0004567-45.2024.5.02.0022	R\$ 12.000,00	2
0005678-56.2024.5.02.0009	R\$ 9.500,00	1
0006789-67.2024.5.02.0015	R\$ 25.000,00	4

Ela rodou uma linha e mostrou o resultado ao sócio:

```
df["valor_acordo"].mean()
```

```
19000.0
```

O sócio olhou a tela e comentou: “então o acordo é R\$ 19.000,00”.

Explique, em um parágrafo, por que essa frase confunde três coisas diferentes. Use obrigatoriamente as palavras **variável**, **valor observado** e **estatística**, e diga a qual delas corresponde, na tela acima, o nome `valor_acordo`, uma célula da planilha e o número `19000.0`.

Questão 2 ★

Uma procuradoria municipal quer entender por que tantas execuções fiscais prescrevem antes de recuperar o crédito. Montou uma base em que cada linha é uma certidão de dívida ativa executada, cujas primeiras linhas são estas. A coluna `n_citacoes` conta quantas vezes o oficial de justiça tentou citar o devedor.

numero_cda	valor_inscrito	n_citacoes	tributo	houve_penhora	faixa_de_valor
2019/004512	3.420,00	2	IPTU	não	até R\$ 5 mil
2018/011907	47.180,50	1	ISS	sim	R\$ 5 a 50 mil
2020/000883	612,00	3	taxa de lixo	não	até R\$ 5 mil
2017/023144	128.900,00	0	ISS	não	acima de R\$ 50 mil

Ao carregar o arquivo, o pandas informou como guardou cada coluna:

```
df.dtypes
```

```
numero_cda      object
valor_inscrito   float64
n_citacoes      int64
tributo          object
houve_penhora    bool
faixa_de_valor   object
```

Essa saída diz como o computador **guardou** cada coluna, e não que tipo de variável cada uma **é**. Para cada coluna, diga o tipo de variável (numérica discreta, numérica contínua, categórica nominal, categórica ordinal ou categórica binária) e justifique a escolha em uma frase. Atenção: uma das colunas não é nenhum desses cinco tipos.

Questão 3

Um Juizado Especial Cível exporta as sentenças do ano num arquivo em que cada linha é uma sentença. A primeira coluna, `id_sentenca`, é um número sequencial que o sistema atribui a cada documento no momento em que ele é assinado.

id_sentenca	data_assinatura	resultado
4183291	03/02/2025	procedente em parte
4183508	03/02/2025	improcedente
4184017	04/02/2025	procedente
...	...	...

Um estagiário quis “resumir a base” e rodou a média de todas as colunas numéricas:

```
df["id_sentenca"].mean()
```

```
4183729.6
```

Explique o que esse resultado significa, e diga qual é a única informação sobre `id_sentenca` que vale a pena olhar.

Questão 4

Os números desta questão são reais. Numa base de 460 acórdãos de dano moral do TJSP, a coluna `camara` guarda o número da câmara julgadora, de 1 a 38. Um aluno rodou uma linha de código e colou a saída abaixo no relatório, sem mais nenhum comentário.

```
df["camara"].describe()
```

```
count    393.000000
mean     17.898219
std      10.342592
min       1.000000
25%      11.000000
50%      16.000000
75%      27.000000
max      38.000000
```

- Aponte tudo o que está errado em colar essa saída num relatório.
- A primeira linha, count 393, é a única informação aproveitável aqui. Por quê?
- Escreva o que o aluno deveria ter feito, e o que deveria constar do relatório.

Questão 5

Um instituto de pesquisa vai estudar as multas ambientais aplicadas por órgãos federais. A base traz uma linha por auto de infração:

numero_do_auto	orgao_autuante	valor_multa	descricao_da_infracao
9147822-E	IBAMA	R\$ 50.000,00	Transportar 12,4 m³ de madeira serrada de espécie nativa sem licença válida para todo o tempo da viagem.
9148003-E	IBAMA	R\$ 8.500,00	Manter em cativeiro três aves da fauna silvestre nativa sem autorização do órgão competente.
2210447-D	ICMBio	R\$ 130.000,00	Destruir 3,1 hectares de vegetação em área de unidade de conservação de proteção integral.
9148219-E	IBAMA	R\$ 2.000,00	Deixar de apresentar relatório anual de atividades potencialmente poluidoras no prazo.

Depois de coletar tudo, o instituto decidiu restringir a análise apenas aos autos lavrados pelo IBAMA, que são a maioria, e descartou o resto. Conferindo o resultado do recorte:

```
df["orgao_autuante"].value_counts()
```

```
IBAMA    812
```

Para cada coluna, diga se ela é ou não uma variável para fins de análise, e por quê.

- numero_do_auto
- descricao_da_infracao
- orgao_autuante, depois do recorte

Questão 6 ★

Um grupo de pesquisa vai investigar a seguinte pergunta:

Nas ações de despejo por falta de pagamento, o tamanho do débito está associado à concessão da liminar de desocupação?

A base tem uma linha por ação, e começa assim (o número do processo está abreviado para caber):

numero_processo	valor_do_debito	meses_de_atraso	tipo_imovel	liminar_concedida	houve_purgacao
1004512-88	R\$ 14.300,00	5	residencial	sim	não
1005033-21	R\$ 3.100,00	2	residencial	não	sim
1005190-74	R\$ 62.400,00	9	comercial	sim	não
1005247-09	R\$ 7.800,00	3	comercial	não	não

Percorra as **seis** colunas e, para cada uma, diga qual papel ela cumpre nessa pergunta: identifica o caso, o que eu quero explicar, o que pode explicar, ou define quais casos entram. Mais de uma coluna pode cumprir o mesmo papel, e você precisa justificar cada atribuição em uma frase.

Questão 7

Os CEJUSCs, Centros Judiciários de Solução de Conflitos e Cidadania, foram criados pela [Resolução 125/2010 do CNJ](#) e são as unidades onde os tribunais fazem conciliação e mediação. Eles atuam em duas frentes: a **processual**, quando já existe ação em curso e o juiz remete as partes à tentativa de acordo, e a **pré-processual**, quando a pessoa procura o centro antes de ajuizar qualquer coisa. O acordo obtido é homologado por um magistrado e vale como decisão judicial. O CNJ mantém uma [página de perguntas frequentes sobre a política](#), e o TJSP descreve os seus centros na [página de Conciliação e Mediação](#). Só em São Paulo são 322 centros, que somaram mais de 1,4 milhão de acordos desde 2014, com índice de acordo particularmente alto na frente pré-processual.

Um desses centros mantém uma base com uma linha por audiência realizada:

assunto	valor_da_causa	duracao_minutos	conciliador_capacitado	houve_acordo
Cobrança indevida	R\$ 4.200,00	38	sim	sim
Contrato de locação	R\$ 22.000,00	65	não	não
Plano de saúde	R\$ 9.800,00	22	sim	não
Cobrança indevida	R\$ 1.500,00	15	sim	sim

Escreva **duas** perguntas de pesquisa que possam ser respondidas com essa base e nas quais houve_acordo cumpra papéis diferentes: em uma delas ela deve ser o que você quer explicar, e na outra ela deve ser o que pode explicar. Para cada pergunta, diga qual coluna ocupa o outro papel.

Questão 8

Um Procon estadual tem 380 reclamações registradas contra empresas de telefonia. O atendente que registra a reclamação ouve o consumidor, escreve um relato livre e escolhe um assunto numa lista fechada que hoje tem 40 opções. Quatro registros, feitos por atendentes diferentes:

id	relato do consumidor	assunto escolhido
1	Apareceu na conta um pacote de streaming que eu nunca pedi, e já paguei três meses.	Cobrança indevida
2	Estão me cobrando por um serviço adicional que eu não contratei, desde março.	Serviço não fornecido
3	Veio na fatura uma assinatura que eu não reconheço e a operadora não soube explicar.	Problema na fatura
4	Cobram de mim um plano que nunca foi ativado na minha linha.	Cobrança abusiva

Um requisito das variáveis categóricas é que as categorias sejam **mutuamente exclusivas e exaustivas**. Discuta se a coluna de assunto cumpre o requisito, explique o que dá errado na análise quando ele não é cumprido, e proponha um tratamento concreto.

Questão 9

Uma advogada procura o núcleo de pesquisa empírica do escritório com esta pergunta: “O dano moral por inscrição indevida em cadastro de inadimplentes deve ser indenizado em valor mais alto do que hoje se pratica?”

O núcleo tem à disposição uma base de 800 acórdãos de tribunais estaduais sobre esse tema, com as colunas `numero_processo`, `tribunal`, `comarca`, `orgao_julgador`, `data_julgamento`, `dias_de_inscricao_indevida`, `houve_dano_moral`, `valor_arbitrado` e `ementa`.

- a) Explique por que a pergunta, como está, não pode ser respondida com essa base.

- b) Reescreva-a como uma pergunta empírica que a base possa ajudar a responder.
- c) **Monte a tabela** que descreve a sua versão da pergunta, no mesmo formato que o Projeto 1 pede: uma linha por coluna que você vai usar, com as colunas *variável*, *tipo*, *papel* e *de onde tirar*. Inclua apenas as colunas que a sua pergunta usa, e não a base inteira.

PARTE 2

Tabelas

Questão 10 ★

Uma defensoria pública vai analisar 1.200 audiências de custódia realizadas no ano. A base começa assim:

id_audiencia	horas_ate_audiencia	alegou_violencia	decisao	defensor_ou_advogado
A-2025-0417	19	sim	liberdade provisória	defensor
A-2025-0418	23	não	prisão preventiva	defensor
A-2025-0419	14	não	prisão preventiva	advogado
A-2025-0420	31	sim	relaxamento	defensor

Uma base de dados está **arrumada** (o termo em inglês é *tidy*) quando cumpre três regras. Enuncie as três regras e ilustre cada uma com essa tabela, apontando o que faz o papel de linha, o que faz o papel de coluna e o que faz o papel de célula.

Questão 11

Um pesquisador está estudando recuperações judiciais e montou esta tabela a partir do sistema do tribunal. Cada número é a quantidade de pedidos de recuperação distribuídos naquela comarca naquele ano.

comarca	2023	2024	2025
São Paulo	48	51	43
Campinas	5	7	5
Ribeirão Preto	6	4	6

- a) Qual regra da tabela arrumada foi quebrada, e por quê?
- b) Redesenhe a tabela na forma arrumada, escrevendo as primeiras linhas.
- c) Cite duas contas que ficam difíceis na tabela original e fáceis na arrumada.

Questão 12

Um pesquisador quer saber se os bancos são condenados com mais frequência do que as companhias aéreas em ações de consumo. Ele extraiu a tabela abaixo da capa dos processos.

processo	partes	resultado
1001234-55.2024.8.26.0100	Maria Silva x Banco Alfa S/A	procedente em parte
1002345-66.2024.8.26.0100	João Souza x Cia Aérea Beta	improcedente
1003456-77.2024.8.26.0100	Ana Lima x Banco Alfa S/A; Loja Gama Ltda	procedente

- a) Aponte os problemas de arrumação desta tabela.
- b) Explique por que, do jeito que a tabela está, a pergunta do pesquisador não pode ser respondida com uma conta.
- c) Proponha uma estrutura de tabela que permita respondê-la.

Questão 13 ★

Um monitor entregou esta planilha de ações de cobrança de cotas condominiais, dizendo que já está pronta para análise.

caso	comarca	valor_cobrado	pedidos	distribuicao
1	São Paulo	R\$ 5.000,00	cobrança	12/03/2024
2	Campinas	8000	cobrança e dano moral	5 de abril de 2024
3	São Paulo/SP	R\$ 12.000	dano moral	2024-04-19
4	são paulo	não consta	cobrança	22/04/2024
TOTAL		25.000		

Identifique pelo menos **quatro** problemas distintos, explique o efeito prático de cada um sobre as contas que virão depois, e diga como corrigir.

Questão 14

Um tribunal divulgou uma nota informando que “em 62% dos casos houve acordo na conciliação”. O número saiu desta base, em que cada linha é uma **audiência**:

processo	data_audiencia	houve_acordo
1002345-66.2025	04/03/2025	False
1002891-13.2025	04/03/2025	True
1002345-66.2025	22/05/2025	False
1003120-77.2025	23/05/2025	True
1002345-66.2025	11/08/2025	True

São 1.500 audiências no total, referentes a 900 processos distintos, e o número da nota veio daqui:

```
df["houve_acordo"].mean()
```

```
0.62
```

- Que problema isso cria para a afirmação da nota?
- A base está arrumada, ou não está? Justifique.
- Que providência você tomaria antes de reportar a proporção, e o que precisa ser escrito no relatório de qualquer forma?

PARTE 3

Estatísticas

Questão 15 ★

Um juizado especial cível julgou, numa mesma semana, nove ações de indenização por negativação indevida. Os valores arbitrados, já ordenados, foram:

R\$ 2.000 R\$ 3.000 R\$ 5.000 R\$ 6.000 R\$ 8.000 R\$ 10.000 R\$ 12.000
R\$ 15.000 R\$ 29.000

Calcule à mão a média, a mediana, a moda, o mínimo, o máximo e a amplitude, mostrando as contas. Em seguida, responda: a média é maior, menor ou igual à mediana, e o que isso diz sobre o formato da distribuição?

Questão 16 ★

Uma defensoria pública quer dimensionar a carga de trabalho da instrução criminal e contou quantas testemunhas foram ouvidas em cinco processos, na ordem em que eles foram encerrados:

4 9 2 6 4

Calcule à mão a média, a variância e o desvio padrão, mostrando a tabela de desvios. Depois, escreva uma frase que interprete o desvio padrão obtido, em linguagem de relatório.

Use o denominador $n - 1$ na variância, que é a convenção do pandas e a que vale na disciplina inteira.

Questão 17 ★

Uma corregedoria acompanha o tempo que os processos levam até a sentença e separou nove processos encerrados numa vara. Os tempos, em dias, já ordenados:

210 280 340 390 450 520 610 740 1.180

Calcule à mão o primeiro quartil, o terceiro quartil e o intervalo interquartil, mostrando como você localizou cada posição. Depois, escreva o que o intervalo interquartil obtido significa em português, sem usar a palavra “quartil”.

Localize os quartis como o pandas faz: na lista ordenada, contando as posições a partir de zero, a posição do quartil é $p \times (n - 1)$, com p igual a 0,25 para o primeiro e 0,75 para o terceiro; se a posição cair entre dois valores, interpole proporcionalmente entre eles.

Questão 18

Voltando às nove indenizações por negativação indevida da Questão 15:

R\$ 2.000 R\$ 3.000 R\$ 5.000 R\$ 6.000 R\$ 8.000 R\$ 10.000 R\$ 12.000
R\$ 15.000 R\$ 29.000

Nesse conjunto, a média é de R\$ 10.000,00, a mediana é de R\$ 8.000,00, o desvio padrão é de R\$ 8.276,47 e o intervalo interquartil é de R\$ 7.000,00.

Ao conferir os autos, descobriu-se que a sentença de R\$ 29.000,00 foi lançada na base por engano: ela é de outra vara. Retire esse valor, ficando com oito. Para sua conferência, os valores recalculados são: média de R\$ 7.625,00, mediana de R\$ 7.000,00, desvio padrão de R\$ 4.501,98 e intervalo interquartil de R\$ 6.000,00.

Monte uma tabela com o antes, o depois e a variação percentual de cada medida. Depois responda: quais medidas são mais sensíveis a um único caso extremo, e o que essa constatação implica na escolha do que reportar num parecer?

Questão 19 ★

Um CEJUSC registrou o resultado das dez audiências de conciliação de uma manhã, na ordem em que aconteceram:

não sim não não sim não sim não não não

- Calcule a proporção de audiências com acordo, apresentando a razão entre as duas quantidades.
- Reescreva a mesma coluna trocando “sim” por 1 e “não” por 0, e calcule a média dessa nova coluna.
- Explique por que os dois números coincidem, e diga por que isso não vale para uma variável categórica com três categorias.

Questão 20

O mesmo tribunal da Questão 14 guarda houve_acordo como coluna lógica, com verdadeiro em 612 das 1.500 audiências:

processo	data_audiencia	houve_acordo
1002345-66.2025	04/03/2025	False
1002891-13.2025	04/03/2025	True
1002345-66.2025	22/05/2025	False
...	...	...

Um analista roda:

```
df["houve_acordo"].mean()
```

- Que número essa linha devolve? Apresente a conta, e explique por que uma coluna de verdadeiro e falso aceita uma média.
- Escreva, em uma frase de relatório, o que esse número significa.
- A linha `df["houve_acordo"].sum()` devolve o quê, e para que serve?

Questão 21

Uma base de 3.000 recursos julgados por um tribunal tem a coluna `recurso_provido` preenchida com os textos "sim" e "não", e não com valores lógicos. Um estagiário executa a mesma linha da questão anterior:

```
df["recurso_provido"].mean()
```

```
TypeError: Could not convert string 'simnãoãosimnão...' to numeric
```

- Explique o erro, e diga por que ele é uma boa notícia.
- Descreva, em português, duas formas diferentes de chegar à proporção de recursos providos com a coluna nesse formato, e diga qual você prefere e por quê.
- Um colega sugere trocar "sim" por 1, "não" por 0 e as células vazias por 0,5, para "não perder informação". Avalie a sugestão.

Questão 22

No conjunto das nove indenizações da Questão 15, a variância vale 68.500.000 e o desvio padrão vale R\$ 8.276,47, em torno de uma média de R\$ 10.000,00.

- Qual é a unidade de medida da variância nesse caso? Escreva-a por extenso.
- Explique por que a variância existe, se o desvio padrão é mais fácil de interpretar.
- Um relatório afirma: "a variância das indenizações é de R\$ 68.500.000,00, o que mostra dispersão altíssima". Corrija a frase.

Questão 23

Os números desta questão são reais. Numa base de 460 acórdãos de dano moral do TJSP, 303 têm valor de indenização extraído da ementa. O resumo dessa coluna é este:

```
df["valor_indenizacao"].describe()
```

```
count    303.000000
mean      7935.255182
std       8388.184932
min        40.250000
```

25%	5000.000000
50%	5000.000000
75%	10000.000000
max	90000.000000

Olhando a coluna de perto: 99 acórdãos arbitram exatamente R\$ 5.000,00, 56 arbitram menos que isso, e 155 arbitram esse valor ou menos. A moda também é R\$ 5.000,00.

- As linhas 25% e 50% mostram o mesmo número. Como três medidas diferentes podem coincidir? Mostre, com os números acima, por que isso acontece.
- Colher mais acórdãos resolveria a coincidência? Justifique.
- O que você escreveria no relatório para que o leitor não ache que houve erro de conta?

PARTE 4

Interpretação

Questão 24 ★

Os números desta questão são reais. Numa base de 460 acórdãos de dano moral do TJSP, foi possível extrair o valor arbitrado em 303 deles. Nesses 303, a média é de R\$ 7.935,26 e a mediana é de R\$ 5.000,00.

Escreva um parágrafo de relatório interpretando as duas medidas em conjunto. O parágrafo precisa dizer o que cada número significa, o que a diferença entre eles indica, e sobre quantos casos as contas foram feitas.

Questão 25

Sobre a mesma base real de 460 acórdãos do TJSP, em que 303 têm valor extraído, com média de R\$ 7.935,26, mediana de R\$ 5.000,00, moda de R\$ 5.000,00 e máximo de R\$ 90.000,00, um parecer afirma o seguinte:

"A indenização média por dano moral no TJSP é de R\$ 7.935,26. Portanto, metade dos casos recebe mais do que isso, e nosso cliente, que recebeu R\$ 5.000,00, foi tratado abaixo da média do tribunal."

Identifique **três** problemas distintos nessa passagem e reescreva-a de forma defensável.

Questão 26 ★

Os números desta questão são reais. Na base de 460 acórdãos de dano moral do TJSP, em 157 não foi possível extrair o valor da indenização. Em 192 dos 460 o acórdão não reconheceu dano moral algum.

- Liste pelo menos **três** razões substantivas diferentes pelas quais uma célula da coluna de valor pode estar vazia.
- Por que tratar todas essas ausências da mesma forma é um problema?
- Que informação sobre os faltantes precisa constar do relatório, mesmo que a análise apenas os ignore?

Questão 27

Continuando na base real de 460 acórdãos do TJSP: um colega, incomodado com as 157 células vazias da coluna de valor, resolveu preenchê-las com zero.

```
df["valor_indenizacao"].mean()          # sobre os 303 com valor  
df["valor_indenizacao"].fillna(0).mean() # sobre as 460 linhas
```

```
7935.255182
```

```
5226.917935
```

A mediana, nas duas contas, continuou em R\$ 5.000,00.

- a) Explique por que a média caiu tanto e a mediana não se moveu.
- b) Existe alguma pergunta de pesquisa para a qual preencher com zero seria **correto**? Se sim, qual, e o que mudaria no enunciado da pergunta.
- c) Qual é o problema de fazer isso sem declarar?

Questão 28

Um escritório quer descobrir quanto costuma receber de honorários de sucumbência nas **causas de consumo** que patrocina, para calibrar propostas a clientes novos. O setor financeiro mandou o resumo abaixo, calculado sobre **todos** os processos encerrados nos últimos três anos, de qualquer matéria.

medida	valor	medida	valor
processos encerrados	240	mínimo	R\$ 180,00
com honorários fixados	180	primeiro quartil	R\$ 3.500,00
média	R\$ 12.400,00	terceiro quartil	R\$ 14.000,00
mediana	R\$ 6.000,00	máximo	R\$ 210.000,00
moda	R\$ 5.000,00	desvio padrão	R\$ 21.800,00

- a) Escolha quais medidas reportar e justifique cada escolha e cada omissão.
- b) O mínimo de R\$ 180,00 chama atenção. O que você faria antes de reportá-lo?
- c) Há um problema conceitual em usar esses números para responder à pergunta como ela foi feita. Qual é?

COMO ESTA LISTA FOI ELABORADA

Parte das questões desta lista foi redigida com apoio do modelo de linguagem Claude Opus 5. Todas passaram por revisão do professor, enunciado por enunciado: o caso, os números, o gabarito e o recorte de conteúdo são de responsabilidade dele, e as questões que não sobreviveram à revisão ficaram de fora.