

Lista 2

Encadeamento, gramática de gráficos e duas variáveis

Conteúdo Aulas 4 a 6
Turma 4A · 2026/2
Professor Julio Trecenti
Versão Sem respostas.

POR ONDE COMEÇAR

As questões marcadas com uma estrela vermelha são o caminho mínimo: são oito de dezoito, e juntas cobrem uma vez cada conceito das aulas 4 a 6. Se o tempo for curto, faça essas e volte às outras quando puder. As demais repetem os mesmos conceitos em outros contextos, e é a repetição em contextos diferentes que faz o conceito grudar.

Nenhuma questão pede que você escreva código. Todas pedem que você leia um código ou um gráfico e explique o que ele faz, o que ele mostra, ou por que ele responde a outra pergunta. As respostas do gabarito também não têm código, pelo mesmo motivo: o que está sendo avaliado é o raciocínio, e ele se escreve em português.

PARTE 1

Encadear operações

Questão 1 ★

Uma procuradoria municipal quer saber o valor médio das execuções fiscais que ainda estão em andamento. A base tem uma linha por execução:

processo	situacao	valor	vara
1500123-45.2023.8.26.0053	em andamento	R\$ 12.400,00	3ª
1500987-11.2022.8.26.0053	extinta	R\$ 380.000,00	1ª
1501234-77.2023.8.26.0053	em andamento	R\$ 8.900,00	3ª
1502345-90.2021.8.26.0053	extinta	R\$ 4.100,00	2ª
1503456-12.2024.8.26.0053	em andamento	R\$ 15.200,00	1ª

Duas pessoas escreveram códigos diferentes:

```
# a estagiária
(  
  execucoes  
  .query("situacao = 'em andamento'")  
  .agg(media=("valor", "mean"))  
)
```

```
# o assessor  
(  
  execucoes  
  .agg(media=("valor", "mean"))  
)
```

```
.query("situacao == 'em andamento'")
)
```

- a) Um dos dois códigos não roda. Qual, e por quê?
- b) Suponha que esse código passasse a rodar. Explique por que **resumir antes de filtrar** continuaria sendo uma má ideia, como regra geral de análise.

Questão 2

Leia o encadeamento abaixo, que roda sobre uma base de audiências de custódia:

```
(
  custodias
  .query("houve_alegacao_tortura")
  .sort_values("duracao_min", ascending=False)
  [ ["processo", "comarca", "duracao_min"] ]
  .head(10)
)
```

Não explique linha a linha. Escreva um parágrafo curto respondendo:

- a) Qual é o **propósito** desse código, ou seja, o que ele foi feito para produzir?
- b) Qual **pergunta de pesquisa** ele responde, e para quem essa resposta serviria?

Questão 3

Ainda sobre a base de audiências de custódia, considere estes dois códigos:

```
# A
(
  custodias
  .sort_values("duracao_min", ascending=False)
  .head(10)
  [ ["processo", "duracao_min"] ]
)
```

```
# B
(
  custodias
  .head(10)
  .sort_values("duracao_min", ascending=False)
  [ ["processo", "duracao_min"] ]
)
```

- a) Os dois devolvem a mesma tabela? Explique.
- b) No código A, trocar de lugar o `.head(10)` e a seleção de colunas mudaria o resultado? Explique por quê.

Questão 4 ★

Esta questão não tem código, nem na pergunta nem na resposta.

Você tem uma base de **sentenças de primeiro grau em ações de plano de saúde**, com uma linha por sentença e as seguintes colunas:

coluna	o que ela guarda
processo	número do processo
comarca	comarca onde tramitou
ano	ano da sentença
tipo_pedido	negativa de cobertura, reajuste, rede credenciada, outros
resultado	procedente, parcialmente procedente, improcedente
valor_danos	valor fixado a título de dano moral, em reais; vazio quando não houve condenação
dias_ate_sentenca	dias entre a distribuição e a sentença

As cinco operações que você conhece são: **filtrar linhas**, **selecionar colunas**, **ordenar linhas**, **agrupar e resumir** e **criar colunas**. Não é preciso usar todas, e a ordem é parte da resposta.

Para cada objetivo abaixo, escreva o passo a passo em português, numerando as operações na ordem em que você as faria e dizendo, em cada passo, **qual coluna** você usaria e **por que aquele passo vem naquele lugar**.

a) Quero saber, para cada tipo de pedido, o valor mediano de dano moral entre as sentenças proferidas em 2023 em diante.

b) Quero as vinte sentenças mais demoradas da base, com o número do processo, a comarca e a demora em anos (e não em dias).

Questão 5

Agora o caminho inverso da questão anterior. Alguém já fez a análise, e sobrou só o resultado.

Sobre a mesma base de sentenças de plano de saúde, uma analista produziu esta tabela:

comarca	sentencas	prop_procedente
São Paulo	1.204	0,71
Campinas	318	0,66
Santos	190	0,74
Ribeirão Preto	151	0,59
São José do Rio Preto	140	0,63

Ela guardou só as comarcas com pelo menos 100 sentenças, e ordenou pelo número de sentenças.

a) Qual das perguntas abaixo esta análise responde? Escolha **uma** e justifique em duas ou três frases.

pergunta
I Em quais comarcas o consumidor tem mais chance de ganhar uma ação de plano de saúde?
II Entre as comarcas com volume relevante desta base, a proporção de sentenças procedentes varia muito?
III Qual comarca tem mais ações de plano de saúde no estado?
IV O tipo de pedido influencia o resultado da sentença?

b) Para cada uma das outras três, escreva em uma frase **o que faltaria** na análise para respondê-la.

Questão 6

Os números desta questão são reais, e vêm da base de acórdãos criminais do TJSP usada nas aulas. Ela tem **475 acórdãos** e várias colunas com campos vazios, porque nem toda ementa menciona o regime inicial e nem toda ementa menciona a pena.

Um aluno queria descartar apenas os acórdãos em que o regime não foi encontrado, e escreveu `criminal.dropna()`. Sobraram **190 linhas**. Ele esperava algo perto de **333**, que é o que sai com `criminal.dropna(subset=["regime_inicial"])`.

Esta é a documentação da função:

pandas.DataFrame.dropna

```
DataFrame.dropna(*, axis=0, how=<no_default>, thresh=<no_default>, subset=None, inplace=False, ignore_index=False) \[source\]
```

Remove missing values.

See the [User Guide](#) for more on which values are considered missing, and how to work with missing data.

Parameters:

how : {'any', 'all'}, default 'any'

Determine if row or column is removed from DataFrame, when we have at least one NA or all NA.

- 'any' : If any NA values are present, drop that row or column.
- 'all' : If all values are NA, drop that row or column.

subset : column label or iterable of labels, optional

Labels along other axis to consider, e.g. if you are dropping rows these would be a list of columns to include.

a) Usando a documentação acima, explique por que o `.dropna()` sem argumento devolveu bem menos linhas. Aponte qual parâmetro responde por isso.

b) Um colega sugeriu: "então é só usar `.dropna()` e pronto, você fica com os casos completos, que são os melhores". Responda a ele, dizendo que problema essa escolha cria para a análise.

Questão 7 ★

Uma pesquisadora quer comparar a capital com o interior. A base tem uma coluna `comarca`, com o nome da comarca de cada acórdão, e não tem nenhuma coluna que diga "capital" ou "interior".

```
(
    criminal
    .assign(eh_capital=criminal["comarca"] == "São Paulo")
    .dropna(subset=["pena_anos"])
    .groupby("eh_capital")
    .agg(
        n=("processo", "size"),
        pena_mediana=("pena_anos", "median"),
    )
    .reset_index()
)
```

	eh_capital	n	pena_mediana
0	False	161	4.166667
1	True	55	4.666667

- a) Explique o que a criação da coluna faz aqui, e por que ela não pode vir depois do agrupamento.
- b) O descarte dos vazios de pena e a criação da coluna podem trocar de lugar sem mudar o resultado? Justifique.
- c) Olhando a saída, o que você responderia à pergunta "a capital julga diferente do interior"?

Questão 8

Este código roda sobre a base de acórdãos criminais, e os números da saída são reais:

```
(
  penas
  .groupby("regime", as_index=False, observed=True)
  .agg(prop_reincidencia=("houve_reincidencia", "mean"))
)
```

	regime	prop_reincidencia
0	aberto	0.074074
1	semiaberto	0.418182
2	fechado	0.511364

A coluna `houve_reincidencia` só tem os valores `True` e `False`.

- a) Explique por que a **média** de uma coluna de verdadeiro e falso é a proporção de verdadeiros.
- b) Escreva, em uma frase, o que a saída diz.
- c) Um colega olhou os números e escreveu: "o regime fechado leva o réu à reincidência". Comente.

PARTE 2

A gramática dos gráficos

A DEFINIÇÃO QUE ORGANIZA ESTA PARTE

Um **gráfico estatístico** é um mapeamento de variáveis em aspectos estéticos de formas geométricas.

Três palavras carregam a definição inteira. **Variáveis**: colunas da tabela, e não valores soltos. **Aspectos estéticos**: posição, cor, tamanho, forma. **Formas geométricas**: barras, pontos, linhas, caixas.


Todas as questões desta parte são a mesma pergunta em situações diferentes: o que foi mapeado em quê, e isso responde à pergunta que se queria fazer?

Questão 9

Uma aluna quer um gráfico de barras cinza e escreve:

```
(
  ggplot(criminal)
  + aes(x="assunto", fill="cinza")
  + geom_bar()
)
```

O gráfico saiu assim:



As barras ficaram todas da mesma cor, como ela queria, mas apareceu uma legenda ao lado com um único item escrito cinza.

a) Explique por que a legenda apareceu.

b) Diga o que precisa mudar, em português, e escreva a regra geral em uma frase.

Questão 10 ★

Agora o inverso da questão anterior. Um aluno quer que a cor das barras separe os acórdãos com e sem reincidência, e escreve:

```
(
  ggplot(penas)
  + aes(x="regime")
  + geom_bar(fill="houve_reincidencia")
)
```

O código não roda: o plotnine reclama que não conhece a cor `houve_reincidencia`.

Não corrija o código. Em vez disso:

a) Explique qual é o **problema conceitual** desse código, usando a definição de gráfico estatístico da abertura desta parte.

b) Diga o que muda **no desenho** e **na pergunta que o gráfico responde** depois que o problema for resolvido.

Questão 11 ★

Esta questão junta o que vimos nas aulas 5 e 6. Complete a tabela dizendo qual geometria usar em cada caso e por quê.


o que você tem	a geometria	por quê
uma variável categórica, e você quer contar os casos de cada categoria		
uma variável numérica, e você quer ver como os valores se distribuem		
uma tabela em que a altura da barra já está calculada numa coluna		
uma variável numérica e uma categórica, e você quer comparar a distribuição entre as categorias		
duas variáveis numéricas, e você quer ver se uma acompanha a outra		
uma variável numérica medida ao longo do tempo		
duas variáveis categóricas		

COMO RESPONDER

Não é preciso escrever código: o nome da geometria em português já serve ("barras", "caixas", "pontos", "linha", "histograma"). Se ajudar, **desenhe um rascunho** de cada gráfico ao lado. Desenhar costuma ser o jeito mais rápido de descobrir se você entendeu a geometria ou se só decorou o nome dela.

Questão 12

Os três gráficos abaixo usam **exatamente as mesmas duas variáveis**, o regime inicial e a reincidência, e a mesma geometria de barras. A única diferença é como as barras foram repartidas.



- a) Para cada um dos três, escreva **qual pergunta ele responde bem**.
- b) Para cada um dos três, descreva **uma situação concreta**, em um relatório jurídico, em que ele seria a escolha certa.
- c) Uma leitura fica difícil ou impossível em dois dos três gráficos. Qual é ela, e em quais?

PARTE 3**Ler e criticar um gráfico****Questão 13** ★

Duas formas de olhar a mesma coluna numérica, a pena em anos:

```
# A  
ggplot(penas) + aes(x="pena_anos") + geom_histogram(bins=20)
```

```
# B  
ggplot(penas) + aes(x="regime", y="pena_anos") + geom_boxplot()
```

- a) O que o A mostra que o B não mostra?
- b) O que o B faz que o A não faz?
- c) Uma aluna rodou o A com 3 faixas e depois com 100 e ficou confusa com a diferença. Como você explicaria a ela o que escolher?

Questão 14


Estes números são reais e saem da base de acórdãos criminais, considerando os acórdãos que têm regime e pena informados:

regime	mediana	média	acórdãos
aberto	1,42	2,08	54
semiaberto	3,08	3,72	55
fechado	5,83	6,36	88

- a) **Desenhe à mão** um rascunho do histograma da pena de todos esses acórdãos juntos, sem separar por regime. Não precisa ser bonito nem preciso: o que importa é o formato, onde fica o pico e para que lado vai a cauda. Depois caracterize a distribuição em uma frase.
- b) Nos três regimes a média é maior que a mediana. Como esse fato sustenta o desenho que você fez?

Questão 15 ★

O gráfico abaixo é de dispersão: cada ponto é uma unidade da federação. No eixo horizontal, o número de processos novos por mil habitantes no ano. No eixo vertical, o IDH do estado. A reta é a linha de tendência.



Eixo do IDH: Atlas do Desenvolvimento Humano. Eixo de processos: valores ilustrativos, construídos para o exercício.

- a) Escreva uma frase que descreva **corretamente** o que o gráfico mostra.
- b) Se um estado aumentar a sua litigiosidade, isso causará um aumento no IDH? Explique.

Questão 16

Um relatório de um tribunal traz o gráfico de dispersão abaixo, com uma vara em cada ponto, e a seguinte conclusão:




Figura do relatório. Valores ilustrativos.

Conclusão do relatório: contratar mais servidores aumenta o tempo de tramitação. Recomenda-se congelar as contratações.

Explique, em dois ou três parágrafos, por que essa conclusão não se sustenta. Sua resposta deve mencionar pelo menos uma explicação alternativa concreta para o mesmo gráfico.

Questão 17

Uma equipe acompanha a proporção de recursos negados ao longo dos anos, separando os casos em que o Ministério Público está no polo ativo dos casos em que está no polo passivo. O gráfico tem uma linha para cada polo.


```
(  
  ggplot(resumo)  
  + aes(x="ano", y="prop_negados", color="polo_mp")  
  + geom_line()  
  + geom_point()  
)
```

a) Por que a cor foi declarada dentro do mapeamento aqui, e o que aconteceria com o gráfico se ela virasse um valor fixo na geometria da linha?

b) Por que vale acrescentar os pontos a um gráfico que já tem linha?

Questão 18 ★

Esta questão fecha a lista. Um grupo apresentou o gráfico abaixo em sala. Ele sai da base de recursos criminais das câmaras do TJSP, e mostra a proporção de recursos integralmente negados por assunto. Os assuntos com menos de 40 recursos foram descartados, e sobraram nove.



E o grupo escreveu a seguinte conclusão:

A Câmara é mais dura com crimes patrimoniais: a proporção de negativas é maior nesses assuntos. Isso mostra um viés dos desembargadores contra réus de crimes contra o patrimônio.

Escreva uma avaliação dessa conclusão, em três parágrafos, respondendo:

- a)** O gráfico sustenta a primeira frase da conclusão? Olhe os assuntos, e não só a forma das barras.
- b)** Que decisões de quem fez o gráfico afetam a leitura, e como elas deveriam ser declaradas?
- c)** O que faltaria para sustentar a palavra “viés”?