

Lista 2

Encadeamento, gramática de gráficos e duas variáveis

Conteúdo Aulas 4 a 6
Turma 4A · 2026/2
Professor Julio Trecenti
Versão Sem respostas.

POR ONDE COMEÇAR

As questões marcadas com uma estrela vermelha são o caminho mínimo: são nove de vinte e quatro, e juntas cobrem uma vez cada conceito das aulas 4 a 6. Se o tempo for curto, faça essas e volte às outras quando puder. As demais repetem os mesmos conceitos em outros contextos, e é a repetição em contextos diferentes que faz o conceito grudar.

Nenhuma questão pede que você escreva código do zero. Todas pedem que você leia um código, diga o que ele produz, ou explique por que ele produz outra coisa.

PARTE 1

Encadear operações

Questão 1 ★

Uma procuradoria municipal quer saber o valor médio das execuções fiscais que ainda estão em andamento. A base tem uma linha por execução:

processo	situacao	valor	vara
1500123-45.2023.8.26.0053	em andamento	R\$ 12.400,00	3ª
1500987-11.2022.8.26.0053	extinta	R\$ 380.000,00	1ª
1501234-77.2023.8.26.0053	em andamento	R\$ 8.900,00	3ª
1502345-90.2021.8.26.0053	extinta	R\$ 4.100,00	2ª
1503456-12.2024.8.26.0053	em andamento	R\$ 15.200,00	1ª

Duas pessoas escreveram códigos diferentes:

```
# a estagiária
(  
  execucoes  
  .query("situacao = 'em andamento'")  
  .agg(media=("valor", "mean"))  
)
```

```
# o assessor
(  
  execucoes  
  .agg(media=("valor", "mean"))  
  .query("situacao = 'em andamento'")  
)
```

- a) Um dos dois códigos não roda. Qual, e por quê?
- b) Explique, em uma frase, a regra geral que esse par ilustra sobre a ordem das operações no encadeamento.

Questão 2

Leia o encadeamento abaixo, que roda sobre uma base de audiências de custódia:

```
(
  custodias
  .query("houve alegacao tortura")
  .sort_values("duracao_min", ascending=False)
  [ ["processo", "comarca", "duracao_min"] ]
  .head(10)
)
```

Escreva, em português e em uma linha cada, o que cada uma das quatro operações faz. Depois diga, em uma frase, qual pergunta esse código responde.

Questão 3

Ainda sobre a base de audiências de custódia, considere estes dois códigos:

```
# A
(
  custodias
  .sort_values("duracao_min", ascending=False)
  .head(10)
  [ ["processo", "duracao_min"] ]
)
```

```
# B
(
  custodias
  .head(10)
  .sort_values("duracao_min", ascending=False)
  [ ["processo", "duracao_min"] ]
)
```

- a) Os dois devolvem a mesma tabela? Explique.
- b) No código A, trocar de lugar o `.head(10)` e a seleção de colunas `[ ["processo", "duracao_min"] ]` mudaria o resultado? Explique por quê.

Questão 4 ★

Uma pesquisadora está trabalhando com uma base de acórdãos criminais e escreveu:

```
(
  criminal
  .query("eh trafico")
  [ "pena_anos" ]
  .sort_values(ascending=False)
  .head(5)
)
```

```
448    21.166667
54      16.750000
383    10.250000
219      9.500000
272      9.000000
Name: pena_anos, dtype: float64
```

Ela queria mostrar, junto de cada pena, o número do processo e a comarca. Mas não conseguiu: escreveu `.head(5)[["processo", "comarca"]]` no fim e recebeu erro.

Explique o que aconteceu, e o que precisa mudar no código. Sua resposta deve explicar a diferença entre `["pena_anos"]` e `[["pena_anos"]]`.

Questão 5

Os números desta questão são reais, e vêm da base de acórdãos criminais do TJSP usada nas aulas. Ela tem **475 acórdãos** e várias colunas com campos vazios, porque nem toda ementa menciona o regime inicial e nem toda ementa menciona a pena.

Um aluno queria descartar apenas os acórdãos em que o regime não foi encontrado, e escreveu:

```
criminal.dropna().shape
```

```
(190, 18)
```

Ele esperava algo perto de 333 linhas, que é o que sai com `criminal.dropna(subset=["regime_inicial"])`.

a) Explique por que o `.dropna()` sem argumento devolveu bem menos linhas.

b) Um colega sugeriu: “então é só usar `.dropna()` e pronto, você fica com os casos completos, que são os melhores”. Responda a ele, dizendo que problema essa escolha cria para a análise.

Questão 6

Duas formas de escrever a mesma coisa:

```
# A
(
    criminal
    .groupby("regime_inicial")
    .agg(n=("processo", "size"))
    .reset_index()
)
```

```
# B
(
    criminal
    .groupby("regime_inicial", as_index=False)
    .agg(n=("processo", "size"))
)
```

a) As duas devolvem a mesma tabela. Explique o que o `.reset_index()` faz no A e por que ele não é necessário no B.

b) Se você esquecer os dois, o que acontece com a coluna `regime_inicial`? E por que isso atrapalha na hora de fazer um gráfico?

PARTE 2

A gramática dos gráficos

Questão 7 ★

Um gráfico estatístico é um mapeamento de variáveis em aspectos estéticos de formas geométricas. Na prática, todo gráfico precisa de três camadas.

Os três blocos abaixo foram rodados em sequência, e cada um produziu uma coisa diferente na tela:

```
# 1
ggplot(penas)
```

```
# 2
ggplot(penas) + aes(x="regime")
```

```
# 3
ggplot(penas) + aes(x="regime") + geom_bar()
```

O primeiro produziu um retângulo cinza vazio. O segundo produziu um retângulo com os nomes dos regimes escritos embaixo, e nada dentro. O terceiro produziu três barras.

Explique o que cada camada acrescentou, e responda: por que o segundo gráfico, mesmo sem desenhar nada, já é um gráfico válido?

Questão 8

Uma aluna quer um gráfico de barras cinza e escreve:

```
(
  ggplot(multas)
  + aes(x="tipo_infracao", fill="cinza")
  + geom_bar()
)
```

O gráfico sai com todas as barras da mesma cor, mas aparece uma legenda ao lado com um único item escrito cinza.

a) Explique por que a legenda apareceu.

b) Escreva a correção, e explique a regra em uma frase.

Questão 9 ★

Agora o inverso da questão anterior. Um aluno quer que a cor das barras separe os acórdãos com e sem reincidência, e escreve:

```
(
  ggplot(penas)
  + aes(x="regime")
```

```
+ geom_bar(fill="houve_reincidencia")
)
```

O código não roda: o plotnine reclama que não conhece a cor `houve_reincidencia`.

Explique o que aconteceu, escreva a correção e diga o que muda **no desenho** depois da correção.

Questão 10

Complete a tabela abaixo, dizendo qual geometria usar em cada caso e por quê. Todas as geometrias da coluna do meio aparecem uma vez só.

o que você tem	a geometria	por quê
uma variável categórica, e você quer contar os casos de cada categoria		
uma variável numérica, e você quer ver como os valores se espalham		
uma tabela em que a altura da barra já está calculada numa coluna		

Escolha entre `geom_bar()`, `geom_col()` e `geom_histogram(bins=)`.

Questão 11

Os números desta questão são reais. Na base de acórdãos criminais, depois de descartar quem não tem regime nem pena, sobram **197 acórdãos**, assim distribuídos:

regime	acórdãos
aberto	54
semiaberto	55
fechado	88

Um aluno quer o gráfico de barras dessa contagem e pergunta: “preciso fazer o `groupby` primeiro para calcular esses números?”

Responda a ele, e escreva o código do gráfico.

Questão 12

Os três gráficos abaixo usam **exatamente as mesmas duas variáveis** e mudam uma palavra só:

```
+ geom_bar()                # A, que é o mesmo que position="stack"
+ geom_bar(position="dodge") # B
+ geom_bar(position="fill")  # C
```

O `aes()` é `aes(x="regime", fill="houve_reincidencia")` nos três.

Para cada uma das perguntas abaixo, diga qual dos três gráficos responde melhor, e por quê:

- Quantos acórdãos há em cada regime?
- A proporção de reincidentes muda conforme o regime?
- Em qual regime há mais acórdãos de reincidentes, em número absoluto?

Questão 13

Uma pesquisadora fez um gráfico de barras da classe processual dos acórdãos e mandou a imagem para a orientadora. A orientadora respondeu: “não consigo ler os nomes”.

Este é o código:

```
(
  ggplot(criminal)
  + aes(x="classe")
  + geom_bar()
)
```

As classes da base incluem Apelação Criminal, Revisão Criminal, Embargos de Declaração Criminal e Embargos Infringentes e de Nulidade.

a) Qual carta falta nesse gráfico, e por que ela é necessária aqui e não era no gráfico por regime?

b) A base tem 475 acórdãos, e 441 deles são apelações. Comente o que esse gráfico vai mostrar, e o que isso significa para quem quer estudar a Câmara.

PARTE 3

Duas variáveis

Questão 14 ★

Na aula 6 a frase foi: **o par de tipos escolhe a geometria**. Para cada par abaixo, diga qual geometria usar e qual pergunta ela responde.

as duas variáveis	a geometria	a pergunta que ela responde
duas numéricas		
uma numérica e uma categórica		
duas categóricas		
uma numérica e o tempo		

Questão 15

Este boxplot compara a pena, em anos, entre os três regimes iniciais. Os números são reais:

regime	mediana	média	acórdãos
aberto	1,42	2,08	54
semiaberto	3,08	3,72	55
fechado	5,83	6,36	88

a) Nos três regimes a média é maior que a mediana. O que isso diz sobre a forma da distribuição das penas?

b) Um colega propõe trocar o boxplot por um gráfico de barras com a pena média de cada regime, "que fica mais limpo". O que se perde nessa troca?

Questão 16 ★

Um grupo quer saber se ementas mais longas correspondem a penas maiores, e fez uma nuvem de pontos com o número de palavras da ementa no eixo x e a pena no eixo y. Cada ponto é um acórdão.

O gráfico saiu com uma mancha densa perto da origem e alguns pontos espalhados para a direita e para cima. A nuvem sobe um pouco da esquerda para a direita, mas com muita dispersão.

a) O primeiro gráfico que eles fizeram tinha os pontos totalmente opacos, e no meio da mancha não se distinguia nada. Que ajuste resolve isso, e por que ele funciona?

b) Eles acrescentaram uma reta de tendência com `geom_smooth(method="lm")` e ela subiu. Escreva uma frase que descreva corretamente o que o gráfico mostra, e uma frase que seria uma leitura exagerada dele.

Questão 17

Um relatório de um tribunal traz o seguinte gráfico e a seguinte conclusão:

Nuvem de pontos com uma vara em cada ponto. No eixo x, o número de servidores da vara. No eixo y, o tempo médio de tramitação dos processos daquela vara. A reta de tendência sobe.

Conclusão do relatório: contratar mais servidores aumenta o tempo de tramitação. Recomenda-se congelar as contratações.

Explique, em dois ou três parágrafos, por que essa conclusão não se sustenta. Sua resposta deve mencionar pelo menos uma explicação alternativa concreta para o mesmo gráfico.

Questão 18

Uma equipe acompanha a proporção de recursos negados ao longo dos anos, separando os casos em que o Ministério Público está no polo ativo dos casos em que está no polo passivo. O gráfico tem uma linha para cada polo.

```
(  
  ggplot(resumo)  
  + aes(x="ano", y="prop_negados", color="polo_mp")  
  + geom_line()  
  + geom_point()  
)
```

a) Por que o `color` está dentro do `aes()` aqui, e o que aconteceria com o gráfico se ele fosse retirado do `aes()` e passado para dentro do `geom_line()`?

b) Por que vale acrescentar o `geom_point()` a um gráfico que já tem linha?

Questão 19

Duas formas de olhar a mesma coluna numérica:

```
# A  
ggplot(penas) + aes(x="pena_anos") + geom_histogram(bins=20)
```

```
# B  
ggplot(penas) + aes(x="regime", y="pena_anos") + geom_boxplot()
```

a) O que o A mostra que o B não mostra?

b) O que o B faz que o A não faz?

c) Uma aluna rodou o A com `bins=3` e depois com `bins=100` e ficou confusa com a diferença. Como você explicaria a ela o que escolher?

PARTE 4

Preparar a tabela e ler o gráfico

Questão 20 ★

Uma pesquisadora quer comparar a capital com o interior. A base tem uma coluna comarca, com o nome da comarca de cada acórdão, e não tem nenhuma coluna que diga "capital" ou "interior".

```
(
    criminal
    .assign(eh_capital=criminal["comarca"] == "São Paulo")
    .dropna(subset=["pena_anos"])
    .groupby("eh_capital")
    .agg(
        n=("processo", "size"),
        pena_mediana=("pena_anos", "median"),
    )
    .reset_index()
)
```

	eh_capital	n	pena_mediana
0	False	161	4.166667
1	True	55	4.666667

- a) Explique o que o `.assign()` faz aqui, e por que ele não pode vir depois do `.groupby("eh_capital")`.
- b) O `.dropna(subset=["pena_anos"])` e o `.assign()` podem trocar de lugar sem mudar o resultado? Justifique.
- c) Olhando a saída, o que você responderia à pergunta "a capital julga diferente do interior"?

Questão 21

Este código roda sobre a base de acórdãos criminais, e os números da saída são reais:

```
(
    penas
    .groupby("regime", as_index=False, observed=True)
    .agg(prop_reincidencia=("houve_reincidencia", "mean"))
)
```

	regime	prop_reincidencia
0	aberto	0.074074
1	semiaberto	0.418182
2	fechado	0.511364

A coluna `houve_reincidencia` só tem os valores `True` e `False`.

- a) Explique por que a **média** de uma coluna de verdadeiro e falso é a proporção de verdadeiros.
- b) Escreva, em uma frase, o que a saída diz.
- c) Um colega olhou os números e escreveu: "o regime fechado leva o réu à reincidência". Comente.

Questão 22 ★

Continuando a questão anterior, a pesquisadora fez o gráfico da tabela `resumo_regime`, que tem três linhas e duas colunas (`regime` e `prop_reincidencia`):

```
(
  ggplot(resumo_regime)
  + aes(x="regime", y="prop_reincidencia")
  + geom_bar()
)
```

O gráfico saiu com **três barras de mesma altura**, todas no valor 1, e ela achou que tinha corrompido a tabela.

- a) Explique o que aconteceu.
- b) Escreva a correção.
- c) Por que esse erro é mais difícil de encontrar do que um erro de sintaxe?

Questão 23

Uma aluna quer que as barras apareçam em ordem decrescente de valor, e escreve:

```
resumo = (
  penas
  .groupby("comarca", as_index=False)
  .agg(pena_mediana=("pena_anos", "median"))
  .sort_values("pena_mediana", ascending=False)
)

(
  ggplot(resumo)
  + aes(x="comarca", y="pena_mediana")
  + geom_col()
  + coord_flip()
)
```

As barras saem em ordem alfabética, e não em ordem de pena.

- a) Explique por que ordenar a tabela não ordenou as barras.
- b) Escreva a correção.
- c) Depois de corrigir, ela viu que algumas comarcas com pena mediana altíssima apareciam no topo. Ao conferir, descobriu que essas comarcas tinham um ou dois acórdãos só. Que operação está faltando no pipeline, e por quê?

Questão 24 ★

Esta questão fecha a lista. Um grupo apresentou o gráfico abaixo em sala:

Barras deitadas, uma por assunto criminal, mostrando a proporção de recursos integralmente negados em cada assunto, ordenadas da maior para a menor. Os assuntos com menos de 40 recursos foram descartados, e sobraram nove. A maior proporção é 0,64 e a menor é 0,44.

E escreveram a seguinte conclusão:

A Câmara é mais dura com crimes patrimoniais: a proporção de negativas é maior nesses assuntos. Isso mostra um viés dos desembargadores contra réus de crimes contra o patrimônio.

Escreva uma avaliação dessa conclusão, em três parágrafos, respondendo:

- a)** O que o gráfico efetivamente permite afirmar?
- b)** Que decisões de quem fez o gráfico afetam a leitura, e como elas deveriam ser declaradas?
- c)** O que faltaria para sustentar a palavra “viés”?