Lista 6

Regressão múltipla, regressão logística e métricas

Conteúdo Aulas 19 a 21 · treino para o Projeto 6
Turma 4A · 2026/2
Professor Julio Trecenti
Versão Sem respostas.

POR ONDE COMEÇAR

As questões marcadas com uma estrela vermelha são o caminho mínimo: são nove de catorze, e juntas cobrem uma vez cada conceito. A parte 1 é a regressão linear múltipla (aulas 19 e 20), a parte 2 é a regressão logística (aula 20), a parte 3 são as métricas e o ponto de corte (aula 21), e a parte 4 é o Projeto 6 em miniatura: ler o modelo, escolher o corte e dizer o que as métricas não mostram.

Ninguém precisa escrever código. As saídas que aparecem aqui têm o mesmo formato das que o app do Projeto 6 mostra, e todas as bases são inventadas. Uma calculadora ajuda nas questões 4, 6, 8 e 10.

PARTE 1

Regressão linear múltipla

Questão 1 ★

O Código Civil manda fixar os alimentos "na proporção das necessidades do reclamante e dos recursos da pessoa obrigada" (art. 1.694, § 1º). Uma Defensoria sorteou 150 sentenças de alimentos de uma comarca e relacionou a pensão fixada (`pensao`, em R$ mil por mês) com a renda comprovada do alimentante (`renda`, em R$ mil por mês), o número de filhos que recebem a pensão (`filhos`) e se o alimentando foi assistido pela Defensoria (`defensoria`, 1 se sim):

```
modelo = smf.ols("pensao ~ renda + filhos + defensoria", data=alimentos).fit()
print(modelo.summary())
```

```
                            OLS Regression Results   (saída cortada)
==============================================================================
Dep. Variable:                  pensao   R-squared:                       0.684
Model:                            OLS   Adj. R-squared:                  0.678
No. Observations:                 150   F-statistic:                     105.4
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept      0.0400      0.128      0.313      0.755      -0.213       0.293
renda          0.1445      0.009     15.803      0.000       0.126       0.163
filhos         0.3292      0.049      6.748      0.000       0.233       0.426
defensoria     0.0192      0.076      0.254      0.800      -0.130       0.169
==============================================================================
```

a) Interprete o coeficiente de `renda`.

b) Interprete o coeficiente de `filhos`.

c) O que a saída permite concluir sobre `defensoria`?

d) Qual é a pensão média prevista para um alimentante com renda de R$ 6 mil por mês, dois filhos, sem Defensoria?

e) O que significa o R^2 de 0,684?

Questão 2 ★

Um escritório estudou 240 sentenças de indenização por **negativação indevida** (inscrição do nome em cadastro de inadimplentes por dívida inexistente), metade de juizados especiais e metade de varas cíveis. A indenização (`indenizacao`) e o valor pedido na inicial (`valor_pedido`) estão em R$ mil. Primeiro, só o juizado:

```
                coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept      6.4520      0.211     30.508      0.000       6.035       6.869
juizado       -2.9242      0.283    -10.332      0.000      -3.482      -2.367
R-squared: 0.310
```

Depois, com o valor pedido:

```
                  coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept        0.8758      0.352      2.490      0.013       0.183       1.569
juizado          0.1670      0.260      0.643      0.521      -0.345       0.679
valor_pedido     0.1146      0.007     17.301      0.000       0.102       0.128
R-squared: 0.695
```

E as médias por grupo:

```
         valor_pedido  indenizacao
juizado
0               48.64         6.45
1               21.68         3.53
```

a) Interprete o coeficiente associado a `juizado` no primeiro modelo. Confira com a tabela de médias.

b) Interprete o coeficiente associado a `juizado` no segundo modelo.

c) Explique por que os coeficientes de `juizado` do primeiro e do segundo modelo são diferentes. Use a tabela de médias.

Questão 3 ★

Indenizações por atraso de voo (`indenizacao`, em R$ mil) contra três companhias aéreas fictícias (Aerovia, Brisa e Celeste), em 250 sentenças:

```
modelo = smf.ols("indenizacao ~ C(companhia)", data=voos).fit()
```

```
                          coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------------------
Intercept                4.3292      0.153     28.246      0.000       4.027       4.631
C(companhia)[T.Brisa]    1.2044      0.236      5.099      0.000       0.739       1.670
C(companhia)[T.Celeste] -0.1145      0.258     -0.444      0.658      -0.623       0.394
R-squared: 0.117
```

a) Quantas colunas de 0 e 1 (dummies) o modelo criou para a variável `companhia`? Por que não três? Qual companhia ficou como referência?

b) Qual é a indenização média de cada companhia?

c) A Brisa difere da Aerovia? E a Celeste?

d) Se a referência fosse a Brisa, qual seria o intercepto, e qual seria o coeficiente da Celeste?

Questão 4

Outro levantamento de atraso de voo, agora sem olhar a companhia. Em 200 sentenças, a indenização (`indenizacao`, em R$ mil) foi relacionada às horas de atraso (`horas_atraso`) e à idade do passageiro (`idade`, em anos). Só entraram atrasos de 4 horas ou mais, porque abaixo disso quase não há condenação:

```
                  coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept       -0.6892      0.327     -2.109      0.036      -1.334      -0.045
horas_atraso     0.3035      0.012     25.605      0.000       0.280       0.327
idade            0.0269      0.005      5.207      0.000       0.017       0.037
R-squared: 0.780
```

E o resumo das duas explicativas:

```
      horas_atraso  idade
min            4.0   18.0
mean          17.1   48.8
max           29.8   80.0
```

a) Interprete o coeficiente de `horas_atraso`.

b) Leia o intercepto ao pé da letra: a que perfil de processo ele corresponde, e qual seria a indenização prevista para esse perfil?

c) Essa leitura faz sentido? Use o resumo das explicativas para dizer se o intercepto descreve algum processo da base ou se é uma extrapolação dos dados.

d) Qual é a indenização prevista para o menor atraso e o passageiro mais novo da base (4 horas e 18 anos)? Compare com o intercepto.

Questão 5

Certo ou errado? Justifique em uma ou duas linhas.

a) Na questão 1, como o coeficiente de `defensoria` tem valor-p de 0,80, ficou provado que a assistência da Defensoria não muda a pensão.

b) Um valor-p muito pequeno quer dizer que a variável explica grande parte da variação da variável resposta.

c) Acrescentar uma variável ao modelo pode mudar o coeficiente das variáveis que já estavam nele.

d) “Mantidas as demais” quer dizer que o pesquisador manteve as outras variáveis fixas ao coletar os dados.

PARTE 2

Regressão logística

Questão 6 ★

Chance é a probabilidade de acontecer dividida pela de não acontecer: $\text{chance} = p/(1-p)$. A volta é $p = \text{chance}\ /(1+\text{chance})$.

A chance é o jeito de falar das apostas. Chance de **5** quer dizer "5 para 1": para cada vez em que o evento não acontece, ele acontece 5 vezes. São 5 em cada 6 casos, e a probabilidade é $5/6 \approx 83\%$. Chance de **1** é "1 para 1", meio a meio (50%). Chance de **0,25** é "1 para 4": acontece 1 vez para cada 4 em que não acontece, ou 1 em cada 5 casos (20%). Chance acima de 1 quer dizer probabilidade acima de 50%, e chance abaixo de 1, probabilidade abaixo de 50%.

a) Complete a tabela.

probabilidade	chance	chance	probabilidade
50%		1	
75%		4	
20%		0,25	
5%		0,5	

b) Num tribunal, 400 apelações em ações de consumo foram julgadas no ano. Pelo advogado do apelante:

advogado do apelante	provido	negado
Defensoria	60	90
particular	80	170

Calcule a probabilidade e a chance de provimento em cada grupo e a razão de chances (Defensoria dividida por particular).

c) Um jornal publica: "recurso da Defensoria tem 42% mais probabilidade de ser provido". Está certo?

Questão 7 ★

Outro levantamento do mesmo tribunal, com 800 apelações em ações de consumo de vários anos, rodou a regressão logística de `provido` (1 se o recurso foi provido) usando: `defensoria` (1 se o apelante é assistido pela Defensoria), `pericia` (1 se houve perícia em primeiro grau), `juiz_substituto` (1 se a sentença foi de juiz substituto) e `valor_causa` (em R$ mil).

```
logit = smf.logit("provido ~ defensoria + pericia + juiz_substituto + valor_causa",
                  data=apelacoes).fit()
print(logit.summary())
razoes = np.exp(pd.concat([logit.params, logit.conf_int()], axis=1))
```

```
                           Logit Regression Results   (saída cortada)
==============================================================================
                     coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept          -1.2021      0.180     -6.681      0.000      -1.555      -0.849
defensoria          0.6071      0.164      3.696      0.000       0.285       0.929
```

```
pericia              0.8886      0.166      5.356      0.000       0.563       1.214
juiz_substituto      0.0329      0.164      0.200      0.841      -0.289       0.355
valor_causa         -0.0086      0.004     -2.121      0.034      -0.016      -0.001
==============================================================================

                 razao_chances   2.5%  97.5%
Intercept                0.301  0.211  0.428
defensoria               1.835  1.330  2.532
pericia                  2.432  1.757  3.366
juiz_substituto          1.033  0.749  1.426
valor_causa              0.991  0.984  0.999
```

a) De onde sai o 1,835 da segunda tabela? Faça a interpretação da razão de chances de `defensoria`.

b) A razão de chances de `defensoria` aqui (1,84) é maior que a da tabela da questão 6 (1,42). Como isso pode acontecer?

c) Interprete `valor_causa`. O coeficiente é negativo: o que isso diz?

Questão 8

Use os coeficientes da questão 7.

a) Calcule a probabilidade prevista de provimento para uma apelação da Defensoria, com perícia, sentença de juiz titular e valor da causa de R$ 20 mil. Passe pelo log da chance, depois pela chance, depois pela probabilidade.

b) Suponha que, em outra base, uma regressão **linear** de `provido` tivesse previsto probabilidade de 1,08 para alguns perfis de apelação. O que há de errado com esse número, e por que a logística não tem esse problema?

Questão 9

Certo ou errado? Justifique em uma ou duas linhas.

a) Razão de chances igual a 2 quer dizer que a probabilidade dobra.

b) Um coeficiente negativo na saída da logística corresponde a uma razão de chances menor que 1.

c) Se o intervalo de 95% da razão de chances vai de 0,75 a 1,43, não há evidência de associação.

d) O coeficiente da logística diz em quantos pontos percentuais a probabilidade aumenta quando a variável aumenta uma unidade.

PARTE 3

Matriz de confusão e métricas

Questão 10 ★

Um tribunal usa um modelo que sinaliza petições iniciais com indício de **litigância predatória** (ações em massa, com procurações genéricas e documentos repetidos) para revisão por um servidor antes do despacho. Num mês, 2.000 petições passaram pelo modelo, e uma auditoria posterior verificou quais eram de fato predatórias:

	era predatória	não era
sinalizada pelo modelo	84	156
não sinalizada	36	1.724

a) Identifique os verdadeiros positivos, os falsos positivos, os falsos negativos e os verdadeiros negativos, e diga o que cada um é **neste caso**.

b) Calcule a acurácia, a precisão, a sensibilidade (recall) e a especificidade.

c) Traduza a precisão e a sensibilidade em uma frase cada, para o juiz corregedor.

d) Quantas petições eram predatórias? Qual seria a acurácia de um modelo que nunca sinaliza nada?

Questão 11 ★

Uma procuradoria testou um modelo que alerta para execuções fiscais com risco de **prescrição intercorrente** nos próximos seis meses, para priorizar diligências. Em 1.000 execuções, 30 de fato prescreveriam. O modelo alertou 54, das quais 18 eram de risco. A empresa que vendeu o modelo anuncia "95,2% de acerto".

a) Monte a matriz de confusão e confira os 95,2%.

b) Compare com um modelo trivial que nunca alerta. Qual tem acurácia maior?

c) Calcule a sensibilidade e a precisão do modelo, e diga, para o procurador chefe, o que elas significam.

d) Que métrica deveria constar do anúncio, e por quê?

Questão 12 ★

O modelo da questão 10 devolve, para cada petição, a **probabilidade** de ser predatória. Petições com probabilidade igual ou acima do **corte** são sinalizadas. Num mês com 2.000 petições (143 predatórias), a tabela mostra o resultado de seis cortes:

```
corte  VP   FP  FN   VN  sinalizadas  precisao  sensibilidade
 0.05 139 1259   4  598         1398     0.099          0.972
 0.10 132  730  11 1127          862     0.153          0.923
 0.20 112  256  31 1601          368     0.304          0.783
 0.30  84   93  59 1764          177     0.475          0.587
 0.40  63   27  80 1830           90     0.700          0.441
 0.50  43    8 100 1849           51     0.843          0.301
```

a) O que acontece com a precisão e com a sensibilidade quando o corte sobe? Por quê?

b) A equipe consegue revisar **200 petições por mês**. Qual é o menor corte da tabela que cabe nessa capacidade? Quantas predatórias passam sem revisão nele?

c) Um assessor sugere o corte de 0,05, "para não deixar passar quase nenhuma". O que acontece com a equipe?

d) Por que 0,50 não é um corte "natural" aqui?

Questão 13

Responda em poucas linhas.

a) Num modelo que decide quais pedidos de **liminar em saúde** vão para a análise urgente de um plantão médico, qual erro é mais grave, o falso positivo ou o falso negativo? Que métrica você acompanharia?

b) Num modelo que **suspende automaticamente** o processamento de petições suspeitas de litigância predatória até a parte apresentar documentos, qual erro é mais grave? Que métrica você acompanharia?

c) Nos dois casos, cite uma coisa importante para a decisão que a matriz de confusão não registra.

PARTE 4

O Projeto 6 em miniatura

Questão 14 ★

Numa procuradoria municipal, a maior parte das execuções fiscais não acha bens para penhorar, e cada busca de bens (diligência com oficial de justiça, pesquisa em cartórios e sistemas) custa horas de trabalho. A procuradoria consegue fazer **300 buscas por mês**. Um modelo de regressão logística, ajustado em 3.000 execuções antigas, estima a probabilidade de uma execução nova **localizar bens** (`bens` = 1), a partir de quatro características:

	razao_chances	2.5%	97.5%	P>|z|
Intercept	0.067	0.054	0.084	0.000
empresa_ativa	3.405	2.807	4.129	0.000
imovel_registrado	4.207	3.458	5.118	0.000
citado_pessoalmente	2.020	1.670	2.445	0.000
regiao_capital	0.847	0.698	1.027	0.091

Nas 1.000 execuções novas do mês (208 delas, como se soube depois, tinham bens), os cortes dão:

corte	VP	FP	FN	VN	sinalizadas	precisao	sensibilidade
0.10	198	605	10	187	803	0.247	0.952
0.15	180	425	28	367	605	0.298	0.865
0.20	134	247	74	545	381	0.352	0.644
0.30	105	174	103	618	279	0.376	0.505
0.40	53	61	155	731	114	0.465	0.255
0.50	22	28	186	764	50	0.440	0.106

a) Interprete a razão de chances de `imovel_registrado` e diga o que a saída permite concluir sobre `regiao_capital`.

b) Escolha um corte da tabela, respeitando a capacidade de 300 buscas, e descreva o que ele produz: buscas feitas, buscas sem resultado, execuções com bens que ficam sem busca, precisão e sensibilidade.

c) Qual erro é mais caro para a procuradoria: buscar onde não há bens, ou não buscar onde há? Use a resposta para defender o seu corte.

d) Nomeie uma coisa que essas métricas não mostram e que importa para a decisão.