# Lista 7

Machine learning: sobreajuste, validação, métricas, árvores e florestas

**Conteúdo** Aulas 20 a 24 · treino para os Projetos 7 e 8
**Turma** 4A · 2026/2
**Professor** Julio Trecenti
**Versão** **Com respostas comentadas. Não distribuir antes do prazo.**

POR ONDE COMEÇAR

São dez questões: seis dissertativas e quatro de marcar a correta ou de verdadeiro ou falso. Juntas, cobrem sobreajuste, validação cruzada, o `C` da regressão logística, as medidas de erro, o ponto de corte, a escolha da métrica, árvores, florestas e vazamento.

Ninguém precisa escrever código: o foco é **ler os resultados e decidir**. Uma calculadora ajuda na questão 3. A lista é treino para os **Projetos 07 e 08**.

As questões com uma estrela vermelha são o caminho mínimo: são seis de dez, e juntas passam por sobreajuste, escolha do `C`, ponto de corte, escolha da métrica, árvores e vazamento.

PARTE 1

## Questões dissertativas

### Questão 1 ★

FÁCIL

Um escritório quer prever se as suas ações de indenização contra companhias aéreas serão procedentes. Tem um histórico de 400 processos, julgados em 120 varas diferentes, e ajustou duas regressões logísticas: uma com a vara como variável e outra sem. Depois testou as duas em 150 processos novos, que não entraram no ajuste:

| modelo | acerto no histórico | acerto nos novos |
|---|---|---|
| com a vara | 93% | 64% |
| sem a vara | 79% | 77% |

**a)** O que aconteceu com o modelo com a vara? Dê o nome do fenômeno.

**b)** Por que uma variável com 120 categorias, em 400 processos, facilita esse problema?

**c)** Se o escritório tivesse olhado só o acerto no histórico, que decisão teria tomado? O que isso ensina sobre como avaliar um modelo de previsão?

**d)** Cite uma forma de manter a informação da vara sem cair no mesmo problema.

RESPOSTA

**a) Sobreajuste**: o modelo com a vara acerta muito o histórico (93%) e pouco os processos novos (64%), menos até que o modelo sem a vara (77%). Ele decorou o histórico, inclusive o acaso.

**b)** São pouco mais de 3 processos por vara, em média. Com tão poucos casos, o coeficiente de cada vara aprende o resultado daqueles 3 processos, que pode ser puro acaso (como no juiz com um processo só, da aula 22). O modelo ganha muitos coeficientes para se ajustar ao histórico e pouca informação para cada um.

**c)** Teria escolhido o modelo com a vara, que acerta 93% no histórico, e errado mais nos processos de verdade. Um modelo de previsão se avalia em **casos que ele não viu**: num teste guardado ou por validação cruzada, nunca nos dados do ajuste.

**d)** A **regularização**: uma penalidade (o `C` da regressão logística) que encolhe os coeficientes das varas com poucos processos para perto da média, escolhida por validação cruzada. Também valeria agrupar as varas raras numa categoria só, ou usar uma característica da vara (por exemplo, a região) em vez da vara.

## Questão 2 ★

MÉDIO

Uma base reúne cerca de 6 mil acórdãos de recursos criminais do TJSP, de 2016 a 2023. Para cada acórdão, há o assunto do recurso (roubo, furto, tráfico etc.), a câmara que julgou, a comarca de origem, se quem recorreu foi o Ministério Público, o tempo até o julgamento e algumas características de quem relatou. A pergunta é se a decisão terá voto divergente, ou seja, se será por maioria. A divergência é rara: acontece em cerca de 2% dos acórdãos.

Uma regressão logística foi ajustada com vários valores de `C`. A tabela traz, para cada `C`, a AUC no próprio treino e a AUC média na validação cruzada (5 partes):

| C | 0,003 | 0,01 | 0,03 | 0,1 | 0,3 | 1 | 10 | 100 | 10.000 |
|---|---|---|---|---|---|---|---|---|---|
| treino | 0,66 | 0,69 | 0,73 | 0,78 | 0,83 | 0,86 | 0,90 | 0,91 | 0,92 |
| validação | 0,62 | 0,64 | 0,66 | 0,69 | 0,70 | 0,70 | 0,68 | 0,65 | 0,63 |

**a)** Qual `C` você escolheria? Lembre-se: `C` menor quer dizer penalidade maior.

**b)** Explique o que acontece à direita da tabela (`C` grande) e à esquerda (`C` muito pequeno), usando as palavras sobreajuste e subajuste.

**c)** Com `C = 10.000`, a distância entre treino e validação é de quase 0,3; com `C = 0,003`, é pequena. A distância pequena quer dizer que o modelo de `C = 0,003` é o melhor? Explique.

**d)** `C = 0,3` e `C = 1` empatam na validação, com AUC de 0,70. No treino, o de `C = 1` vai melhor (0,86 contra 0,83). Qual dos dois você escolheria, e por quê?

RESPOSTA

**a)** `C = 0,3` (ou `C = 1`), com AUC de 0,70 na validação, a maior da tabela.

**b)** À direita, a penalidade é quase nula: o modelo usa as centenas de dummies (comarcas, câmaras) para decorar o treino. O treino sobe até 0,92 enquanto a validação cai para 0,63: **sobreajuste**. À esquerda, a penalidade é tão forte que os coeficientes ficam perto de zero: o modelo quase não aprende, e vai mal no treino (0,66) e na validação (0,62): **subajuste**.

**c)** Não. Uma distância pequena só diz que o modelo não decorou; ele pode ser ruim nos dois lugares, como aqui. O que escolhe o modelo é a **AUC na validação**, e ela é menor com `C = 0,003` (0,62) do que com `C = 0,3` (0,70).

**d)** `C = 0,3`. Na validação, que é o que conta, os dois empatam. A vantagem do `C = 1` no treino não é um argumento a favor dele: é só sinal de que ele se ajusta mais aos dados que já viu. No empate, prefere-se o modelo mais simples, com mais penalidade, que tende a variar menos em casos novos.

## Questão 3

FÁCIL

Um modelo prevê a procedência de ações de consumo contra um banco. Com corte 0,5 (processos com probabilidade de pelo menos 0,5 são marcados como procedentes), em 1.000 processos de validação:

| | marcado | não marcado |
|---|---|---|
| procedente | 210 | 90 |
| improcedente | 140 | 560 |

**a)** Calcule a sensibilidade, a especificidade, a 1 – especificidade e a precisão. Escreva o que cada uma quer dizer neste caso, em uma frase.

**b)** Imagine o mesmo modelo numa carteira com o dobro de improcedentes (300 procedentes e 1.400 improcedentes, com as mesmas proporções em cada linha). Quais das quatro medidas mudam? Calcule as que mudam.

**c)** Use o item b para explicar por que a curva ROC e a AUC são feitas com sensibilidade e 1 – especificidade, e não com a precisão.

RESPOSTA

**a)** Sensibilidade: $210/300 = 70\%$, dos processos procedentes, o modelo marca 70%. Especificidade: $560/700 = 80\%$, dos improcedentes, o modelo deixa de fora 80%. 1 – especificidade: $140/700 = 20\%$, dos improcedentes, o modelo marca 20% por engano. Precisão: $210/350 = 60\%$, dos processos marcados, 60% são de fato procedentes.

**b)** Na linha dos improcedentes, FP passa a 280 e VN a 1.120. A sensibilidade (70%), a especificidade (80%) e a 1 – especificidade (20%) **não mudam**: cada uma é calculada dentro de uma linha só. A precisão muda: $210/(210 + 280) = 42{,}9\%$.

**c)** A precisão mistura as duas linhas e depende de quantos procedentes há na base: o mesmo modelo, com as mesmas qualidades, tem precisão de 60% numa carteira e 43% em outra. A sensibilidade e a 1 – especificidade medem **o modelo**, e não a mistura da carteira. Por isso a curva ROC (uma contra a outra, em todos os cortes) e a AUC servem para comparar modelos em qualquer base.

## Questão 4 ★

MÉDIO

Uma regressão logística dá, para cada recurso criminal do TJSP, a probabilidade de a decisão ter voto divergente (ser por maioria). A divergência é rara: acontece em cerca de 2% dos acórdãos. Uma defensoria quer usar esse modelo para escolher em que recursos fazer sustentação oral, porque uma decisão não unânime desfavorável ao réu abre os embargos infringentes. A equipe consegue acompanhar no máximo 15% dos recursos.

A tabela mostra cinco cortes. Para cada um, a parte dos recursos que o modelo marca (e que a equipe teria de acompanhar), a sensibilidade (a parte das divergências que estão entre os marcados) e a precisão (a parte dos marcados que de fato tiveram divergência):

| corte | recursos marcados | sensibilidade | precisão |
|---|---|---|---|
| 0,01 | 72% | 94% | 3% |
| 0,02 | 37% | 62% | 4% |
| 0,03 | 20% | 44% | 5% |
| 0,04 | 12% | 34% | 6% |
| 0,05 | 8% | 23% | 6% |

**a)** Qual corte respeita a capacidade da equipe e encontra mais divergências?

**b)** Sem o modelo, a defensoria poderia sortear os recursos que vai acompanhar. Se sorteasse 12% deles (o mesmo tanto que o corte 0,04 marca), que parte das divergências esperaria encontrar entre os sorteados? Compare com a sensibilidade do corte 0,04: o modelo ajuda?

**c)** A precisão nunca passa de 6%. Um defensor conclui: “o modelo erra 94% das vezes, não serve”. Avalie esse argumento.

RESPOSTA

**a)** O corte de **0,04**: marca 12% dos recursos, dentro dos 15%, e encontra 34% das divergências. O de 0,03 marcaria 20%, acima da capacidade.

**b)** O sorteio não olha nada do recurso, então os 12% sorteados têm, em média, 12% das divergências: a sensibilidade esperada é de 12%. Com o modelo, os 12% marcados têm 34% das divergências, quase três vezes mais com o mesmo esforço. O modelo ajuda.

**c)** O argumento confunde precisão com utilidade. A divergência acontece em cerca de 2% dos acórdãos: mesmo um bom modelo marca muitos recursos que não terão divergência. Ao acaso, a precisão seria de 2%; o modelo triplica isso. O que importa para a defensoria é encontrar mais divergências com a capacidade que tem, e isso o modelo faz.

## Questão 5

MÉDIO

Com os mesmos acórdãos criminais do TJSP e a mesma pergunta da questão 4 (a decisão terá voto divergente?), árvores de várias profundidades foram avaliadas no treino e na validação cruzada, e comparadas com uma floresta de 300 árvores:

| modelo | AUC no treino | AUC na validação |
|---|---|---|
| árvore, profundidade = 1 | 0,57 | 0,56 |
| árvore, profundidade = 3 | 0,66 | 0,63 |
| árvore, profundidade = 5 | 0,73 | 0,69 |
| árvore, profundidade = 6 | 0,74 | 0,69 |
| árvore, profundidade = 8 | 0,77 | 0,66 |
| árvore, profundidade = 12 | 0,82 | 0,56 |
| floresta de 300 árvores | 0,99 | 0,74 |

**a)** Qual profundidade você escolheria? Por quê?

**b)** Descreva o que acontece entre a profundidade 5 e a 12.

**c)** A floresta tem AUC de 0,99 no treino. Isso é sobreajuste? Ela deve ser descartada?

**d)** Explique, sem fórmulas, por que a média de muitas árvores erra menos em casos novos do que uma árvore só.

**e)** A lista de importância da floresta põe `tempo` (anos até o julgamento) em primeiro lugar. Um jornalista escreve: "a demora causa a divergência nas câmaras". O que está errado?

RESPOSTA

**a)** A profundidade 5 (ou 6), com a maior AUC na validação, 0,69. Entre as duas, a 5 é mais simples.

**b)** O treino continua subindo (0,73 para 0,82), e a validação cai (0,69 para 0,56): a árvore passa a decorar, com folhas de poucos acórdãos. É sobreajuste.

**c)** O treino perto de 1 é normal numa floresta: cada árvore é funda e decora a sua amostra. Mas o que decide é a **validação**, e a floresta tem a maior da tabela (0,74). Ela não deve ser descartada; a distância grande não é um problema quando a validação é a melhor.

**d)** Cada árvore usa uma amostra sorteada dos acórdãos e, em cada pergunta, algumas colunas sorteadas. Por isso as árvores erram de jeitos diferentes. Na média, os erros de uma compensam os de outra, e a previsão muda menos de uma amostra para outra.

**e)** A importância mede quanto a coluna ajuda a **prever**, não o efeito dela. O tempo pode estar associado a outra coisa que importa de verdade (casos mais complexos demoram mais e também dividem mais a câmara): uma variável de confusão. Para falar em causa, seria preciso um desenho causal, não um modelo de previsão.

## Questão 6 ★

MÉDIO

Para cada situação, diga qual medida deve guiar a escolha do ponto de corte (ou do modelo) e por quê. Pense primeiro em qual erro custa mais, e para quem.

**a)** No plantão judiciário, um modelo marca as petições com pedido de tutela de urgência em saúde. As marcadas vão para o topo da fila e são lidas no mesmo dia; as demais ficam para a semana seguinte.

**b)** Um banco quer oferecer acordo, sem análise de um advogado, nas ações revisionais em que o modelo prevê condenação. Cada acordo oferecido é dinheiro que sai do caixa.

**c)** Uma equipe tem quatro modelos candidatos e ainda não sabe como o modelo escolhido será usado, nem com qual corte.

**d)** Um tribunal quer arquivar automaticamente, sem que ninguém leia, as petições que o modelo apontar como cópia de ações já julgadas entre as mesmas partes.

**e)** Uma câmara em que metade dos recursos é provida quer só saber se o modelo acerta mais do que erra. Para ela, errar para um lado custa o mesmo que errar para o outro.

RESPOSTA

**a) Sensibilidade.** O erro grave é o falso negativo: uma urgência que espera uma semana. O falso positivo só adianta a leitura de uma petição que podia esperar, e o servidor lê todas as marcadas no mesmo dia. Escolhe-se um corte baixo, que marque quase todas as urgências.

**b) Precisão.** Sem ninguém revisando, cada processo marcado vira um acordo pago. O falso positivo é pagar acordo numa ação que o banco ganharia; o falso negativo é só seguir litigando, como já acontece hoje. Escolhe-se um corte alto.

**c) AUC.** Ela compara os modelos sem depender de um corte que ainda não foi decidido. O corte se escolhe depois, com o modelo já escolhido.

**d) Precisão**, de novo, e por um motivo mais forte: o falso positivo é uma ação legítima arquivada, alguém que perde o acesso ao juiz porque o modelo errou. O falso negativo é uma petição repetida que segue o trâmite normal e será extinta pelo juiz, como já acontece hoje. O corte deve ser alto, mesmo deixando passar algumas repetidas. É o contrário do item a, porque ali cada marcada é lida por alguém.

**e) Acurácia.** Com as classes equilibradas e os dois erros com o mesmo custo, contar acertos é uma medida razoável. É a situação em que ela funciona; quando o evento é raro ou os erros pesam diferente, ela engana.

PARTE 2

# Questões de marcar

## Questão 7

FÁCIL

Marque V (verdadeiro) ou F (falso) em cada afirmação.

(  ) a) O coeficiente de uma variável numa regressão logística é um hiperparâmetro, escolhido por validação cruzada.

(  ) b) A profundidade máxima de uma árvore de decisão é um hiperparâmetro.

(  ) c) Na validação cruzada com 5 partes, cada parte serve uma vez para avaliar o modelo ajustado nas outras quatro, e a AUC de validação é a média das 5 rodadas.

(  ) d) Se uma rodada da validação cruzada deu AUC bem maior que as outras, é ela que mostra o potencial do modelo e deve ser relatada.

( ) e) O preparo (dummies e padronização) deve ser ajustado só nas partes de ajuste de cada rodada, e não na base inteira antes de dividir.

**RESPOSTA: F, V, V, F, V**

**a) Falso.** O coeficiente é um **parâmetro**: o ajuste o calcula a partir dos exemplos. O hiperparâmetro da logística é o `C`, fixado antes do ajuste.

**b) Verdadeiro.** Ela limita quantas perguntas seguidas a árvore pode fazer e é fixada antes. Já a pergunta de cada nó ("juros abaixo de 2,24%?") é parâmetro: a árvore a escolhe sozinha.

**c) Verdadeiro.** É a definição. A média das 5 rodadas é mais estável que qualquer rodada sozinha.

**d) Falso.** Escolher a melhor rodada é escolher pela sorte: ela é só a parte que calhou de ser mais fácil. O número a relatar é a média.

**e) Verdadeiro.** O preparo também é ajuste. Se ele vê a base inteira, a parte de avaliação de cada rodada deixa de ser nova. Por isso ele vai dentro do pipeline.

## Questão 8

MÉDIO

Uma empresa de tecnologia jurídica separou 20% de uma base de sentenças como teste. Para escolher o `C` da regressão logística, testou 30 valores, calculou a AUC de cada um no teste e ficou com o melhor, que deu AUC de 0,81. É esse número que aparece na proposta comercial. Seis meses depois, usando o modelo em sentenças novas, o cliente mediu AUC de 0,72. Qual explicação está correta?

(A) As sentenças novas devem ser diferentes das antigas, porque um modelo bem testado não perde 0,09 de AUC em seis meses.

(B) Trinta valores de `C` são poucos; com mais valores testados no teste, a AUC da proposta seria mais próxima da real.

(C) O modelo tem subajuste: o `C` escolhido penaliza demais, e por isso ele vai pior nas sentenças novas.

(D) A AUC de 0,72 é a menos confiável das duas, porque foi medida pelo cliente numa base que a empresa não controlou.

(E) **O teste foi usado para escolher o `C`, e o melhor de 30 tentativas no teste carrega sorte.**

**RESPOSTA: E**

O teste foi usado para **escolher**, e deixou de ser um teste: o melhor dos 30 valores no teste é, em parte, o que deu mais sorte naquelas sentenças. Em sentenças novas a sorte não se repete, e a AUC cai. O certo é escolher o `C` por validação cruzada no treino e abrir o teste uma vez, no fim: esse número é a estimativa honesta para a proposta.

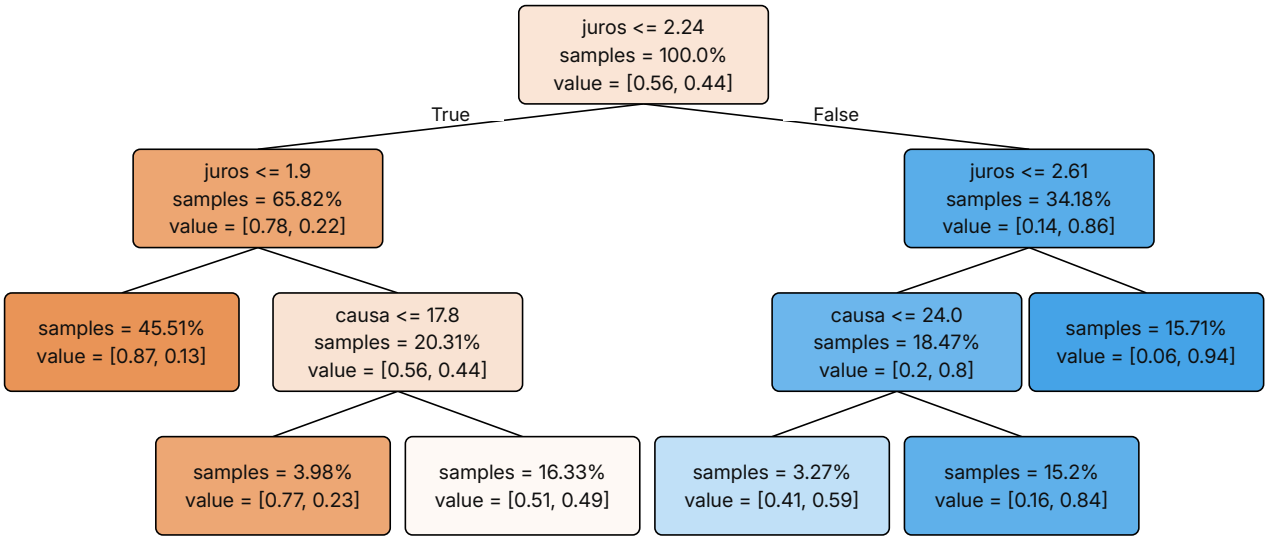
- **A** pode acontecer na vida real, mas aqui há uma explicação que já basta, e é ela que o enunciado descreve.
- **B** inverte o efeito: quanto mais tentativas no mesmo teste, mais otimista fica o melhor número.
- **C** não tem apoio nos dados: nada indica que o `C` escolhido penalize demais.
- **D** desconfia do número honesto. O 0,72 foi medido em sentenças que não participaram de nenhuma escolha.

## Questão 9 ★

FÁCIL

Uma árvore de decisão prevê se a sentença numa ação revisional de financiamento será favorável ao autor, com duas colunas: `juros`, a taxa do contrato (% ao mês), e `causa`, o valor da causa (R$ mil). O desenho abaixo é o que sai do `plot_tree` do scikit-learn, como na aula 24. Em cada caixa, a primeira linha é a pergunta (quem responde sim vai para a esquerda, `True`); `samples` é a proporção dos processos do

treino que chegaram ali; e `value` traz duas proporções: a de sentenças desfavoráveis e a de favoráveis ao autor. As caixas sem pergunta são as folhas.




Um contrato tem juros de 2,0% ao mês, e a causa vale R$ 40 mil. Qual é a probabilidade de sentença favorável ao autor prevista pela árvore?

(A) 13%

(B) 23%

(C) **49%**

(D) 51%

(E) 44%

**RESPOSTA: C**

Juros de 2,0 são menores ou iguais a 2,24: `True`, esquerda. Não são menores ou iguais a 1,9: direita. A causa de 40 não é menor ou igual a 17,8: direita. O processo cai na folha com `value = [0.51, 0.49]`, e a probabilidade de sentença favorável é a segunda proporção, **49%**.

- **A** (13%) erra a segunda pergunta, como se os juros estivessem abaixo de 1,9.
- **B** (23%) erra a última pergunta, como se a causa fosse menor que R$ 17,8 mil.
- **D** (51%) chega à folha certa e lê a proporção errada: 51% é a de sentenças desfavoráveis.
- **E** (44%) para na raiz: é a proporção de favoráveis em todo o treino, antes de qualquer pergunta.

Vale notar que o valor da causa só é olhado para juros entre 1,9 e 2,61: abaixo ou acima disso, só os juros decidem. É uma **interação** (o efeito da causa depende dos juros), que a árvore encontra sozinha; numa regressão logística, alguém teria de incluí-la no modelo.

## Questão 10 ★

MÉDIO

Uma procuradoria quer prever, no dia da distribuição, se uma execução fiscal será extinta por prescrição. Marque V se a variável pode entrar no modelo e F se não pode.

( ) a) O valor da dívida.

( ) b) O tipo de tributo.

( ) c) A data da última citação do executado.

( ) d) O número de execuções anteriores à distribuição contra o mesmo executado.

( ) e) A data do arquivamento definitivo do processo.

**RESPOSTA: V, V, F, V, F**
A pergunta para cada coluna é: **no dia em que vou prever, eu já sei isto?**

**a) e b) Verdadeiro.** O valor da dívida e o tipo de tributo são conhecidos na distribuição.

**c) Falso.** A citação acontece depois da distribuição, e a data da última citação só se conhece com o processo andando (ou terminado). É vazamento.

**d) Verdadeiro**, porque conta só as execuções anteriores. Contar as posteriores seria vazamento.

**e) Falso.** O arquivamento definitivo vem depois do desfecho, e praticamente carrega a resposta. É o exemplo clássico de vazamento: com colunas assim, o modelo teria uma AUC quase perfeita na validação cruzada e seria inútil na distribuição, quando essas datas não existem.