Lista 7

Machine learning: sobreajuste, validação, métricas, árvores e florestas

Conteúdo Aulas 20 a 24 · treino para os Projetos 7 e 8
Turma 4A · 2026/2
Professor Julio Trecenti
Versão Sem respostas.

POR ONDE COMEÇAR

São dez questões: seis dissertativas e quatro de marcar a correta ou de verdadeiro ou falso. Juntas, cobrem sobreajuste, validação cruzada, o `C` da regressão logística, as medidas de erro, o ponto de corte, a escolha da métrica, árvores, florestas e vazamento.

Ninguém precisa escrever código: o foco é **ler os resultados e decidir**. Uma calculadora ajuda na questão 3. A lista é treino para os **Projetos 07 e 08**.

As questões com uma estrela vermelha são o caminho mínimo: são seis de dez, e juntas passam por sobreajuste, escolha do `C`, ponto de corte, escolha da métrica, árvores e vazamento.

PARTE 1

Questões dissertativas

Questão 1 ★

Um escritório quer prever se as suas ações de indenização contra companhias aéreas serão procedentes. Tem um histórico de 400 processos, julgados em 120 varas diferentes, e ajustou duas regressões logísticas: uma com a vara como variável e outra sem. Depois testou as duas em 150 processos novos, que não entraram no ajuste:

modelo	acerto no histórico	acerto nos novos
com a vara	93%	64%
sem a vara	79%	77%

a) O que aconteceu com o modelo com a vara? Dê o nome do fenômeno.

b) Por que uma variável com 120 categorias, em 400 processos, facilita esse problema?

c) Se o escritório tivesse olhado só o acerto no histórico, que decisão teria tomado? O que isso ensina sobre como avaliar um modelo de previsão?

d) Cite uma forma de manter a informação da vara sem cair no mesmo problema.

Questão 2 ★

Uma base reúne cerca de 6 mil acórdãos de recursos criminais do TJSP, de 2016 a 2023. Para cada acórdão, há o assunto do recurso (roubo, furto, tráfico etc.), a câmara que julgou, a comarca de origem, se quem recorreu foi o Ministério Público, o tempo até o julgamento e algumas características de quem relatou. A pergunta é se a decisão terá voto divergente, ou seja, se será por maioria. A divergência é rara: acontece em cerca de 2% dos acórdãos.

Uma regressão logística foi ajustada com vários valores de `C`. A tabela traz, para cada `C`, a AUC no próprio treino e a AUC média na validação cruzada (5 partes):

C	0,003	0,01	0,03	0,1	0,3	1	10	100	10.000
treino	0,66	0,69	0,73	0,78	0,83	0,86	0,90	0,91	0,92
validação	0,62	0,64	0,66	0,69	0,70	0,70	0,68	0,65	0,63

a) Qual `C` você escolheria? Lembre-se: `C` menor quer dizer penalidade maior.

b) Explique o que acontece à direita da tabela (`C` grande) e à esquerda (`C` muito pequeno), usando as palavras sobreajuste e subajuste.

c) Com `C = 10.000`, a distância entre treino e validação é de quase 0,3; com `C = 0,003`, é pequena. A distância pequena quer dizer que o modelo de `C = 0,003` é o melhor? Explique.

d) `C = 0,3` e `C = 1` empatam na validação, com AUC de 0,70. No treino, o de `C = 1` vai melhor (0,86 contra 0,83). Qual dos dois você escolheria, e por quê?

Questão 3

Um modelo prevê a procedência de ações de consumo contra um banco. Com corte 0,5 (processos com probabilidade de pelo menos 0,5 são marcados como procedentes), em 1.000 processos de validação:

	marcado	não marcado
procedente	210	90
improcedente	140	560

a) Calcule a sensibilidade, a especificidade, a 1 – especificidade e a precisão. Escreva o que cada uma quer dizer neste caso, em uma frase.

b) Imagine o mesmo modelo numa carteira com o dobro de improcedentes (300 procedentes e 1.400 improcedentes, com as mesmas proporções em cada linha). Quais das quatro medidas mudam? Calcule as que mudam.

c) Use o item b para explicar por que a curva ROC e a AUC são feitas com sensibilidade e 1 – especificidade, e não com a precisão.

Questão 4 ★

Uma regressão logística dá, para cada recurso criminal do TJSP, a probabilidade de a decisão ter voto divergente (ser por maioria). A divergência é rara: acontece em cerca de 2% dos acórdãos. Uma defensoria quer usar esse modelo para escolher em que recursos fazer sustentação oral, porque uma decisão não unânime desfavorável ao réu abre os embargos infringentes. A equipe consegue acompanhar no máximo 15% dos recursos.

A tabela mostra cinco cortes. Para cada um, a parte dos recursos que o modelo marca (e que a equipe teria de acompanhar), a sensibilidade (a parte das divergências que estão entre os marcados) e a precisão (a parte dos marcados que de fato tiveram divergência):

corte	recursos marcados	sensibilidade	precisão
0,01	72%	94%	3%
0,02	37%	62%	4%
0,03	20%	44%	5%
0,04	12%	34%	6%
0,05	8%	23%	6%

a) Qual corte respeita a capacidade da equipe e encontra mais divergências?

b) Sem o modelo, a defensoria poderia sortear os recursos que vai acompanhar. Se sorteasse 12% deles (o mesmo tanto que o corte 0,04 marca), que parte das divergências esperaria encontrar entre os sorteados? Compare com a sensibilidade do corte 0,04: o modelo ajuda?

c) A precisão nunca passa de 6%. Um defensor conclui: “o modelo erra 94% das vezes, não serve”. Avalie esse argumento.

Questão 5

Com os mesmos acórdãos criminais do TJSP e a mesma pergunta da questão 4 (a decisão terá voto divergente?), árvores de várias profundidades foram avaliadas no treino e na validação cruzada, e comparadas com uma floresta de 300 árvores:

modelo	AUC no treino	AUC na validação
árvore, profundidade = 1	0,57	0,56
árvore, profundidade = 3	0,66	0,63
árvore, profundidade = 5	0,73	0,69
árvore, profundidade = 6	0,74	0,69
árvore, profundidade = 8	0,77	0,66
árvore, profundidade = 12	0,82	0,56
floresta de 300 árvores	0,99	0,74

a) Qual profundidade você escolheria? Por quê?

b) Descreva o que acontece entre a profundidade 5 e a 12.

c) A floresta tem AUC de 0,99 no treino. Isso é sobreajuste? Ela deve ser descartada?

d) Explique, sem fórmulas, por que a média de muitas árvores erra menos em casos novos do que uma árvore só.

e) A lista de importância da floresta põe `tempo` (anos até o julgamento) em primeiro lugar. Um jornalista escreve: “a demora causa a divergência nas câmaras”. O que está errado?

Questão 6 ★

Para cada situação, diga qual medida deve guiar a escolha do ponto de corte (ou do modelo) e por quê. Pense primeiro em qual erro custa mais, e para quem.

a) No plantão judiciário, um modelo marca as petições com pedido de tutela de urgência em saúde. As marcadas vão para o topo da fila e são lidas no mesmo dia; as demais ficam para a semana seguinte.

b) Um banco quer oferecer acordo, sem análise de um advogado, nas ações revisionais em que o modelo prevê condenação. Cada acordo oferecido é dinheiro que sai do caixa.

c) Uma equipe tem quatro modelos candidatos e ainda não sabe como o modelo escolhido será usado, nem com qual corte.

d) Um tribunal quer arquivar automaticamente, sem que ninguém leia, as petições que o modelo apontar como cópia de ações já julgadas entre as mesmas partes.

e) Uma câmara em que metade dos recursos é provida quer só saber se o modelo acerta mais do que erra. Para ela, errar para um lado custa o mesmo que errar para o outro.

PARTE 2

Questões de marcar

Questão 7

Marque V (verdadeiro) ou F (falso) em cada afirmação.

( ) a) O coeficiente de uma variável numa regressão logística é um hiperparâmetro, escolhido por validação cruzada.

( ) b) A profundidade máxima de uma árvore de decisão é um hiperparâmetro.

( ) c) Na validação cruzada com 5 partes, cada parte serve uma vez para avaliar o modelo ajustado nas outras quatro, e a AUC de validação é a média das 5 rodadas.

( ) d) Se uma rodada da validação cruzada deu AUC bem maior que as outras, é ela que mostra o potencial do modelo e deve ser relatada.

( ) e) O preparo (dummies e padronização) deve ser ajustado só nas partes de ajuste de cada rodada, e não na base inteira antes de dividir.

Questão 8

Uma empresa de tecnologia jurídica separou 20% de uma base de sentenças como teste. Para escolher o `C` da regressão logística, testou 30 valores, calculou a AUC de cada um no teste e ficou com o melhor, que deu AUC de 0,81. É esse número que aparece na proposta comercial. Seis meses depois, usando o modelo em sentenças novas, o cliente mediu AUC de 0,72. Qual explicação está correta?

(A) As sentenças novas devem ser diferentes das antigas, porque um modelo bem testado não perde 0,09 de AUC em seis meses.

(B) Trinta valores de `C` são poucos; com mais valores testados no teste, a AUC da proposta seria mais próxima da real.

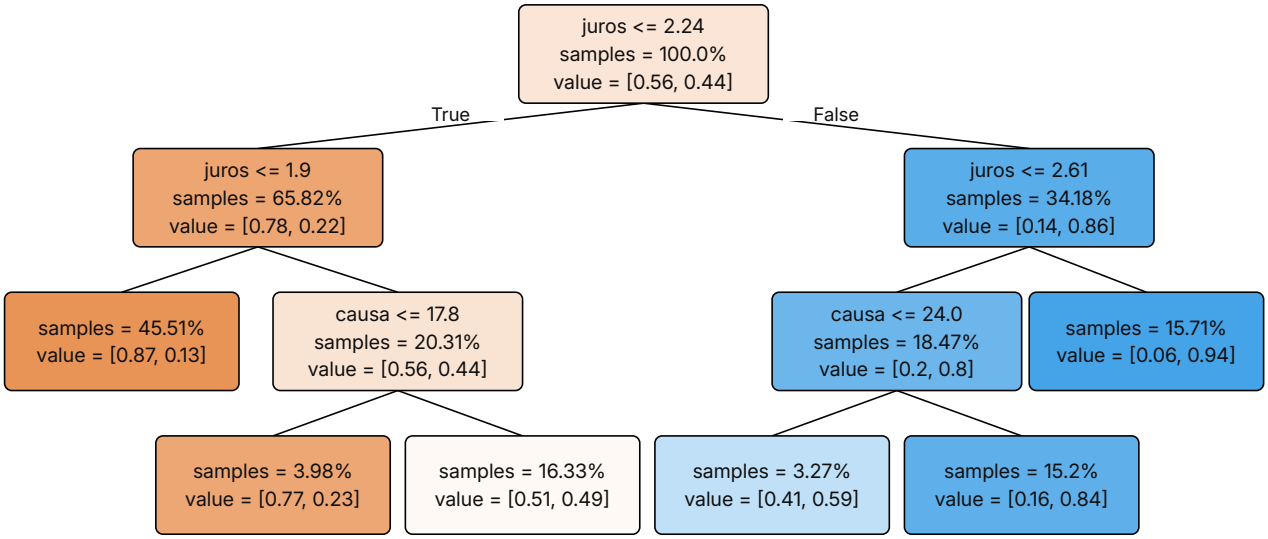
(C) O modelo tem subajuste: o `C` escolhido penaliza demais, e por isso ele vai pior nas sentenças novas.

(D) A AUC de 0,72 é a menos confiável das duas, porque foi medida pelo cliente numa base que a empresa não controlou.

(E) O teste foi usado para escolher o `C`, e o melhor de 30 tentativas no teste carrega sorte.

Questão 9 ★

Uma árvore de decisão prevê se a sentença numa ação revisional de financiamento será favorável ao autor, com duas colunas: `juros`, a taxa do contrato (% ao mês), e `causa`, o valor da causa (R$ mil). O desenho abaixo é o que sai do `plot_tree` do scikit-learn, como na aula 24. Em cada caixa, a primeira linha é a pergunta (quem responde sim vai para a esquerda, `True`); `samples` é a proporção dos processos do treino que chegaram ali; e `value` traz duas proporções: a de sentenças desfavoráveis e a de favoráveis ao autor. As caixas sem pergunta são as folhas.



Um contrato tem juros de 2,0% ao mês, e a causa vale R$ 40 mil. Qual é a probabilidade de sentença favorável ao autor prevista pela árvore?

(A) 13%

(B) 23%

(C) 49%

(D) 51%

(E) 44%

Questão 10 ★

Uma procuradoria quer prever, no dia da distribuição, se uma execução fiscal será extinta por prescrição. Marque V se a variável pode entrar no modelo e F se não pode.

( ) a) O valor da dívida.

( ) b) O tipo de tributo.

( ) c) A data da última citação do executado.

( ) d) O número de execuções anteriores à distribuição contra o mesmo executado.

( ) e) A data do arquivamento definitivo do processo.