Lista 7

Machine learning: sobreajuste, validação, ponto de corte, árvores e florestas

Conteúdo Aulas 22 a 24 · treino para os Projetos 7 e 8
Turma 4A · 2026/2
Professor Julio Trecenti
Versão Sem respostas.

POR ONDE COMEÇAR

As questões marcadas com uma estrela vermelha são o caminho mínimo: são oito de doze, e juntas cobrem uma vez cada conceito das aulas 22 a 24. A parte 1 é o sobreajuste e o teste, a parte 2 é a validação cruzada e o `C`, a parte 3 são o ponto de corte, a curva ROC e a AUC, e a parte 4 são as árvores, as florestas e o vazamento.

Ninguém precisa escrever código: o foco é **ler os resultados e decidir**. As tabelas vêm de bases inventadas ou da base do Projeto 08 com a pergunta da aula (houve voto divergente?). Uma calculadora ajuda nas questões 5 e 6. A lista é treino para o **Projeto 07** (provinha de 10/11) e para o **Projeto 08**.

PARTE 1

Sobreajuste, treino e teste

Questão 1 ★

Um escritório quer prever se as suas ações de indenização contra companhias aéreas serão procedentes. Tem um histórico de 400 processos, julgados em **120 varas** diferentes, e ajustou duas regressões logísticas: uma com a vara como variável e outra sem. Depois testou as duas em 150 processos novos, que não entraram no ajuste:

modelo	acerto no histórico	acerto nos novos
com a vara	93%	64%
sem a vara	79%	77%

a) O que aconteceu com o modelo com a vara? Dê o nome do fenômeno.

b) Por que uma variável com 120 categorias, em 400 processos, facilita esse problema?

c) Se o escritório tivesse olhado só o acerto no histórico, que decisão teria tomado? O que isso ensina sobre como avaliar um modelo de previsão?

d) Cite uma forma de manter a informação da vara sem cair no mesmo problema.

Questão 2

Para cada item, diga se é um **parâmetro** (sai dos dados, no ajuste) ou um **hiperparâmetro** (fixado antes do ajuste, e escolhido por validação cruzada). Justifique em uma linha.

a) O coeficiente da prova documental numa regressão logística.

b) O `C` da regressão logística.

c) A profundidade máxima de uma árvore de decisão.

d) A pergunta “juros abaixo de 2,24%?” no topo de uma árvore.

e) O número de árvores de uma floresta aleatória.

f) Por fim: o **ponto de corte** é um parâmetro, um hiperparâmetro ou outra coisa? Quando e com que critério ele é escolhido?

Questão 3 ★

Uma empresa de tecnologia jurídica separou 20% de uma base de sentenças como teste. Para escolher o `C` da regressão logística, testou 30 valores, calculou a AUC de cada um **no teste** e ficou com o melhor, que deu AUC de **0,81**. É esse número que aparece na proposta comercial. Seis meses depois, usando o modelo em sentenças novas, o cliente mediu AUC de **0,72**.

a) Explique por que o número da proposta era otimista.

b) Como a empresa deveria ter escolhido o `C`? E para que deveria ter servido o teste?

c) Com 30 valores de `C`, por que o problema é maior do que se tivessem testado só 2?

PARTE 2

Validação cruzada e o C

Questão 4 ★

Na base do Projeto 08, com a pergunta da aula 23 (houve voto divergente?), uma regressão logística foi ajustada com vários valores de `C`. A tabela traz a AUC média na validação cruzada (5 partes) e, para três deles, a AUC no próprio treino:

C	0,003	0,01	0,03	0,1	0,3	1	10	100	10.000
validação	0,62	0,64	0,66	0,69	0,70	0,70	0,68	0,65	0,63
treino	0,66				0,83				0,92

a) Qual `C` você escolheria? Lembre-se: `C` menor quer dizer penalidade maior.

b) Explique o que acontece à direita da tabela (`C` grande) e à esquerda (`C` muito pequeno), usando as palavras **sobreajuste** e **subajuste**.

c) Com `C = 10.000`, a distância entre treino e validação é de quase 0,3; com `C = 0,003`, é pequena. A distância pequena quer dizer que o modelo de `C = 0,003` é o melhor? Explique.

d) `C = 0,3` e `C = 1` empataram. Que critério você usaria para escolher entre eles?

Questão 5

Na validação cruzada de um modelo, as 5 rodadas deram estas AUC:

```
rodada:   1     2     3     4     5
AUC:    0,58  0,71  0,66  0,74  0,62
```

a) Qual é a AUC de validação cruzada do modelo?

b) A base tem 4.400 acórdãos de treino, e só 97 com divergência. Por que as rodadas variam tanto?

c) Um colega sugere relatar a rodada 4, “que mostra o potencial do modelo”. O que você responde?

d) Na validação cruzada, o modelo de cada rodada é ajustado em 4 partes e avaliado na quinta. Por que ajustar o **preparo** (as dummies e a padronização) na base inteira, antes de dividir, seria um erro?

PARTE 3

Ponto de corte, curva ROC e AUC

Questão 6 ★

Um modelo prevê a procedência de ações de consumo contra um banco. Com **corte 0,5** (processos com probabilidade de pelo menos 0,5 são marcados como procedentes), em 1.000 processos de validação:

	marcado	não marcado
procedente	210	90
improcedente	140	560

a) Calcule a sensibilidade, a especificidade, a 1 – especificidade e a precisão. Escreva o que cada uma quer dizer **neste caso**, em uma frase.

b) Imagine o mesmo modelo numa carteira com o **dobro de improcedentes** (300 procedentes e 1.400 improcedentes, com as mesmas proporções em cada linha). Quais das quatro medidas mudam? Calcule as que mudam.

c) Use o item b para explicar por que a curva ROC e a AUC são feitas com sensibilidade e 1 – especificidade, e não com a precisão.

Questão 7 ★

Dois modelos foram comparados na validação cruzada: **A**, uma regressão logística com penalidade, e **B**, uma floresta aleatória. A tabela mostra o acerto de cada um em três pontos de corte, e a AUC:

modelo	acerto, corte 0,3	acerto, corte 0,5	acerto, corte 0,7	AUC
A: logística	71%	78%	70%	0,79
B: floresta	76%	75%	74%	0,80

a) Pelo acerto, qual modelo é melhor? A resposta depende de quê?

b) Por que a AUC é a medida certa para comparar os dois **na validação cruzada**?

c) Pela AUC, os dois praticamente empatam. O modelo vai ser usado por uma câmara que precisa **justificar** a cada parte por que o processo foi priorizado. Qual você escolheria?

d) Escolhido o modelo, como e com que dados se escolhe o ponto de corte?

Questão 8

Uma defensoria quer usar o modelo da aula 23 para escolher em que recursos criminais fazer sustentação oral, porque uma decisão não unânime desfavorável ao réu abre os embargos infringentes. A equipe consegue acompanhar **no máximo 15%** dos recursos. Com as probabilidades de validação, a tabela mostra cinco cortes:

corte	recursos marcados	sensibilidade	precisão
0,01	72%	94%	3%
0,02	37%	62%	4%
0,03	20%	44%	5%
0,04	12%	34%	6%
0,05	8%	23%	6%

a) Qual corte respeita a capacidade da equipe e encontra mais divergências?

b) Se a defensoria sorteasse 12% dos recursos para acompanhar, que sensibilidade esperaria? O modelo ajuda?

c) A precisão nunca passa de 6%. Um defensor conclui: "o modelo erra 94% das vezes, não serve". Avalie esse argumento.

d) Por que esses cortes são tão baixos (0,01 a 0,05), em vez de algo perto de 0,5?

PARTE 4

Árvores, florestas e vazamento

Questão 9 ★

Uma árvore de decisão prevê se a sentença numa ação revisional de financiamento será favorável ao autor, com a taxa de juros do contrato (% ao mês) e o valor da causa (R$ mil). Em cada pergunta, **sim** vai para cima e **não** para baixo; cada folha traz a proporção de sentenças favoráveis e o número de processos do treino:

```
juros < 2,24?
├─ sim: juros < 1,90?
│    ├─ sim: FOLHA 1 ............................ 13% favoráveis (446 processos)
│    └─ não: causa < R$ 17,8 mil?
│         ├─ sim: FOLHA 2 ....................... 23% favoráveis (39 processos)
│         └─ não: FOLHA 3 ....................... 49% favoráveis (160 processos)
└─ não: juros < 2,61?
     ├─ sim: causa < R$ 24 mil?
     │    ├─ sim: FOLHA 4 ....................... 59% favoráveis (32 processos)
     │    └─ não: FOLHA 5 ....................... 84% favoráveis (149 processos)
     └─ não: FOLHA 6 ............................ 94% favoráveis (154 processos)
```

a) Qual a probabilidade de sentença favorável prevista para cada processo?

processo	juros (% ao mês)	causa (R$ mil)
P	1,5	30
Q	2,0	40
R	2,5	10
S	3,2	5

b) Escreva, em linguagem natural, a regra que leva à folha 5.

c) O valor da causa importa em todos os processos? O que isso mostra sobre o que uma árvore consegue captar sem que ninguém peça?

d) Com corte 0,5, quais folhas teriam os processos marcados como sentença favorável?

Questão 10 ★

Na base do Projeto 08, com a pergunta da aula (houve voto divergente?), árvores de várias profundidades foram avaliadas no treino e na validação cruzada, e comparadas com uma floresta de 300 árvores:

AUC	prof. 1	prof. 3	prof. 5	prof. 6	prof. 8	prof. 12	floresta
treino	0,57	0,66	0,73	0,74	0,77	0,82	0,99
validação	0,56	0,63	0,69	0,69	0,66	0,56	0,74

a) Qual profundidade você escolheria? Por quê?

b) Descreva o que acontece entre a profundidade 5 e a 12.

c) A floresta tem AUC de 0,99 no treino. Isso é sobreajuste? Ela deve ser descartada?

d) Explique, sem fórmulas, por que a média de muitas árvores erra menos em casos novos do que uma árvore só.

e) A lista de importância da floresta põe `tempo` (anos até o julgamento) em primeiro lugar. Um jornalista escreve: "a demora causa a divergência nas câmaras". O que está errado?

Questão 11 ★

Uma procuradoria quer prever, **no dia da distribuição**, se uma execução fiscal será extinta por prescrição. Para cada variável, diga se ela pode entrar no modelo e por quê.

a) O valor da dívida.

b) O tipo de tributo.

c) A data da última citação do executado.

d) O número de execuções anteriores contra o mesmo executado.

e) A data do arquivamento definitivo do processo.

f) Com todas as variáveis, o modelo teve AUC de 0,99 na validação cruzada. O que você suspeitaria antes de comemorar?

Questão 12

Uma empresa oferece a um banco um modelo que prevê, para cada ação revisional recém-distribuída, a probabilidade de condenação. O material de venda diz: "**AUC de 0,93**, floresta aleatória com 500 árvores, treinada com 50 mil processos". O banco quer usar o modelo para decidir em quais processos propor acordo.

a) Formule três perguntas que o banco deveria fazer à empresa antes de acreditar no 0,93. Para cada uma, diga que problema ela procura descobrir.

b) Suponha que a AUC tenha sido medida corretamente. Por que ela ainda não basta para decidir em quais processos propor acordo? O que falta?

c) O banco tem um modelo próprio, uma regressão logística com AUC de 0,90 na mesma validação. Em que situação faria sentido ficar com o próprio modelo?