Projeto Aplicado 7

Machine learning: sobreajuste, validação, métricas e árvores

Regras

- São 5 questões de múltipla escolha, cada uma com **uma só alternativa correta** e valendo **2,0 pontos**. Não há desconto por resposta errada, e não é preciso calculadora.
- Marque as letras na **folha de respostas**, no fim da prova: é ela que vale na correção.

Questão 1 · 2,0 pontos

FÁCIL

Um escritório que defende companhias aéreas quer prever se as ações de passageiros por atraso de voo serão julgadas procedentes nos juizados especiais. Ajustou árvores de decisão com profundidades máximas diferentes e mediu a AUC no próprio treino e na validação cruzada (5 partes):

AUC	profundidade = 2	profundidade = 4	profundidade = 8	profundidade = 20
treino	0,68	0,76	0,88	0,99
validação cruzada	0,67	0,74	0,71	0,62

Qual afirmação está correta?

(A) A profundidade 20 é a melhor escolha, porque a AUC de 0,99 no treino mostra que ela capta todos os padrões dos processos.

(B) **A profundidade 4 é a melhor escolha: tem a maior AUC na validação, e as árvores mais profundas passam a decorar o treino.**

(C) A profundidade 2 é a melhor escolha, porque treino e validação quase coincidem, sinal de que não há sobreajuste.

(D) A profundidade 8 é a melhor escolha, porque equilibra uma AUC alta no treino com uma AUC ainda boa na validação.

(E) A profundidade 20 pode ser usada sem risco, porque a validação cruzada já corrige o sobreajuste das árvores profundas.

RESPOSTA: B

Quem escolhe a profundidade é a **AUC na validação**, e a maior é a da profundidade 4 (0,74). Da profundidade 4 para a 20, o treino sobe de 0,76 para 0,99 e a validação cai de 0,74 para 0,62: a árvore passa a fazer perguntas que só servem para os processos do treino, com folhas de poucos casos. É o desenho do sobreajuste da aula 22.

- **A** escolhe pelo treino, que é justamente o número que o sobreajuste infla.
- **C** confunde distância pequena com modelo bom. A profundidade 2 não decorou, mas também aprendeu pouco: vai mal nos dois lugares (subajuste).
- **D** pesa o treino na escolha. O treino não entra no critério: entre as quatro, a 8 tem validação menor que a 4.
- **E** inverte o papel da validação cruzada: ela **mede** o sobreajuste, e é por isso que mostra a profundidade 20 com 0,62. Ela não o corrige.

Questão 2 · 2,0 pontos

MÉDIO

Uma empresa de tecnologia jurídica prevê se pedidos de recuperação judicial terão o processamento deferido. Ela separou 20% dos pedidos como teste, escolheu o `C` da regressão logística por validação cruzada no treino (AUC média de 0,78) e só então avaliou o modelo escolhido no teste, uma única vez (AUC de 0,76). Um sócio propõe: "vamos testar mais 50 valores de `C` direto no teste e mostrar ao cliente o melhor resultado".

Sobre a proposta do sócio, é correto afirmar que:

(A) é uma boa ideia, porque testar mais valores de `C` aumenta a chance de achar o modelo que funciona melhor nos pedidos futuros.

(B) é uma boa ideia, porque o teste é a parte da base mais parecida com os pedidos futuros, o que deixa o número mais realista.

(C) é desnecessária: como o `C` já foi escolhido na validação cruzada, testar outros valores no teste daria o mesmo resultado.

(D) não é uma boa ideia: escolhendo o `C` pelo teste, o modelo decora a base de teste, e o número mostrado fica otimista.

(E) não é uma boa ideia, porque a queda de 0,78 para 0,76 já indica sobreajuste, e o modelo deveria ser descartado antes.

RESPOSTA: D

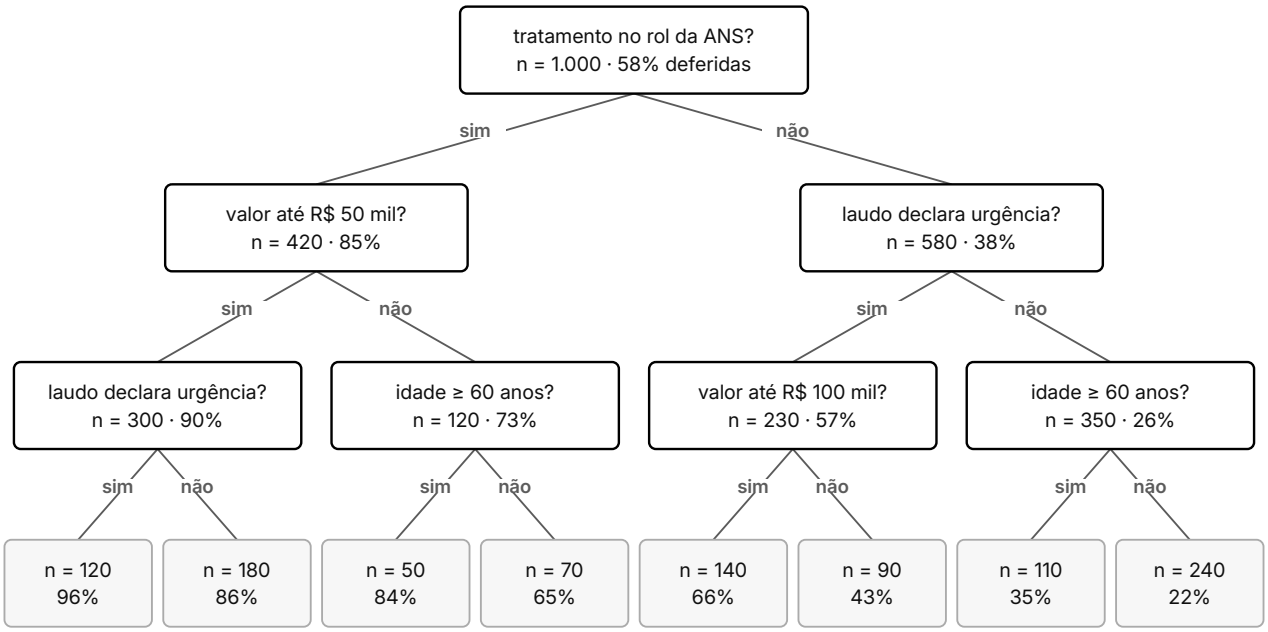
A empresa fez o fluxo certo: escolheu o `C` sem abrir o teste e abriu o teste uma vez, no fim. O 0,76 é o número honesto. Escolher olhando o teste faz a escolha se ajustar àqueles pedidos: entre 50 valores, o que vai melhor naquele teste é em parte o que deu mais sorte com eles, e a sorte não se repete nos pedidos novos. É o mesmo motivo do limite de submissões no Projeto 8.

- **A** é a intuição do sócio, e o erro está em "nos pedidos futuros": o melhor de 50 no teste é o melhor **naquele teste**.
- **B** tem uma premissa razoável (o teste imita os pedidos futuros) e uma conclusão errada: ele só imita enquanto não é usado para escolher.
- **C** supõe que o teste e a validação cruzada concordam em tudo. Não concordam, e por isso o melhor dos 50 no teste quase sempre tem número maior que 0,76, que é justamente o otimismo.
- **E** exagera. Uma diferença de 0,02 entre a validação e o teste é a variação esperada de uma amostra para outra, e não um sinal de sobreajuste.

Questão 3 · 2,0 pontos

FÁCIL

Uma árvore de decisão de profundidade 3 foi ajustada para prever se uma liminar contra plano de saúde, para custear um tratamento, será deferida. Em cada caixa estão a pergunta, o número de pedidos do treino que passaram por ali (n) e a proporção de liminares deferidas entre eles. O "sim" vai para a esquerda, e o "não", para a direita.



Chega um pedido de um tratamento fora do rol da ANS, com laudo que declara urgência, no valor de R$ 200 mil, para uma paciente de 45 anos. Qual é a probabilidade de deferimento prevista pela árvore?

(A) 57% (B) 66% (C) **43%** (D) 22% (E) 38%

RESPOSTA: C

O pedido desce a árvore até uma folha, respondendo uma pergunta por nível: fora do rol, segue pelo "não"; com urgência declarada, pelo "sim"; com valor acima de R$ 100 mil, pelo "não". Cai na folha com **43%** de deferimentos, entre os 90 pedidos parecidos do treino. A previsão de uma árvore é a proporção da folha.

- **A** (57%) e **E** (38%) param no meio do caminho: são as proporções de nós internos, e não de folhas. Elas descrevem grupos maiores e mais misturados.
- **B** (66%) erra a última pergunta, como se o valor estivesse abaixo de R$ 100 mil.
- **D** (22%) erra a segunda pergunta, como se não houvesse urgência, e depois usa a idade.

A idade da paciente não entra nesse caminho: ela só é perguntada em outros ramos. Numa árvore, uma variável pode importar para alguns casos e não para outros, o que é uma interação que o modelo encontra sozinho.

Questão 4 · 2,0 pontos

MÉDIO

A corregedoria de um tribunal quer encontrar petições iniciais de litigância predatória (ações em massa, com documentos padronizados, muitas vezes sem o conhecimento do próprio autor). Um modelo dá, para cada petição, a probabilidade de ela ser predatória. Cada petição marcada como sendo litigância predatória pelo modelo a partir de um valor de corte é analisada por um servidor, e a equipe consegue analisar no máximo 60 petições a cada 1.000 distribuídas. Em um cenário com 1.000 petições analisadas, foram avaliados três valores de corte, com os resultados abaixo:

corte	VP	FP	FN	VN	sensibilidade	precisão	acurácia
0,2	27	93	3	877	90%	23%	90%
0,5	20	30	10	940	67%	40%	96%
0,8	9	3	21	967	30%	75%	98%

VP são as predatórias marcadas, FP as não predatórias marcadas, FN as predatórias não marcadas e VN as não predatórias não marcadas. O que a corregedoria deve fazer?

(A) Usar o corte 0,5: dos três, é o que encontra mais predatórias sem passar das 60 que a equipe analisa.

(B) Usar o corte 0,2, porque encontra 90% das predatórias, e deixar passar uma predatória é o erro mais grave.

(C) Usar o corte 0,8, porque tem a maior acurácia e a maior precisão: quase todas as marcadas são predatórias.

(D) Não usar o modelo: no corte 0,5, a acurácia de 96% fica abaixo dos 97% de não marcar nenhuma petição.

(E) Ordenar as petições pela probabilidade e analisar as 60 mais altas, que têm ao menos 20 predatórias.

RESPOSTA: E

Com uma capacidade fixa, a pergunta não é qual dos três cortes usar, e sim quais 60 petições analisar. Ordenar pela probabilidade e ficar com as 60 mais altas é usar um corte escolhido pela capacidade: ele fica entre 0,2 (que marca 120) e 0,5 (que marca 50). As 60 incluem as 50 do corte 0,5, então têm pelo menos as mesmas 20 predatórias, e as 10 vagas a mais ainda podem encontrar outras.

- **A** respeita a capacidade, mas deixa 10 vagas da equipe paradas sem motivo. O corte 0,5 não tem nada de especial: é só um dos três da tabela.
- **B** tem a prioridade certa e esquece a capacidade: 120 petições marcadas são o dobro do que a equipe analisa, e metade ficaria sem análise.
- **C** escolhe pela acurácia e pela precisão. A acurácia quase não muda entre os cortes, porque as não predatórias são 97% da base; e o corte 0,8 deixa passar 21 das 30 predatórias, com a equipe ociosa.
- **D** compara com um "modelo" que não encontra nenhuma petição predatória, que é tudo o que a corregedoria quer. Quando o evento é raro, a acurácia engana (aula 21).

Questão 5 · 2,0 pontos

DIFÍCIL

Uma procuradoria municipal quer prever, no dia da citação, se uma ação de indenização contra o município será julgada procedente, para decidir em quais processos propor acordo logo no início. Uma floresta aleatória de 500 árvores teve AUC de 0,97 na validação cruzada. As variáveis mais importantes foram, em ordem: (1) os dias entre a citação e a sentença, (2) se o município recorreu da sentença e (3) o valor da causa. Qual é a melhor leitura desse resultado?

(A) A AUC foi medida na validação cruzada, em processos que cada modelo não viu; por isso o 0,97 é uma boa estimativa para os processos novos.

(B) A floresta encontrou um padrão útil: ações que demoram mais até a sentença tendem a ser procedentes, e isso pode orientar os acordos.

(C) Uma AUC tão alta indica sobreajuste; seria melhor limitar a profundidade das árvores e refazer a validação cruzada.

(D) **As duas variáveis mais importantes só são conhecidas depois da sentença: é vazamento, e o modelo deve ser refeito sem elas.**

(E) Como a floresta é difícil de explicar, seria melhor usar uma árvore só, com as mesmas variáveis, que mostra as regras de forma clara.

RESPOSTA: D

A pergunta que se faz a cada variável é: **no dia em que vou prever, eu já sei isto?** No dia da citação ninguém sabe quando sai a sentença, e o município só recorre de uma sentença que perdeu, o que praticamente carrega a resposta. Uma AUC de 0,97 num problema difícil é, antes de tudo, um alerta. É o vazamento da aula 24.

- **A** confia na validação cruzada além do que ela garante. Ela protege contra o sobreajuste, mas não contra o vazamento: as colunas vazadas estão nas partes de ajuste e nas de validação, e o número sai alto nas duas.
- **B** lê a importância como um padrão aproveitável. A coluna ajuda a prever porque vem depois do desfecho, e no dia da citação ela não existe.
- **C** erra o diagnóstico. Sobreajuste aparece como validação **baixa** com treino alto; aqui a validação é que está alta demais.
- **E** troca o modelo e mantém as colunas: a árvore também usaria as variáveis vazadas e também teria uma AUC alta e enganosa.

Folha de respostas

questão	1	2	3	4	5
resposta	B	D	C	E	D