Projeto Aplicado 7

Machine learning: sobreajuste, validação, métricas e árvores

Nome _____

E-mail (@al.insper.edu.br, opcional) _____

Regras

- São 5 questões de múltipla escolha, cada uma com **uma só alternativa correta** e valendo **2,0 pontos**. Não há desconto por resposta errada, e não é preciso calculadora.
- Marque as letras na **folha de respostas**, no fim da prova: é ela que vale na correção.

Questão 1 · 2,0 pontos

Um escritório que defende companhias aéreas quer prever se as ações de passageiros por atraso de voo serão julgadas procedentes nos juizados especiais. Ajustou árvores de decisão com profundidades máximas diferentes e mediu a AUC no próprio treino e na validação cruzada (5 partes):

AUC	profundidade = 2	profundidade = 4	profundidade = 8	profundidade = 20
treino	0,68	0,76	0,88	0,99
validação cruzada	0,67	0,74	0,71	0,62

Qual afirmação está correta?

(A) A profundidade 20 é a melhor escolha, porque a AUC de 0,99 no treino mostra que ela capta todos os padrões dos processos.

(B) A profundidade 4 é a melhor escolha: tem a maior AUC na validação, e as árvores mais profundas passam a decorar o treino.

(C) A profundidade 2 é a melhor escolha, porque treino e validação quase coincidem, sinal de que não há sobreajuste.

(D) A profundidade 8 é a melhor escolha, porque equilibra uma AUC alta no treino com uma AUC ainda boa na validação.

(E) A profundidade 20 pode ser usada sem risco, porque a validação cruzada já corrige o sobreajuste das árvores profundas.

Questão 2 · 2,0 pontos

Uma empresa de tecnologia jurídica prevê se pedidos de recuperação judicial terão o processamento deferido. Ela separou 20% dos pedidos como teste, escolheu o `C` da regressão logística por validação cruzada no treino (AUC média de 0,78) e só então avaliou o modelo escolhido no teste, uma única vez (AUC de 0,76). Um sócio propõe: "vamos testar mais 50 valores de `C` direto no teste e mostrar ao cliente o melhor resultado".

Sobre a proposta do sócio, é correto afirmar que:

(A) é uma boa ideia, porque testar mais valores de `C` aumenta a chance de achar o modelo que funciona melhor nos pedidos futuros.

(B) é uma boa ideia, porque o teste é a parte da base mais parecida com os pedidos futuros, o que deixa o número mais realista.

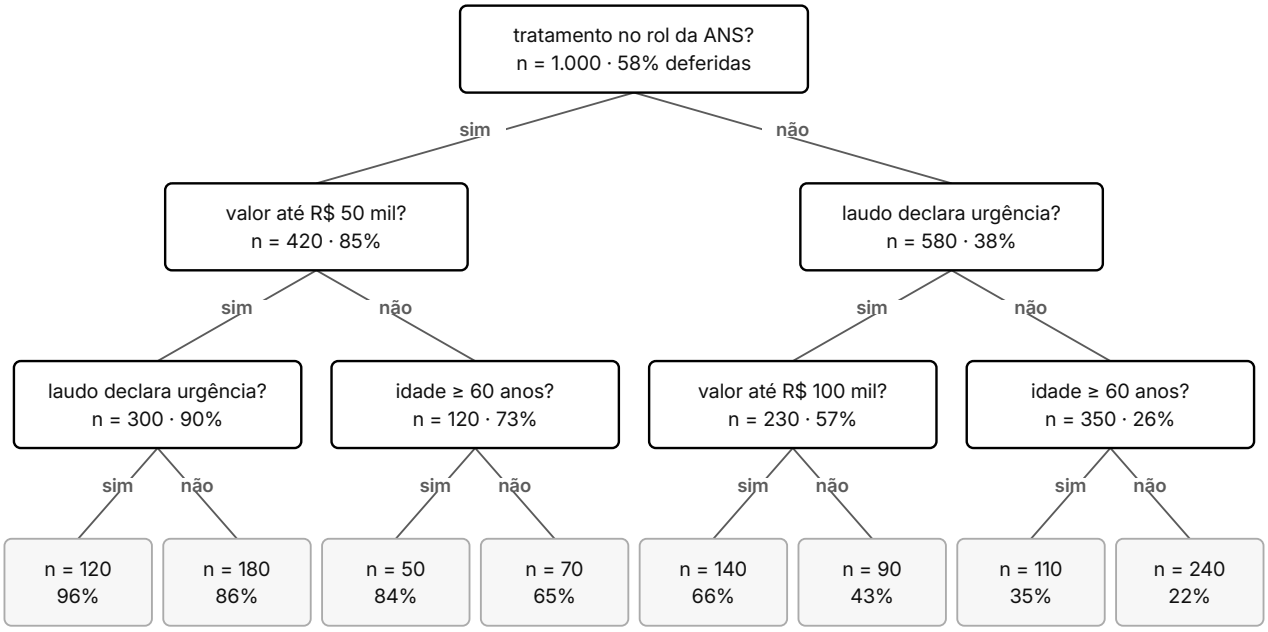
(C) é desnecessária: como o `C` já foi escolhido na validação cruzada, testar outros valores no teste daria o mesmo resultado.

(D) não é uma boa ideia: escolhendo o `C` pelo teste, o modelo decora a base de teste, e o número mostrado fica otimista.

(E) não é uma boa ideia, porque a queda de 0,78 para 0,76 já indica sobreajuste, e o modelo deveria ser descartado antes.

Questão 3 · 2,0 pontos

Uma árvore de decisão de profundidade 3 foi ajustada para prever se uma liminar contra plano de saúde, para custear um tratamento, será deferida. Em cada caixa estão a pergunta, o número de pedidos do treino que passaram por ali (n) e a proporção de liminares deferidas entre eles. O "sim" vai para a esquerda, e o "não", para a direita.



Chega um pedido de um tratamento fora do rol da ANS, com laudo que declara urgência, no valor de R$ 200 mil, para uma paciente de 45 anos. Qual é a probabilidade de deferimento prevista pela árvore?

(A) 57% (B) 66% (C) 43% (D) 22% (E) 38%

Questão 4 · 2,0 pontos

A corregedoria de um tribunal quer encontrar petições iniciais de litigância predatória (ações em massa, com documentos padronizados, muitas vezes sem o conhecimento do próprio autor). Um modelo dá, para cada petição, a probabilidade de ela ser predatória. Cada petição marcada como sendo litigância predatória pelo modelo a partir de um valor de corte é analisada por um servidor, e a equipe consegue analisar no máximo 60 petições a cada 1.000 distribuídas. Em um cenário com 1.000 petições analisadas, foram avaliados três valores de corte, com os resultados abaixo:

corte	VP	FP	FN	VN	sensibilidade	precisão	acurácia
0,2	27	93	3	877	90%	23%	90%
0,5	20	30	10	940	67%	40%	96%
0,8	9	3	21	967	30%	75%	98%

VP são as predatórias marcadas, FP as não predatórias marcadas, FN as predatórias não marcadas e VN as não predatórias não marcadas. O que a corregedoria deve fazer?

(A) Usar o corte 0,5: dos três, é o que encontra mais predatórias sem passar das 60 que a equipe analisa.

(B) Usar o corte 0,2, porque encontra 90% das predatórias, e deixar passar uma predatória é o erro mais grave.

(C) Usar o corte 0,8, porque tem a maior acurácia e a maior precisão: quase todas as marcadas são predatórias.

(D) Não usar o modelo: no corte 0,5, a acurácia de 96% fica abaixo dos 97% de não marcar nenhuma petição.

(E) Ordenar as petições pela probabilidade e analisar as 60 mais altas, que têm ao menos 20 predatórias.

Questão 5 · 2,0 pontos

Uma procuradoria municipal quer prever, no dia da citação, se uma ação de indenização contra o município será julgada procedente, para decidir em quais processos propor acordo logo no início. Uma floresta aleatória de 500 árvores teve AUC de 0,97 na validação cruzada. As variáveis mais importantes foram, em ordem: (1) os dias entre a citação e a sentença, (2) se o município recorreu da sentença e (3) o valor da causa. Qual é a melhor leitura desse resultado?

(A) A AUC foi medida na validação cruzada, em processos que cada modelo não viu; por isso o 0,97 é uma boa estimativa para os processos novos.

(B) A floresta encontrou um padrão útil: ações que demoram mais até a sentença tendem a ser procedentes, e isso pode orientar os acordos.

(C) Uma AUC tão alta indica sobreajuste; seria melhor limitar a profundidade das árvores e refazer a validação cruzada.

(D) As duas variáveis mais importantes só são conhecidas depois da sentença: é vazamento, e o modelo deve ser refeito sem elas.

(E) Como a floresta é difícil de explicar, seria melhor usar uma árvore só, com as mesmas variáveis, que mostra as regras de forma clara.

Folha de respostas

questão	1	2	3	4	5
resposta					

Nome _____