


Ciência de Dados Aplicada ao Direito II

Aula 2: tipos de variáveis

Da variável aleatória à coluna da tabela

Julio Trecenti

Insper

A decorative graphic on the right side of the slide. It consists of several overlapping squares. One square is black, another is red, and a third is light gray with dark gray diagonal stripes. The red square is in the foreground, partially overlapping the black and striped squares.

[Insper.edu.br](https://insper.edu.br)

Antes de tipar: o que é uma variável?

Variável aleatória

Uma regra que associa um valor a cada caso do estudo, antes de você olhar o caso.

Aleatória não quer dizer imprevisível: quer dizer que o valor muda de caso para caso, e você não sabe qual é até medir.

Sorteie uma sentença de furto do TJSP. Antes de abrir o arquivo:

X = pena aplicada, em anos

você sabe que vai sair um número entre 1 e 8, mas não sabe qual

Y = houve confissão espontânea

você sabe que vai sair sim ou não, mas não sabe qual

Z = regime inicial fixado

você sabe que vai sair aberto, semiaberto ou fechado

X, Y e Z são as variáveis. O que aparece quando você abre a sentença é o valor observado delas naquele caso.

Variável, valor observado e estatística

Três coisas diferentes, que a conversa do dia a dia mistura.

Variável

o que se mede

“pena aplicada, em anos”

Existe antes dos dados. É a coluna da tabela.

Valor observado

o valor de um caso

na sentença 0001234-56, a pena foi 5,5 anos

É uma célula da tabela.

Estatística

resumo de muitos valores observados


a pena mediana das 120 sentenças foi 5 anos

É um número calculado da coluna inteira.

O tipo é propriedade da variável, e não do valor observado. Ele determina quais estatísticas podem ser calculadas a partir daquela coluna.

Tipos de variáveis

Os cinco tipos



Fora da árvore: o identificador (número do processo) e o texto livre. Nenhum dos dois entra em conta; eles servem para achar o caso e para construir as outras variáveis.

Numérica: discreta e contínua

Discreta

resultado de contar

- número de réus no processo
- número de testemunhas ouvidas
- número de assuntos do processo
- quantidade de invólucros apreendidos

Entre 2 e 3 réus não existe nada. Some sempre em passos inteiros.

Contínua

resultado de medir numa escala

- pena aplicada, em anos
- valor da indenização, em reais
- massa da droga, em gramas
- tempo até a sentença, em dias

Entre 5,0 e 5,5 anos existe 5,25. O limite é a precisão do instrumento, não a variável.

Quando a distinção importa

Discreta com muitos valores possíveis, como dias de tramitação, é tratada como contínua sem prejuízo. Já uma contagem de 0, 1 e 2 não deve ser tratada como escala.

Categórica: nominal, ordinal e binária

Nominal

categorias sem ordem

comarca

fundamento invocado

classe processual

tipo de prova

Não dá para dizer que São Paulo é maior que Santos.

Ordinal

categorias com ordem

regime de pena

grau de jurisdição

faixa de valor

nível de sigilo

A ordem existe, mas a distância entre duas categorias não é medível.

Binária

só dois valores

houve confissão?

réu é primário?

recurso foi provido?

houve dano moral?

Caso especial de nominal. A média de uma binária é a proporção.

Requisito das categorias

As categorias devem ser mutuamente exclusivas e exaustivas: cada caso pertence a exatamente uma delas. Quando não são, a variável não pode ser tabulada nem comparada entre grupos.

Número que não é número

O erro mais comum da disciplina: o pandas lê a coluna como número, e o número não mede nada.

o que aparece	o que é	tipo	por quê
0001234-56.2024.8.26.0100	número do processo	identificador	É a chave do caso, e não uma medida.
3550308	código do município (IBGE)	identificador	São dígitos que nomeiam São Paulo.
13	número da câmara julgadora	identificador	A 13ª não é maior que a 2ª, e o número só nomeia o órgão.
2	polo: 1 ativo, 2 passivo	categórica nominal	Aqui o número agrupa, em vez de nomear.
1116	código da classe processual	identificador	Rótulo do CNJ para execução fiscal.
3	número de réus no polo passivo	numérica discreta	Esta é contagem, e soma faz sentido.

Como decidir

Verifique se somar dois valores da variável produz algo com sentido. Se não produz, a variável não é numérica, por mais que seja escrita com dígitos.

Papéis das variáveis na pergunta

Os quatro papéis

O papel não é propriedade da variável: é a posição dela na sua pergunta. A mesma coluna muda de papel quando a pergunta muda.

Identifica o caso

acha o processo depois e permite conferir e juntar com outra base. Não entra na comparação.

O que eu quero explicar

o desfecho da pergunta, aquilo que você quer entender por que varia. Em estatística: variável resposta, ou dependente.

O que pode explicar

aquilo que talvez esteja associado ao desfecho. Em estatística: variável explicativa, ou independente.

Define quais casos entram

não responde à pergunta, mas delimita o universo: só sentenças de mérito, só condenações, só um período.

Sem uma variável no papel de desfecho não há o que comparar. A rubrica do Projeto 1 verifica isso.

Da sentença para a tabela

Pergunta de pesquisa

Nas ações de despejo por falta de pagamento, o tamanho do débito está associado à concessão da liminar de desocupação?

variável	tipo	papel	de onde tirar
numero_processo	identificador	identifica o caso	cabeçalho da sentença
tipo_imovel	categórica nominal	o que pode explicar	residencial ou comercial
meses_de_atraso	numérica discreta	o que pode explicar	quantos aluguéis vencidos
valor_do_debito	numérica contínua	o que pode explicar	valor em reais na inicial
faixa_do_debito	categórica ordinal	o que pode explicar	derivada do valor, em três faixas
liminar_concedida	categórica binária	o que quero explicar	sim ou não, no despacho inicial
houve_purgacao	categórica binária	define quais casos entram	só entram os que não purgaram a mora

Uma tabela com esta estrutura, nome, tipo, papel e de onde tirar, é o que o Projeto 1 pede em 18/08. O tipo declarado define o formato do valor que o modelo de linguagem devolve: numérica sai como número, categórica sai como uma das categorias listadas.

O tipo decide a conta

tipo	posição	dispersão	o que não fazer
numérica contínua	média, mediana, quantis	desvio padrão, IQR	reportar só a média quando a distribuição é torta
numérica discreta	média, mediana, moda	desvio padrão, IQR	estrANHAR que a média dê 1,7 réu
categórica ordinal	mediana, moda	amplitude de postos	média das categorias
categórica nominal	moda	nenhuma clássica	média, mediana, desvio padrão
categórica binária	proporção (= média)	raiz de $p(1 - p)$	tratar como se fosse contínua
identificador	nenhuma	nenhuma	qualquer conta

A média de uma binária é a proporção

Guardada como sim/não, a variável vale 1 e 0. Somar dá quantos sim; dividir pelo total dá a fração de sim. Por isso `df["houve_confissao"].mean()` devolve a proporção de confissões, e a mesma conta funciona dentro de um groupby.

O que vem agora

Hoje, no notebook

ler uma base do DataJud, dizer o tipo de cada coluna e converter o que o pandas entendeu errado, inclusive com `pd.Categorical`.

Aula 3, em 18/08

medidas de posição e de dispersão, e definição de variáveis a partir do texto da decisão.

Projeto 1, em 18/08

em grupo: escolher um tema, definir as variáveis com tipo e papel, e rodar o modelo de linguagem para preencher a tabela.

No resto da disciplina

a escolha do gráfico, do teste de hipótese e do modelo depende do tipo das variáveis envolvidas.