

Ciência de Dados Aplicada ao Direito II

Aula 3: filtrar e resumir

Medidas de posição e de dispersão

Julio Trecenti

Insper

A decorative graphic on the right side of the slide. It consists of several overlapping squares. One square is black, another is red, and a third is light gray with dark gray diagonal stripes. The red square is in the foreground, partially overlapping the black and striped squares.

[Insper.edu.br](https://insper.edu.br)

Resumir uma coluna em um número

Posição: onde fica o centro

Indenizações por dano moral arbitradas pelo TJSP, em 303 acórdãos com valor na ementa.

média

R\$ 7.935

somar tudo e dividir pelo número de casos

mediana

R\$ 5.000

o valor do meio, com metade abaixo e metade acima

maior valor

R\$ 90.000

um único acórdão

A média é 59% maior que a mediana

Poucos valores muito altos puxam a média para cima, e a mediana não se move. Tirar o maior acórdão da base derruba a média em R\$ 272 e deixa a mediana exatamente onde estava.

Em valores monetários no Direito, a distribuição quase sempre é assimétrica à direita. Por isso o valor típico de uma indenização se reporta com a mediana, e a média sozinha, sem acompanhamento, tende a enganar quem lê.

Dispersão: quanto os casos variam

Duas medidas, e elas respondem a perguntas diferentes.

Intervalo interquartilico

$IQR = Q3 - Q1$

A largura da metade central dos dados. Vai do valor que deixa 25% abaixo até o que deixa 75% abaixo.

Acompanha a mediana. Dois casos extremos não mexem nele.

Desvio padrão

$\text{divide por } n - 1$

O afastamento típico em relação à média, na mesma unidade da variável.

Acompanha a média. É a base de quase toda a inferência que vem depois.

Nas indenizações: IQR de R\$ 5.000 e desvio padrão de R\$ 8.388

A metade central está espremida entre R\$ 5.000 e R\$ 10.000, e mesmo assim o desvio padrão passa da média. Isso é o que a cauda longa faz. O coeficiente de variação, que é o desvio padrão dividido pela média, dá 1,06: acima de 1, os valores estão espalhados demais para que a média resuma alguma coisa.

Que conta cabe em cada tipo

tipo	posição	dispersão
numérica contínua	média, mediana, quantis	desvio padrão, IQR
numérica discreta	média, mediana, moda	desvio padrão, IQR
categórica ordinal	mediana, moda	amplitude de postos
categórica nominal	moda	nenhuma clássica
categórica binária	proporção, que é a média	raiz de $p(1 - p)$
identificador	nenhuma	nenhuma

A média de uma binária é a proporção

Guardada como sim ou não, a variável vale 1 e 0. Somar dá quantos sim, e dividir pelo total dá a fração de sim. É por isso que `.mean()` numa coluna de verdadeiro e falso devolve a proporção, e é a conta que mais vai aparecer daqui em diante.

Do texto para a variável

A decisão está na ementa: “fixo a indenização em R\$ 8.000,00, atento à capacidade econômica da ré”. Para virar coluna, alguém precisa decidir três coisas.

Onde a informação está

O primeiro valor em reais da ementa nem sempre é o arbitrado: pode ser o pedido, o da sentença reformada, ou custas.

Que valores registrar

Número em reais? Faixa? Indicador de houve ou não houve? Cada escolha responde a uma pergunta diferente.

O que fazer quando falta

Um terço das ementas não traz valor nenhum. Descartar essas linhas muda o universo sobre o qual a resposta vale.

Essa instrução tem nome: definição operacional

É o texto que faria duas pessoas lerem a mesma ementa e registrarem o mesmo valor. Sem ela, a coluna não é reproduzível, e o revisor não tem como conferir o que você mediu.

Projeto 1, hoje

Escolher o tema e ler as sentenças

cinco temas, cada um com uma pergunta de pesquisa e 10 sentenças reais de primeiro grau do TJSP.

Definir as variáveis

nome, tipo, papel na pergunta e de onde tirar. O tipo declarado decide o formato do valor: numérica devolve número, categórica devolve uma das categorias listadas.

Rodar o modelo e dizer que estatísticas calcularia

o modelo lê cada sentença e preenche as suas colunas. Depois você diz que contas faria com a tabela, e elas precisam caber nos tipos.

Pedir feedback e entregar

até três avaliações pela rubrica, que está visível desde o começo. Entrega no BlackBoard: a tabela em CSV e a documentação em JSON.

Em grupo, com cópia e cola bloqueados. A rubrica avalia as escolhas, e não a quantidade de variáveis.