


Ciência de Dados Aplicada ao Direito II

Aula 3: filtrar e resumir

Medidas de posição e de variabilidade

Julio Trecenti

Insper

A decorative graphic on the right side of the slide. It consists of a black square, a red square, and a grey square with diagonal stripes. The red square is in the foreground, partially overlapping the black square. The striped square is behind the black square.

[Insper.edu.br](https://insper.edu.br)

O que é uma estatística

Estatística é um resumo da amostra

Uma estatística é um número calculado a partir dos dados da amostra, que resume uma característica dela.

muitos valores

uma coluna inteira da tabela, com um valor em cada linha



uma conta

somar e dividir, ordenar e pegar o do meio, contar quantos são



um número

o que você reporta, e o que o leitor vai guardar

Resumir é perder informação de propósito

O número que sobra não guarda nenhum caso individual: depois de calcular a média, os casos que a geraram somem. A pergunta da aula não é como calcular, é qual informação vale a pena perder, e isso depende do tipo da variável e da pergunta de pesquisa.

Amostra é o que está na sua tabela. População é o conjunto sobre o qual você quer falar: no caso de hoje, todos os acórdãos do TJSP. Esta aula descreve a amostra. Usar a amostra para afirmar algo sobre a população é inferência, e fica para a aula 18.

De uma coluna a um número

A base de hoje: 460 acórdãos de apelação cível do TJSP em que se discute indenização por dano moral, julgados de agosto de 2025 a agosto de 2026. Em 303 deles a ementa traz o valor arbitrado; nos outros 157, não.

[Baixar a tabela inteira em Excel · 460 linhas, 16 colunas](#)

a variável é a coluna

processo	comarca	valor_indenizacao
1002231-02.2023.8.26.0220	Guaratinguetá	sem valor
1005300-21.2025.8.26.0269	Itapetininga	R\$ 5.000
1000668-49.2025.8.26.0075	Bertioga	R\$ 6.779
1053430-56.2024.8.26.0114	Campinas	R\$ 8.000
1003716-79.2025.8.26.0248	Indaiatuba	R\$ 8.000
e mais 455 linhas		

as estatísticas são números que saem dela

contagem · acórdãos da comarca de São Paulo

142

`df["comarca"].value_counts()`

média · valor médio arbitrado

R\$ 7.935

`df["valor_indenizacao"].mean()`

Três coisas diferentes, e vale separar os nomes

A coluna inteira é a variável. Cada célula é um valor observado: R\$ 5.000 naquele acórdão de Itapetininga, e nenhum valor na primeira linha, porque aquela ementa não traz. O número que sai da conta sobre a coluna toda é a estatística, e ele não é o valor de nenhum acórdão em particular.

Duas perguntas sobre a mesma coluna

A pergunta de hoje é: quanto costuma valer uma indenização por dano moral no TJSP, e o quanto esse valor varia? Toda estatística descritiva responde a uma das duas metades.

POSIÇÃO

Onde fica o centro?

Qual é o valor típico da coluna. É o número que responde a pergunta “quanto costuma ser”.

média · mediana · moda · mínimo · máximo · quartis · proporção

VARIABILIDADE

Como os valores variam?

O quanto os casos se espalham em volta desse centro. É o número que diz se o típico representa alguém.

amplitude · intervalo interquartil · variância · desvio padrão

Uma sem a outra conta meia história

“A indenização típica é R\$ 5.000” parece uma resposta fechada, mas nesta mesma base o menor valor é R\$ 40,25 e o maior é R\$ 90.000. Sem dizer o quanto varia, o valor típico sugere uma regularidade que não existe.

Que conta cabe em cada tipo de variável

O tipo que você declarou na aula 2 decide o que dá para calcular. Média de categoria não é conta difícil, é conta sem sentido.

tipo da variável	posição	variabilidade
numérica contínua	média, mediana, mínimo, máximo, quartis	variância, desvio padrão, amplitude, IIQ
numérica discreta	as mesmas, e a moda passa a fazer sentido	variância, desvio padrão, amplitude, IIQ
categórica ordinal	mediana, moda, mínimo, máximo, quartis	amplitude e IIQ, que aqui saem como categorias
categórica nominal	moda, proporção de cada categoria	nenhuma das quatro
categórica binária	proporção, que aqui é a própria média	desvio padrão, que sai da proporção
identificador	nenhuma	nenhuma

Medidas de posição

Média


Soma de todos os valores dividida pelo número de casos. É o ponto de equilíbrio da distribuição: cada caso puxa a média na proporção do quanto ele vale.

média das indenizações

R\$ 7.935

Somar os 303 valores e dividir por 303.

```
df["valor_indenizacao"].mean()
```



Quem puxa a média são os casos extremos

Tirar da base o único acórdão de R\$ 90.000 derruba a média em R\$ 272. Um caso em 303 move o resumo de todos os outros, e é por isso que a média sozinha engana em valor de indenização.

Mediana


Ordene os valores do menor para o maior e pegue o do meio. Metade dos casos fica abaixo dela, metade acima.

mediana das indenizações

R\$ 5.000

Com 303 valores ordenados, é o valor da posição 152.

```
df["valor_indenizacao"].median()
```



A média é 59% maior que a mediana

A mediana só conta quantos casos estão de cada lado, e não o quanto eles valem. Trocar o maior acórdão por um de um milhão não a move um centavo. Em valor monetário no Direito, que quase sempre tem cauda longa à direita, é ela que responde “quanto costuma ser”.

A mediana feita na mão

Sete acórdãos da base, para ver a conta acontecer. Ordenar primeiro não é detalhe: é a conta inteira.

como vieram da tabela

R\$ 5.000	R\$ 6.779	R\$ 8.000	R\$ 15.000	R\$ 10.000	R\$ 1.621	R\$ 1.700
-----------	-----------	-----------	------------	------------	-----------	-----------

ordenados do menor para o maior

R\$ 1.621	R\$ 1.700	R\$ 5.000	R\$ 6.779	R\$ 8.000	R\$ 10.000	R\$ 15.000
-----------	-----------	-----------	-----------	-----------	------------	------------

o do meio é a mediana

R\$ 1.621	R\$ 1.700	R\$ 5.000	R\$ 6.779	R\$ 8.000	R\$ 10.000	R\$ 15.000
-----------	-----------	-----------	-----------	-----------	------------	------------

Com sete valores a mediana é o quarto; com 303, é o 152º

Se o número de casos for par não existe “o do meio”, e a mediana passa a ser a média dos dois centrais. Repare também que a média destes sete não é nenhum deles, enquanto a mediana é um valor que existe na base.

Moda


O valor que mais se repete na coluna. Serve sobretudo em variável categórica, onde média e mediana não existem, e pouco em numérica, onde os valores raramente se repetem.

valor mais frequente

R\$ 5.000

Aparece em 99 dos 303 acórdãos, 33% do total.

```
df["valor_indenizacao"].value_counts()
```



acórdãos com esse valor exato

Aqui a moda diz algo justamente porque não devia dizer nada

Se cada indenização fosse calculada caso a caso, dois acórdãos dificilmente cairiam no mesmo centavo. Mas 33% caem exatamente em R\$ 5.000, e os oito valores mais frequentes são todos redondos. O valor é arbitrado por ancoragem em números redondos, e não por cálculo. Nenhuma outra medida de posição enxerga isso.

Mínimo

O menor valor observado. Junto com o máximo, delimita onde a sua variável de fato vive.

menor valor da base

R\$ 40,25

O primeiro valor depois de ordenar a coluna.

```
df["valor_indenizacao"].min()
```



os seis menores valores da base

O mínimo é onde o erro de extração aparece primeiro

R\$ 40,25 não é uma indenização por dano moral. Naquele acórdão é o desconto mensal indevido no benefício previdenciário, e a regra que usamos pegou o primeiro valor em reais da ementa. Olhar o mínimo e o máximo antes de qualquer outra conta é o jeito mais barato de descobrir que a coluna mediu outra coisa.

Faltante também não é zero. 157 acórdãos não trazem valor e as contas de hoje ignoram essas linhas. Preencher zero derrubaria a média de R\$ 7.935 para R\$ 5.227 sem que nenhum juiz arbitrasse nada a menos.

No Projeto 1 vale o mesmo: em branco quando a informação não está na sentença, “não se aplica” quando a pergunta não se coloca, e nunca zero.

Máximo


O maior valor observado. Em base judicial, costuma ser um caso só, e costuma ser ele que aparece na manchete.

maior valor da base

R\$ 90.000

O último valor depois de ordenar a coluna.

```
df["valor_indenizacao"].max()
```



os seis maiores valores da base

Um caso, e ele mexe na média de todos

R\$ 90.000 é 18 vezes a mediana. Retirar esse único acórdão baixa a média em R\$ 272 e deixa a mediana exatamente onde estava. Máximo alto não é erro: é a informação de que a distribuição tem cauda, e de que a média vai precisar de companhia.

Quartis


Três cortes que partem a base ordenada em quatro pedaços com o mesmo número de casos: Q1 deixa 25% abaixo, Q2 é a mediana, Q3 deixa 75%. O exemplo é outra coluna da tabela.

Q1 · mediana · Q3, em palavras

110,75 · 161,5 · 236

A metade central das ementas tem entre 110,75 e 236 palavras.

```
df["n_palavras_ementa"].quantile([0.25, 0.5, 0.75])
```



Por que não usamos aqui a coluna do valor

Nela os três cortes não apareceriam separados: 99 dos 303 acórdãos valem exatamente R\$ 5.000, então Q1 e mediana caem os dois nesse valor. Não é falta de dados, é o próprio fenômeno. Repare também nas casas decimais: quando o corte cai entre duas observações, o pandas interpola, e por isso aparece meia palavra.

Proporção


A parte dividida pelo total. É a medida de posição das binárias, serve para cada categoria de uma categórica, e é a que mais aparece em trabalho empírico de Direito.

reconhecem dano moral

58,3%

268 dividido por 460 dá 0,583, ou 58,3%.

`df["tem_dano_moral"].mean()`



Serve para binária e serve para categórica

Em coluna de verdadeiro e falso, verdadeiro vale 1 e falso vale 0: somar dá quantos são verdadeiro, e dividir pelo total dá a fração. É por isso que `.mean()` devolve a proporção. Em coluna de categorias a conta é a mesma, uma proporção por categoria: 142 dos 460 acórdãos são da comarca de São Paulo, ou 30,9%, que sai de `value_counts(normalize=True)`.

Medidas de variabilidade

Amplitude e intervalo interquartil

As duas medem largura e saem em reais. O que muda é quantos casos cada uma escuta.

Amplitude · máximo menos mínimo


R\$ 89.959,75

Depende de exatamente dois acórdãos, os dois mais atípicos da base.

Intervalo interquartil · Q3 menos Q1

R\$ 5.000

A largura da metade central. Trocar o maior valor por outro dez vezes maior não a muda em nada.



A base inteira ocupa R\$ 89.959,75, e a metade dela cabe em R\$ 5.000

Quando esses dois números são tão diferentes, é sinal de cauda longa: a maioria dos casos está espremida e uns poucos estão muito longe.

Variância e desvio padrão

As duas medem o afastamento típico em relação à média. São a mesma informação em duas unidades diferentes.

Variância · média dos quadrados dos desvios


70.361.646

Sai em reais ao quadrado, unidade que não existe no mundo, e por isso quase nunca se reporta.

Desvio padrão · raiz da variância

R\$ 8.388,18

A raiz devolve a unidade original, em reais, e é isso que o torna reportável.



Um desvio padrão de R\$ 8.388 contra uma média de R\$ 7.935

Quando o desvio padrão passa da média, a faixa habitual de um desvio para baixo cai no negativo, e valor de indenização não é negativo. Isso é o aviso de que a distribuição é assimétrica e de que mediana e IIQ descrevem melhor essa coluna.

A mesma coluna, todas as estatísticas

valor_indenizacao, os 303 acórdãos que têm valor: as contas abaixo ignoram os 157 sem valor. Dizer sobre quantos casos a estatística foi calculada faz parte de reportá-la.

POSIÇÃO

mínimo	R\$ 40,25
Q1	R\$ 5.000
mediana	R\$ 5.000
moda	R\$ 5.000 (99 casos)
média	R\$ 7.935,26
Q3	R\$ 10.000
máximo	R\$ 90.000
proporção acima de R\$ 10 mil	7,6% (23 casos)


VARIABILIDADE

amplitude	R\$ 89.959,75
intervalo interquartil	R\$ 5.000
variância	70.361.646 reais ²
desvio padrão	R\$ 8.388,18

A conta que a pergunta pede é uma comparação


Quase sempre é a mesma medida separada por grupo: mediana por assunto dá R\$ 8.000 em “Associação” contra R\$ 5.000 em “Bancários”. É uma linha de pandas, e é a aula 4; hoje basta dizer a conta.

```
df.groupby("assunto")["valor_indenizacao"].median()
```



O mapa da aula em um slide

Comece pela coluna, descubra o tipo, e o tipo diz quais contas estão disponíveis.



Projeto 1, na segunda hora de hoje

Uma hora, em grupo. Você vai fazer o caminho inverso do desta aula: partir de sentenças em texto e decidir quais colunas precisam existir para que essas contas sejam possíveis.

Escolher o tema e explorar as sentenças

cinco temas, cada um com uma pergunta de pesquisa e 10 sentenças reais de primeiro grau do TJSP. Três ou quatro leituras bastam.

Definir as variáveis

nome, tipo, papel na pergunta e de onde tirar. É a definição operacional: o texto que faria duas pessoas lerem a mesma sentença e registrarem o mesmo valor.

Rodar o modelo e dizer que estatísticas calcularia

o modelo lê cada sentença e preenche as suas colunas. Depois você diz que contas faria, e elas precisam caber nos tipos que você declarou.

Avaliar, ajustar e entregar

avaliações pela rubrica, que está visível desde o começo. Entrega no BlackBoard: a tabela em CSV e a documentação em JSON.

A rubrica avalia a qualidade das escolhas, e não a quantidade de variáveis. Lista curta e bem definida vale mais do que lista longa.