

Ciência de Dados Aplicada ao Direito II

Aula 4: encadear operações

E como ler a documentação de uma função

Julio Trecenti

Insper

[Insper.edu.br](https://insper.edu.br)

O que você já sabe fazer

Das aulas 2 e 3. Vale deixar este slide aberto enquanto você programa.

função	o que faz	onde apareceu
<code>pd.read_csv(caminho)</code>	lê um arquivo e devolve a tabela	aula 2
<code>.info()</code>	colunas, faltantes e dtype de cada uma	aula 2
<code>.nunique()</code>	quantos valores distintos por coluna	aula 2
<code>.astype("string")</code>	converte a coluna, aqui para texto	aula 2
<code>pd.to_datetime(coluna)</code>	de texto para data	aula 2
<code>.dt.year, .dt.month, .dt.days</code>	pedaços de uma data ou duração	aula 2
<code>pd.Categorical(coluna, categories=, ordered=)</code>	declara as categorias e a ordem	aula 2
<code>.cat.add_categories()</code> e <code>.fillna()</code>	abre uma categoria e preenche	aula 2
<code>pd.cut(coluna, bins=, labels=)</code>	de numérica para faixas	aula 2
<code>.describe()</code>	resumo rápido de uma coluna numérica	aula 3
<code>.mean(), .median(), .mode()</code>	medidas de posição	aula 3
<code>.std(ddof=), .var(), .quantile()</code>	medidas de dispersão	aula 3
<code>.value_counts(normalize=)</code>	contagem ou proporção por categoria	aula 3
<code>df[condicao]</code>	índice lógico, o filtro mais explícito	aula 3

O que entra hoje

função	o que faz	para quê
<code>.query("coluna == 'valor'")</code>	escolhe linhas por condição	filtrar
<code>.dropna(subset=[...])</code>	descarta linhas sem valor	filtrar
<code>.assign(nova=lambda d: ...)</code>	cria coluna	transformar
<code>[["a", "b"]]</code>	escolhe colunas	transformar
<code>.sort_values("a", ascending=False)</code>	ordena	transformar
<code>.groupby("a").agg(s=("b", "mean"))</code>	uma linha por grupo	agregar
<code>.reset_index()</code>	tira o agrupamento do índice	agregar
<code>.head(n)</code>	corta as primeiras linhas	ver

O formato

```
resultado = (  
    tabela  
    .operacao_1(...)  
    .operacao_2(...)  
)
```

Os parênteses existem para você poder quebrar a linha: sem eles, a quebra encerra o comando.

Dentro do encadeamento, olhe para as colunas com `lambda d:`, e nunca pelo nome da tabela original.

Toda função tem mais do que você usa

pandas.DataFrame.sort_values

```
DataFrame.sort_values(by, *, axis=0, ascending=True, inplace=False, kind='quicksort', na_position='last', ignore_index=False, key=None)
```

[\[source\]](#)

Sort by the values along either axis.

Parameters:

by : *str or list of str*

Name or list of names to sort by.

- if *axis* is 0 or *'index'* then *by* may contain index levels and/or column labels.
- if *axis* is 1 or *'columns'* then *by* may contain column levels and/or index labels.

axis : *"{0 or 'index', 1 or 'columns'}", default 0*

Axis to be sorted.

ascending : *bool or list of bool, default True*

Sort ascending vs. descending. Specify list for multiple sort orders. If this is a list of bools, must match the length of the *by*.

inplace : *bool, default False*

If True, perform operation in-place.

Você escreve


```
.sort_values("pena_anos",  
             ascending=False)
```

A função aceita oito parâmetros.

A primeira linha da página é a assinatura, e ela responde três perguntas: quais argumentos existem, em que ordem, e qual o valor padrão de cada um.

Repare no `na_position='last'`: é ele que decide onde ficam os valores faltantes quando você ordena. Ninguém adivinha isso, está escrito ali.

As quatro partes de uma página



Comece pelos Examples e volte para os Parameters quando precisar mudar alguma coisa.

Parameters

o que a função aceita, com o tipo e o padrão de cada um

Returns

o que ela devolve, e isso decide o que dá para encadear depois


See also

as funções vizinhas, que muitas vezes são a que você queria

Examples

código pronto para copiar e adaptar, no fim da página

Onde procurar



The screenshot shows the pandas DataFrame API reference page. The left sidebar lists various DataFrame methods and attributes, including `pandas.DataFrame`, `pandas.DataFrame.index`, `pandas.DataFrame.columns`, `pandas.DataFrame.dtypes`, `pandas.DataFrame.info`, `pandas.DataFrame.select_dtypes`, `pandas.DataFrame.values`, `pandas.DataFrame.axes`, `pandas.DataFrame.ndim`, `pandas.DataFrame.size`, `pandas.DataFrame.shape`, `pandas.DataFrame.memory_usage`, `pandas.DataFrame.empty`, `pandas.DataFrame.set_flags`, `pandas.DataFrame.astype`, `pandas.DataFrame.convert_dtypes`, `pandas.DataFrame.infer_objects`, `pandas.DataFrame.copy`, and `pandas.DataFrame.to_numpy`. The main content area shows the DataFrame constructor, attributes, and underlying data. The right sidebar lists topics covered on the page, including `Constructor`, `Attributes and underlying data`, `Conversion`, `Indexing, iteration`, `Binary operator functions`, `Function application, GroupBy & window`, `Computations / descriptive stats`, `Reindexing / selection / label manipulation`, `Missing data handling`, `Reshaping, sorting, transposing`, `Combining / comparing / joining / merging`, `Time Series-related`, `Flags`, `Metadata`, `Plotting`, `Sparse accessor`, and `Serialization / IO / conversion`.

DataFrame	
Constructor	
<code>DataFrame</code> ([data, index, columns, dtype, copy])	Two-dimensional, size-mutable, potentially heterogeneous tabular data.
Attributes and underlying data	
Axes	
<code>DataFrame.index</code>	The index (row labels) of the DataFrame.
<code>DataFrame.columns</code>	The column labels of the DataFrame.
<code>DataFrame.dtypes</code>	Return the dtypes in the DataFrame.
<code>DataFrame.info</code> ([verbose, buf, max_cols, ...])	Print a concise summary of a DataFrame.
<code>DataFrame.select_dtypes</code> ([include, exclude])	Return a subset of the DataFrame's columns based on the column dtypes.
<code>DataFrame.values</code>	Return a Numpy representation of the DataFrame.

No site

pandas.pydata.org, em API reference. A lista à direita da página separa por assunto: descriptive stats, groupby, reshaping, missing data.

No notebook

escreva o nome da função com ? no fim e rode a célula. A documentação abre ali mesmo, sem trocar de janela.

Na busca

procure por "pandas" mais o que você quer fazer, em inglês. O primeiro resultado costuma ser a página oficial.

`criminal.groupby?`

`help(pd.cut)`