


Ciência de Dados Aplicada ao Direito II

Aula 5: o pipeline e a gramática de gráficos

E a Gincana do Pipeline

Julio Trecenti

Insper



Insper.edu.br

O plano de hoje

A aula 4 ficou nas medidas resumo e sobrou a manipulação de dados. Hoje ela sai, junto com os gráficos, e quase toda a aula é de pé.

25 min

Slides

os cinco verbos do pandas e a gramática de gráficos. É a única exposição da aula.

55 min

Gincana do Pipeline

três aquecimentos e seis rodadas em grupo, com cartas de papel. Todo grupo que acertar pontua.

15 min

Notebook

vocês digitam os pipelines que montaram no papel e veem rodar.

8 min

Fechamento

prêmios e o que cai no Projeto 02, quinta.

A pergunta de hoje

Nas apelações criminais do TJSP, a proporção de acórdãos que mencionam reincidência varia conforme o regime inicial fixado?

A base tem 475 acórdãos. Três colunas resolvem a pergunta:

coluna	o que é	o estado dela
regime_inicial	aberto, semiaberto ou fechado, lido da ementa	vazio em 142 acórdãos
houve_reincidencia	verdadeiro ou falso, lido da ementa	completo
pena_anos	a pena em anos, lida da ementa	vazio em 55%, e com valores implausíveis

Guardem a terceira linha. A pena foi lida pegando o primeiro número seguido de "anos", e às vezes o número errado. Isso aparece já no aquecimento.

Do jeito da aula 3

Uma variável nova a cada operação. Funciona, e responde a pergunta:

```
apelacoes = criminal[criminal["classe"] == "Apelação Criminal"]
com_regime = apelacoes.dropna(subset=["regime_inicial"])
fechado = com_regime[com_regime["regime_inicial"] == "fechado"]
semiaberto = com_regime[com_regime["regime_inicial"] == "semiaberto"]
aberto = com_regime[com_regime["regime_inicial"] == "aberto"]

pd.Series({
    "fechado": fechado["houve_reincidencia"].mean(),
    "semiaberto": semiaberto["houve_reincidencia"].mean(),
    "aberto": aberto["houve_reincidencia"].mean(),
})
```

Seis variáveis

que existem só para chegar num resultado

Nomes que não dizem nada

com_regime vai ser reaproveitado por engano daqui a três células

Não escala

um quarto regime obriga a escrever mais uma linha, e a lembrar de incluí-la

A mesma coisa, encadeada

Nenhuma variável intermediária, e a ordem das operações é a ordem das linhas. Leia de cima para baixo:

```
(  
    criminal  
    .query("classe == 'Apelação Criminal'")  
    .dropna(subset=["regime_inicial"])  
    .groupby("regime_inicial")  
    .agg(proporcao=("houve_reincidencia", "mean"))  
)
```

pegue a tabela criminal,
fique só com as apelações,
descarte quem não tem regime,
faça as pilhas por regime,
e calcule a proporção de cada pilha.

Por que os parênteses

Dentro de um par de parênteses o python deixa você quebrar a linha à vontade. Sem eles, criminal seguido de quebra de linha e .query(...) é erro de sintaxe. Os parênteses existem só para você pôr uma operação por linha.

Os cinco verbos

Cinco operações resolvem quase toda análise descritiva. As cartas da gincana são estas cinco, mais duas de apoio.

operação	o que faz	o detalhe que pega
<code>.query("coluna == 'valor'")</code>	escolher linhas	a condição vai escrita como texto
<code>[["a", "b"]]</code>	escolher colunas	dois pares de colchetes; um só devolve a coluna solta
<code>.sort_values("a", ascending=False)</code>	ordenar	ascending=False põe o maior primeiro
<code>.groupby("a").agg(nome=("b", "mean"))</code>	agregar por grupo	uma linha por grupo, e o <code>.reset_index()</code> devolve a coluna
<code>.assign(nova=tabela["b"] > 8)</code>	criar uma coluna	vem antes de qualquer operação que use a coluna nova
<code>.dropna(subset=["a"])</code>	apoio: descartar vazios	só as linhas em que aquela coluna está vazia
<code>.head(n)</code>	apoio: as n primeiras	da tabela como ela está naquele ponto

A coluna criada pelo `.assign()` só existe da linha seguinte em diante. Por isso ele vem antes de quem for usar ela.

A ordem importa

As duas células têm exatamente as mesmas operações. Só trocam duas linhas de lugar.

ordena e depois corta

```
(  
    criminal  
    .sort_values("pena_anos", ascending=False)  
    .head(5)  
)
```

As cinco maiores penas da base. É o que a pergunta pedia.

corta e depois ordena

```
(  
    criminal  
    .head(5)  
    .sort_values("pena_anos", ascending=False)  
)
```

Cinco acórdãos quaisquer, os cinco primeiros da tabela, ordenados entre si. Nada a ver com as maiores penas.

O `.head(5)` não sabe o que você queria. Ele pega as cinco primeiras linhas da tabela como ela está naquele ponto.

O que é um gráfico

Antes de desenhar qualquer coisa, uma definição. Ela cabe numa frase, e a frase organiza tudo o que vem depois.

Um gráfico estatístico é um mapeamento de variáveis (colunas) em aspectos estéticos de formas geométricas.

Quatro palavras fazem o trabalho:



mapeamento

uma ligação: cada valor da coluna vira um valor visual



variáveis (colunas)

o que sai da tabela, e nada mais



aspectos estéticos

posição, altura, cor, tamanho, forma



formas geométricas

barra, ponto, linha, caixa

Note o que a definição NÃO diz: nada sobre que biblioteca, que cor bonita ou que tipo de gráfico. Ela diz o que precisa ser decidido.

A gramática de gráficos

A definição vira código quase palavra por palavra. São três camadas, somadas com +, e todas as três são obrigatórias.

gráfico = dados + estética + geometria

dados

de que tabela saem as variáveis

`ggplot(penas)`

estética

que variável vira que aspecto visual

`aes(x="regime")`

geometria

que forma aparece na tela

`geom_bar()`

É a mesma ideia dos cinco verbos: lá, operações somadas com ponto. Aqui, camadas somadas com mais.

Uma camada de cada vez

1. os dados

```
ggplot(penas)
```

Um retângulo vazio. Já é um gráfico válido: só não dissemos que variável vira o quê.

2. a estética


```
ggplot(penas)  
+ aes(x="regime")
```



O mapeamento aconteceu: regime virou posição no eixo. Ainda não há forma nenhuma.

3. a geometria

```
ggplot(penas)  
+ aes(x="regime")  
+ geom_bar()
```




A forma apareceu. `geom_bar()` conta as linhas de cada categoria sozinho: não existe `groupby` antes.

Pintar não é mapear

A distinção mais importante da aula, e a que mais gera erro. Depende só de o argumento estar dentro ou fora do aes().

fill FORA do aes(): é tinta


```
ggplot(penas)
+ aes(x="regime")
+ geom_bar(fill="#E50505")
```



Vale para todas as barras, não representa nada, e não gera legenda.

fill DENTRO do aes(): é variável

```
ggplot(penas)
+ aes(x="regime", fill="houve_reincidencia")
+ geom_bar()
```



Cada barra se reparte, e aparece legenda: agora a cor mapeia uma variável.

A regra vale para toda estética

**Dentro do aes(), o argumento recebe o NOME DE UMA COLUNA.
Fora do aes(), o argumento recebe um VALOR FIXO.**

Trocar os dois de lugar é o erro mais comum de quem começa, e o sintoma é sempre um destes dois:

Apareceu uma legenda que você não queria

você pôs `fill="azul"` dentro do `aes()`, e o plotnine criou uma variável com um valor só, chamada "azul"

Sumiu a legenda que você queria

você pôs `fill="regime"` fora do `aes()`, e o plotnine tentou pintar tudo de uma cor chamada "regime", que não existe

Os aspectos estéticos mais usados: `x`, `y`, `fill` (preenchimento), `color` (traço), `size` (tamanho), `alpha` (transparência).

Geometrias e tipos de variáveis

Hoje só variáveis sozinhas. Quinta-feira, duas de cada vez.

a variável	a pergunta	a geometria	o detalhe
uma categórica	quantos casos em cada categoria	<code>geom_bar()</code>	conta sozinho: a altura sai da contagem
uma categórica, altura já calculada	mostrar um valor por categoria	<code>geom_col()</code>	usa a coluna que você mapeou em y
uma numérica	como os valores se distribuem	<code>geom_histogram(bins=)</code>	o número de caixas muda a leitura
uma numérica	a mesma distribuição, alisada	<code>geom_density()</code>	sem o degrau das caixas
uma numérica	mediana, quartis e pontos fora	<code>geom_boxplot()</code>	resume, e por isso esconde a forma

`geom_bar()` conta. `geom_col()` usa a altura que você deu. Confundir os dois é a pegadinha da última rodada.

Gincana do Pipeline

Cada mesa tem um baralho de 42 cartas, um tabuleiro e uma folha de resposta. Na frente da carta está o código; no verso, o que ele faz. Virar a carta é permitido, e é o ponto da atividade.

1

Três aquecimentos

de duas ou três cartas, que não pontuam. São para pegar a mecânica.

2

Eu projeto o problema

e digo quantas cartas a resposta tem.

3

A mesa monta no tabuleiro

uma carta por linha, na ordem em que o python executa.

4

Levanta a placa

e escreve a ordem na folha de resposta.

5

Escreve a linha do descarte

uma carta que ficou de fora, e por que ela não serve.

O relator muda a cada rodada: é quem explica se a mesa for chamada.

Como se pontua

3 pontos · ordem certa, dentro do tempo. Vale igual para o primeiro e para o último que acertar.

+1 ponto · a linha do descarte, se ela disser por quê.

+1 ponto · para os três primeiros a levantar a placa com a ordem certa.

Dois prêmios

A lane com mais pontos somados, e um grupo sorteado entre todos os que pontuaram em quatro rodadas ou mais.

Aquecimento A1: A tabela, cinco primeiras linhas

2 cartas

não pontua

A tabela inteira, mostrando só as cinco primeiras linhas.

Procurem só nas cartas turquesa.

Aquecimento A1: a resposta

P01 > P20

```
(  
  criminal  
  .head(5)  
)
```

O QUE O AQUECIMENTO ENSINA

A mecânica, e mais nada: achar a carta, pôr na linha 1 do tabuleiro, levantar a placa. Todo encadeamento começa pelo nome da tabela.

Aquecimento A2: Só os acórdãos de tráfico

2 cartas

não pontua

Fique só com os acórdãos de tráfico.

Procurem só nas cartas turquesa.

Aquecimento A2: a resposta

P01 > P05

```
(  
  criminal  
  .query("eh_trafico")  
)
```

O QUE O AQUECIMENTO ENSINA

Que existem cartas parecidas e é preciso ler as duas. Aqui é bom rodar a errada na tela e mostrar a tabela vazia.

Aquecimento A3: As cinco maiores penas

3 cartas

não pontua

Todos os acórdãos, enfileirados da maior pena para a menor, e só os cinco primeiros.

Procurem só nas cartas turquesa.

Aquecimento A3: a resposta

P01 > P15 > P20

```
(  
    criminal  
    .sort_values("pena_anos", ascending=False)  
    .head(5)  
)
```

O QUE O AQUECIMENTO ENSINA

A primeira vez em que a ordem decide. Vale rodar as duas na tela, lado a lado: é o slide 'a ordem importa' na mão deles.

E dá de brinde a qualidade do dado: as cinco maiores penas da base são um furto, um estelionato, uma apropriação indébita e dois homicídios, com penas de até 75 anos. A leitura da ementa pegou o primeiro número seguido de "anos", e às vezes pegou o número errado. Deixe a sala rir e pergunte de onde veio o 75.

Rodada 1: Quantos em cada regime

5 cartas

5 min

Quantos acórdãos há em cada regime inicial? Descarte os acórdãos em que o regime não foi encontrado na ementa, e devolva uma tabela com uma linha por regime.

Procurem só nas cartas turquesa.

Rodada 2: As cinco maiores penas do tráfico

5 cartas

8 min

Entre os acórdãos de tráfico, quais são as cinco maiores penas? Mostre processo, comarca e pena.

Procurem só nas cartas turquesa.

Rodada 3: A capital julga diferente?

7 cartas

10 min

A capital julga diferente do interior? Crie a coluna que separa os dois e devolva, para cada grupo: quantos acórdãos, a pena mediana e a proporção com reincidência. Descarte quem não tem pena e jogue fora as penas acima de 30 anos.


Procurem só nas cartas turquesa.

Rodada 4: As barras do regime

4 cartas

7 min

Monte o código que produz este gráfico. A tabela é penas.




Procurem só nas cartas roxas.

Rodada 5: Pintar não é mapear

4 cartas

8 min

Este gráfico responde a outra pergunta. Saindo do código da rodada 4, troque exatamente duas cartas para chegar nele.




Procurem só nas cartas roxas.

Rodada 6: Do pandas ao gráfico

9 cartas

12 min

Este gráfico precisa de dois blocos: primeiro um pipeline de pandas que constrói a tabela resumo, e depois o gráfico que sai dela. Monte os dois no tabuleiro.




Procurem só nas as duas cores.

Rodada bônus: O histograma repartido

5 cartas

8 min

Só se sobrar tempo. Monte o código deste gráfico. A tabela é penas.



Procurem só nas cartas roxas.

Quinta-feira

Aula 6, dia 27/08, das 16h30 às 18h30.

Primeira hora

Gráficos de duas variáveis

Duas numéricas, uma numérica e uma categórica, duas categóricas. É a mesma gramática de hoje, com mais uma variável mapeada.

Segunda hora

Projeto 02, individual, valendo nota

Você recebe blocos de pandas e de plotnine fora de ordem, e organiza na ordem em que devem rodar. É exatamente a gincana de hoje, sozinho e no computador. Entrega no mesmo dia.

Para chegar pronto: rode o notebook da aula 5 inteiro, principalmente a parte que você não digitou em sala.