


Ciência de Dados Aplicada ao Direito II

Aula 6: gráficos de duas variáveis

O par de tipos escolhe a geometria

Julio Trecenti

Insper

A decorative graphic on the right side of the slide. It consists of a black square, a red square, and a grey square with diagonal stripes. The red square is in the foreground, partially overlapping the black square. The striped square is behind the black square.

[Insper.edu.br](https://insper.edu.br)

De onde viemos: o encadeamento

Uma análise é uma sequência de operações somadas com ponto. Cada uma recebe a tabela que a anterior devolveu.

```
.query("coluna == 'valor'")
```

escolher linhas

```
[["a", "b"]]
```

escolher colunas: dois pares de colchetes

```
.sort_values("a", ascending=False)
```

ordenar

```
.groupby("a").agg(nome=("b", "mean"))
```

uma linha por grupo

```
.assign(nova=tabela["b"] > 8)
```

criar uma coluna

e sempre entre parênteses

```
(  
    criminal  
    .query("eh_trafico")  
    .sort_values("pena_anos", ascending=False)  
    [["processo", "comarca", "pena_anos"]]  
    .head(5)  
)
```

A ordem é o conteúdo.

Filtrar antes ou depois de agrupar dá números diferentes, e uma operação só usa coluna que já existe naquele ponto.

Os parênteses são o que permitem quebrar a linha e ler o encadeamento de cima para baixo, uma operação por linha.

De onde viemos: a gramática

Um gráfico estatístico é um mapeamento de variáveis (colunas) em aspectos estéticos de formas geométricas.

1. os dados

de qual tabela o gráfico sai

```
ggplot(penas)
```

2. a estética


qual coluna vira qual aspecto do desenho

```
+ aes(x="regime")
```

3. a geometria

que forma ocupa essas posições

```
+ geom_bar()
```



Dentro do `aes()`, nome de coluna. Fora do `aes()`, valor fixo.

É a distinção que mais gera erro, e ela vale para `x`, `y`, `fill`, `color`, `size` e `alpha`.

A coluna que não estava na tabela

Ficou faltando uma rodada da gincana, e ela é a mais usada hoje: a coluna que responde à pergunta nem sempre existe na base.

a coluna nasce no meio do caminho

```
(
    criminal
    .assign(eh_capital=criminal["comarca"] == "São Paulo")
    .groupby("eh_capital")
    .agg(n=("processo", "size"))
    .reset_index()
)
```

A base tem comarca, e não tem eh_capital.

Nenhuma coluna responde “capital ou interior”.

.assign() cria a coluna sem quebrar o encadeamento.

Por isso ele cabe no meio do pipeline.

Ele vem ANTES do .groupby() que usa a coluna.

A coluna precisa existir para ser agrupada. É a única ordem que não pode trocar.

o que isso devolve

eh_capital	n
False	378
True	97


Duas linhas, porque a coluna nova só tem dois valores. O `.reset_index()` é o que traz `eh_capital` para dentro da tabela: sem ele, ela vira rótulo de linha e some do alcance do `aes()`.

Contagem vs proporção

A outra rodada que ficou. Duas perguntas parecidas, dois gráficos diferentes, e a diferença está em quem faz a conta.

quantos acórdãos em cada regime?


```
ggplot(penas, aes(x="regime"))  
+ geom_bar()
```



geom_bar() conta as linhas sozinho. A altura sai da contagem, e não existe coluna y.

que proporção é reincidente?

```
resumo = (  
  penas.groupby("regime", as_index=False)  
  .agg(prop=("houve_reincidencia", "mean"))  
)
```



Depois vem ggplot(resumo) + aes(x="regime", y="prop") + geom_col(). A altura já está na tabela, e a média de uma coluna de verdadeiro/falso é a proporção de verdadeiros.

De uma variável para duas

Na aula 5 todo gráfico tinha uma coluna só. Hoje entram duas, e a gramática não muda: o `aes()` passa a receber dois nomes.

O par de tipos escolhe a geometria.

Antes de escrever qualquer coisa, diga em voz alta o tipo das duas variáveis.

numérica × numérica

quando uma cresce, o que a outra faz

`geom_point()`

numérica × categórica

a distribuição muda entre as categorias

`geom_boxplot()`

categórica × categórica

a composição muda entre as categorias

`geom_bar(position="fill")`

Uma forma mais curta de escrever

O `aes()` pode ir dentro do `ggplot()`, como segundo argumento. As duas células produzem exatamente o mesmo gráfico.

a forma da aula 5

```
(  
  ggplot(penas)  
  + aes(x="regime")  
  + geom_bar()  
)
```

Separa as camadas, e é melhor para aprender.

a forma curta

```
(  
  ggplot(penas, aes(x="regime"))  
  + geom_bar()  
)
```

É a mais comum na prática, e a que você vai achar na internet e nos exercícios.

A regra da aula 5 continua valendo, sem exceção.

Nome de coluna dentro do `aes()`, valor fixo fora dele. Mudou onde o `aes()` está escrito, não o que ele faz.

Duas categóricas: o position

As mesmas duas variáveis, a mesma geometria, três gráficos diferentes. Só muda o argumento position.

position="stack"

```
(
  ggplot(
    penas,
    aes(x="regime",
        fill="houve_reincidencia")
  )
  + geom_bar(position="stack")
)
```

o padrão: quantos casos, empilhados

position="fill"

```
(
  ggplot(
    penas,
    aes(x="regime",
        fill="houve_reincidencia")
  )
  + geom_bar(position="fill")
)
```

todas as barras com altura 1: proporção

position="dodge"


```
(
  ggplot(
    penas,
    aes(x="regime",
        fill="houve_reincidencia")
  )
  + geom_bar(position="dodge")
)
```

lado a lado: contagem, sem empilhar


Os três, lado a lado

A resposta é o fill: ele é o único em que a comparação entre regimes não é atrapalhada pelo tamanho de cada grupo.


position="stack"



position="fill"



position="dodge"



position="fill" esconde quanta gente tem em cada barra.

Uma barra com 4 casos e outra com 400 ficam do mesmo tamanho. Quando a proporção interessa, ele é o certo; quando o tamanho do grupo importa, ele mente por omissão.

Numérica e categórica: caixas

Uma caixa por categoria. Cada caixa é o resumo da aula 3, desenhado.

```
(  
  ggplot(penas, aes(x="regime", y="pena_anos"))  
  + geom_boxplot()  
  + coord_flip()  
)
```

a linha do meio

a mediana

a caixa


do primeiro ao terceiro quartil

os fios

até os valores ainda típicos

os pontos soltos

os distantes do resto




Uma variável: os três casos

O tipo da variável escolhe a geometria. Estes são todos os casos de uma variável sozinha.

categórica · frequência


```
ggplot(penas, aes(x="regime"))  
+ geom_bar()
```



`geom_bar()` conta as linhas sozinho: não existe coluna y.

categórica · frequência relativa


```
ggplot(freq, aes(x="regime", y="prop"))  
+ geom_col()
```



A divisão é feita antes, no pandas. A altura já vem pronta na tabela, então o geom é `geom_col()`.

numérica · distribuição

```
ggplot(penas, aes(x="pena_anos"))  
+ geom_histogram(bins=20)
```




Numérica não tem categoria para contar: o histograma corta em faixas e conta cada faixa.

Duas variáveis: os quatro casos

Agora o par de tipos escolhe a geometria. E quando o eixo x é tempo, o par muda de nome: vira série.

categórica × categórica


```
aes(x="regime",  
fill="houve_reincidencia")  
+ geom_bar(position="fill")
```



Barras repartidas. Em proporção com fill, em contagem com dodge.

categórica × numérica


```
aes(x="regime", y="pena_anos")  
+ geom_boxplot() + coord_flip()
```



Uma caixa por categoria, comparando a distribuição inteira.

numérica × numérica

```
aes(x="n_palavras_ementa",  
y="pena_anos")  
+ geom_point() +  
geom_smooth(method="lm")
```



Um ponto por linha, e a reta resume a direção da nuvem.

numérica × tempo

```
aes(x="mes", y="n")  
+ geom_line() + geom_point()
```



Com o tempo no eixo x, a linha liga os pontos e mostra a trajetória.

Uma variável: qual gráfico

Os mesmos casos, agora em tabela, para consultar depois. Entram também duas geometrias que só aparecem no notebook.

a variável	a pergunta	a geometria	o detalhe
categórica	quantos casos em cada categoria	geom_bar()	conta sozinho: não existe coluna y
categórica, altura já calculada	um valor por categoria	geom_col()	usa a coluna que você mapeou em y
numérica	como os valores se distribuem	geom_histogram(bins=)	o número de faixas muda a leitura
numérica	a mesma distribuição, alisada	geom_density()	sem o degrau das faixas
numérica	mediana, quartis e pontos fora	geom_boxplot()	resume, e por isso esconde a forma

A pergunta a fazer antes de escolher: a altura é uma contagem, ou uma conta que eu já fiz?

Contagem é geom_bar(). Conta pronta é geom_col(). Todo o resto decorre do tipo da variável.


Que gráfico para que par

as duas variáveis	a pergunta	a geometria
numérica × numérica	quando uma cresce, o que a outra faz	<code>geom_point() + geom_smooth()</code>
numérica × numérica, x é tempo	como evolui	<code>geom_line()</code>
numérica × categórica	a distribuição muda entre as categorias	<code>geom_boxplot()</code>
numérica × categórica, já resumida	comparar um valor por categoria	<code>geom_col()</code>
categórica × categórica	a composição muda entre as categorias	<code>geom_bar(position="fill")</code>
categórica × categórica, contagem	quantos casos em cada combinação	<code>geom_bar(position="dodge")</code>

A terceira variável, quando existe, entra em color ou fill dentro do `aes()`, ou em `facet_wrap()` quando ficar carregado.

From data to viz

As tabelas destes slides cobrem o que a disciplina usa. Para o resto, existe uma árvore de decisão pronta: você diz que tipo de dado tem, e ela leva ao gráfico.



data-to-viz.com

Escolha o tipo de dado no alto (numérico, categórico, os dois, mapa, rede, série temporal) e siga a árvore.

Cada gráfico do fim leva a uma página com o código, e a uma lista do que costuma dar errado naquele tipo.

A seção CAVEATS é a melhor parte: é um catálogo de gráficos que enganam, com o motivo.