


Ciência de Dados Aplicada ao Direito II

Aula 6: gráficos de duas variáveis

E o Projeto 02, na segunda hora

Julio Trecenti

Insper

A decorative graphic on the right side of the slide. It consists of several overlapping squares. One square is black, another is red, and a third is light gray with dark gray diagonal stripes. The red square is in the foreground, partially overlapping the black and striped squares.

[Insper.edu.br](https://insper.edu.br)

O plano de hoje

Aula curta e projeto longo. A segunda hora inteira é o Projeto 02, em grupo e valendo nota.

22 min

Slides

as duas rodadas que faltaram da gincana, e de uma variável para duas.

25 min

Notebook

as geometrias novas e as três operações de pandas que o projeto usa.

60 min

Projeto 02

no app da disciplina. Você organiza blocos de pandas e de plotnine na ordem em que devem rodar.

5 min

Fechamento

entrega e o que vem na aula 7.

A coluna que não estava na tabela

Ficou faltando uma rodada da gincana, e ela é a mais usada hoje: a coluna que responde à pergunta nem sempre existe na base.

a coluna nasce no meio do caminho

```
(  
    criminal  
    .assign(eh_capital=criminal["comarca"] == "São Paulo")  
    .groupby("eh_capital")  
    .agg(n=("processo", "size"))  
    .reset_index()  
)
```

A base tem comarca, e não tem eh_capital.


Nenhuma coluna responde “capital ou interior”.

.assign() cria a coluna sem quebrar o encadeamento.

Por isso ele cabe no meio do pipeline.

Ele vem ANTES do .groupby() que usa a coluna.

A coluna precisa existir para ser agrupada. É a única ordem que não pode trocar.




De quebra: a pena sozinha, em faixas. Uma variável numérica pede histograma, e é essa leitura de distribuição que o boxplot de hoje resume.

Contar não é medir

A outra rodada que ficou. Duas perguntas parecidas, dois gráficos diferentes, e a diferença está em quem faz a conta.

quantos acórdãos em cada regime?


```
ggplot(penas, aes(x="regime"))  
+ geom_bar()
```



`geom_bar()` conta as linhas sozinho. A altura sai da contagem, e não existe coluna y.

que proporção é reincidente?

```
resumo = penas.groupby("regime", as_index=False)  
.agg(prop=("houve_reincidencia", "mean"))  
ggplot(resumo, aes(x="regime", y="prop")) + geom_col()
```



A altura já está calculada na tabela, então o geom é `geom_col()`. E a média de uma coluna de verdadeiro/falso é exatamente a proporção de verdadeiros.

De uma variável para duas

Na aula 5 todo gráfico tinha uma coluna só. Hoje entram duas, e a gramática não muda: o `aes()` passa a receber dois nomes.

O par de tipos escolhe a geometria.

Antes de escrever qualquer coisa, diga em voz alta o tipo das duas variáveis.

numérica × numérica

quando uma cresce, o que a outra faz

`geom_point()`

numérica × categórica

a distribuição muda entre as categorias

`geom_boxplot()`

categórica × categórica

a composição muda entre as categorias

`geom_bar(position="fill")`

Uma forma mais curta de escrever

O `aes()` pode ir dentro do `ggplot()`, como segundo argumento. As duas células produzem exatamente o mesmo gráfico.

a forma da aula 5

```
(  
  ggplot(penas)  
  + aes(x="regime")  
  + geom_bar()  
)
```

Separa as camadas, e é melhor para aprender.

a forma do Projeto 02

```
(  
  ggplot(penas, aes(x="regime"))  
  + geom_bar()  
)
```

É a mais comum na prática, e a que você vai achar na internet.

A regra da aula 5 continua valendo, sem exceção.


Nome de coluna dentro do `aes()`, valor fixo fora dele. Mudou onde o `aes()` está escrito, não o que ele faz.

Numérica e categórica: caixas

Uma caixa por categoria. Cada caixa é o resumo da aula 3, desenhado.

```
(  
  ggplot(penas, aes(x="regime", y="pena_anos"))  
  + geom_boxplot(fill="#DCDCDC")  
)
```

a linha do meio	a mediana
a caixa	do primeiro ao terceiro quartil
os fios	até os valores ainda típicos
os pontos soltos	os distantes do resto



O boxplot resume, e resumir é esconder.


Duas distribuições muito diferentes podem ter a mesma caixa. Quando a forma importa, use o histograma com facetas.

Duas categóricas: o position

As mesmas duas variáveis, o mesmo `geom_bar()`, três perguntas diferentes. Só muda o argumento `position`.

`position="stack"`


o padrão: quantos casos, empilhados



Compara total. Comparar as fatias de olho engana, porque as barras têm alturas diferentes.

`position="fill"`


todas com altura 1: proporção



Compara composição. É o gráfico que responde a pergunta da aula 4.

`position="dodge"`

lado a lado: contagem, sem empilhar



Compara cada combinação. Bom quando o tamanho de cada grupo importa.

`position="fill"` esconde quanta gente tem em cada barra: uma com 4 casos e outra com 400 ficam do mesmo tamanho.

Preparar a tabela antes do gráfico

Quando a altura da barra é uma conta, o pandas faz a conta e o plotnine só desenha. Três operações, e as três caem no Projeto 02.

.assign(nova=expressao)

criar uma coluna sem quebrar o encadeamento


.groupby(col, as_index=False)

agrupar já saindo com a coluna dentro da tabela, sem precisar do .reset_index()

reorder("categoria", "valor")

ordenar as barras, escrito dentro do aes(). Ordenar a tabela NÃO ordena as barras.

```
ggplot(resumo, aes(x="reorder(comarca, pena_mediana)", y="pena_mediana"))  
+ geom_col(fill="#E50505") + coord_flip()
```



Que gráfico para que par

as duas variáveis	a pergunta	a geometria
numérica × numérica	quando uma cresce, o que a outra faz	<code>geom_point() + geom_smooth()</code>
numérica × numérica, x é tempo	como evolui	<code>geom_line()</code>
numérica × categórica	a distribuição muda entre as categorias	<code>geom_boxplot()</code>
numérica × categórica, já resumida	comparar um valor por categoria	<code>geom_col()</code>
categórica × categórica	a composição muda entre as categorias	<code>geom_bar(position="fill")</code>
categórica × categórica, contagem	quantos casos em cada combinação	<code>geom_bar(position="dodge")</code>

A terceira variável, quando existe, entra em color ou fill dentro do `aes()`, ou em `facet_wrap()` quando ficar carregado.

Projeto 02

Em grupo, valendo nota, uma hora. É a Gincana do Pipeline de terça-feira, no computador.

Seis desafios

cada um com uma pergunta e a imagem do gráfico que vocês precisam produzir. Dá para avançar e voltar.

Valem 11 pontos

o primeiro vale 1 e os outros 2. Cada tentativa errada desconta 0,25, e a nota para em 10.

Blocos fora de ordem

de pandas e de plotnine. Você escolhe quais usar e em que ordem.

Tem bloco que não serve

e o app explica por que, quando você usa. É o distrator da gincana.

Entrega hoje

no fim da aula. Não há prazo no dia seguinte.

O que o projeto cobra

da aula 5

```
.query() · .groupby().agg() · geom_col()  
contra geom_bar() · coord_flip() · labs()
```

de hoje

```
ggplot(dados, aes(...)) · geom_point() ·  
geom_smooth() · geom_line() · geom_boxplot()  
· .assign() · as_index=False · reorder()
```

Tudo isso está no notebook de hoje, e ele fica aberto durante o projeto.

Duas numéricas: pontos


Um ponto por linha da tabela, com a posição dada pelas duas colunas. `geom_smooth()` acrescenta a reta que resume a nuvem.

```
(  
  ggplot(penas, aes(x="n_palavras_ementa", y="pena_anos"))  
  + geom_point(alpha=0.4)  
  + geom_smooth(method="lm", color="#E50505")  
)
```

alpha vai fora do aes(): é um valor fixo, e serve para enxergar os pontos empilhados uns sobre os outros.

A reta é quase plana, e isso é uma resposta.

O tamanho da ementa não diz quase nada sobre a pena. Gráfico que não mostra relação também responde à pergunta.



O que a reta não diz

Duas leituras que o gráfico anterior não autoriza, e que vão aparecer no relatório de vocês se ninguém avisar.

Reta plana não prova que não há relação

Prova que não há relação linear nestes 197 acórdãos, que são os que tinham regime e pena legíveis na ementa. Mais da metade da base ficou de fora, e ela não saiu por sorteio.

Reta inclinada não provaria causa

Se ementas longas viessem com penas altas, o mais provável seria que caso grave gera ementa longa e pena alta. A reta mede associação, e associação não é causa.

No exercício 3 do notebook vocês escrevem as duas linhas: o que o gráfico mostra, e o que ele não permite concluir.

Antes de sair

Submeta pelo BlackBoard

A entrega é hoje, no fim da aula. O app mostra o que foi registrado na sua sessão.

Rode o notebook inteiro em casa

Principalmente os exercícios 1 a 3, que são os que pedem a leitura escrita do gráfico.

Aula 7

Probabilidade. Volta o papel e a caneta, e some o computador.